

北京交通大学

BEIJING JIAOTONG UNIVERSITY

硕士专业学位论文

基于人工蜂群算法的推荐速度曲线节能优化

作者姓名 刘海娜

工程领域 控制工程

指导教师 王俊峰 教授

培养院系 电子信息工程学院

二零一九年六月

北京交通大学

硕士专业学位论文

基于人工蜂群算法的推荐速度曲线节能优化

Energy-saving Optimization of Recommended Speed Curve Based on
Artificial Bee Colony Algorithm

作者：刘海娜

导师：王俊峰

北京交通大学

2019年6月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

(保密的学位论文在解密后适用本授权说明)

学位论文作者签名: 

导师签名: 

签字日期: 2019年 6月 15日

签字日期: 2019年 6月 15日

北京交通大学

硕士专业学位论文

基于人工蜂群算法的推荐速度曲线节能优化

Energy-saving Optimization of Recommended Speed Curve
Based on Artificial Bee Colony Algorithm

作者姓名：刘海娜 学号：17125108

导师姓名：王俊峰 职称：教授

工程硕士专业领域：控制工程 学位级别：硕士

北京交通大学

2019年6月

致谢

时光荏苒，岁月如梭。回首这两年的硕士生涯，感悟颇多，收获亦丰。

首先要感谢的是我的导师王俊峰教授，本论文是在王老师的悉心指导下完成的，自研一入学到现在将近两年的时间，王老师广博的专业知识、丰富的铁路阅历、勤勉的工作方式、严谨的治学态度、宽广的胸襟为人以及健康的生活方式为我以后人生的学习、工作、生活提供了丰富的借鉴经验，能够师从王老师是我莫大的荣幸。再次感谢王老师在硕士研究生学习期间的谆谆教导和关心爱护。

其次我要感谢各位同窗在实验室科研期间对我的热心帮助。感谢马云鹏、刘浩、徐鹏、刘奇、李明辉、张慧、朱冰洁、刘振宇、张子航、张子群、李爽、陈佳倩，在论文撰写期间，是他们抽出自己宝贵的时间来献计献策，是他们的激烈研讨启发着我思绪的不断完善，是他们的嘘寒问暖始终激励着我砥砺前行。在这里收获的友谊必将使我终生难忘，特在此对他们表示由衷的感谢。

再次我要感激我的家人。亲情是世间最伟大和无私的，没有一丝埋怨地在背后默默支持和鼓励着我，当我为科研而忙碌的时候他们选择不打扰默默的思念、当我感到迷茫的时候他们会耐心的开导、鼓励我，永远做我坚强的后盾，是他们的支持和理解让我更有信心完成学业。

最后我要感谢母校北京交通大学，是学校处处以人为本的理念和广大同窗所营造的良好学术氛围，激发着我不断前进，不断学习，不断进步。感谢为评阅本论文而付出辛勤劳动的各位专家、教授与学者们，感谢在进行学位论文答辩时，各位专家所提出的宝贵意见与建议，感谢所有曾经帮助过我的人！

摘要

城市轨道交通由于具有运输人次多、线路长、间隔时间短、时速快、准时性高等特点已经成为城市中的主流交通运输工具，且其线路数量及运营里程仍在不断增加，因此作为国民经济中能耗最大的行业之一，列车的节能运行显得尤为重要。其中，列车在运行过程中由于牵引做功所消耗的能量占据总能耗一半的比率，因此，通过优化推荐速度曲线以降低牵引能耗的研究具有重要的现实意义。结合现有对推荐速度曲线进行优化的遗传算法、粒子群算法均容易陷入局部收敛的现状，本文提出应用寻优精度高、收敛速度快且全局寻优能力强的人工蜂群算法对列车推荐速度曲线进行优化，主要工作如下：

(1) 分析运行中列车的受力情况，建立动力学模型，并根据动力学方程应用极大值原理，建立哈密尔顿函数，引入拉格朗日算子分析得到列车的最优操纵策略。以能耗和站间运行时间误差为优化目标，建立多目标优化模型，将推荐速度曲线的优化问题转化为在速度-距离二维空间中寻找能耗最低、运行时间误差最小的路径规划问题。

(2) 通过算法对比的方式验证人工蜂群(ABC)算法的寻优精度、稳定性、收敛速度等性能，将粒子群算法和差分进化算法作为对比，应用 MATLAB 分别用三种算法对单峰单极值函数 Sphere Model、多峰多极值函数 Griewank 以及病态函数 Generalized Rosenbrock 进行从低维到高维的仿真，每项仿真运行 30 次，将最大值、最小值、平均值生成表格进行分析，共计 1110 次的仿真对比结果验证了 ABC 算法在寻优精度和稳定性上的绝对优势。通过三种算法适应度进化曲线的对比，验证了 ABC 算法收敛速度相对更快的特点。证明了应用人工蜂群算法优化推荐速度曲线的可行性。

(3) 对于推荐速度曲线节能优化问题提出两种方法，一是将运行时间误差作为约束条件，以此应用单目标优化的方式进行求解，二是对人工蜂群算法进行改进，根据 Pareto 支配原则改变算法中适应度值的计算方式，将得到的 Pareto 最优解存储于外部档案中，并根据拥挤距离对外部档案进行维护，同时改进邻域搜索公式使得外部档案中的解对于搜索具有指引作用。分别对两种方法建立模型，进行优化。

(4) 应用亦庄线的实际数据，以 MATLAB 为工具，对优化模型进行仿真验证，分别用单目标方法和多目标方法进行优化仿真，验证了多目标优化方法的优越性；从等分区间和非等分区间的仿真对比中，验证了等分区间的有效性；从控制策略设置不同参数得到的仿真结果中，验证了ATO控制策略对节能优化的影响。

关键词：城市轨道交通；推荐速度曲线；人工蜂群算法；多目标节能优化；
ATO 控制策略

ABSTRACT

Urban rail transit has become the mainstream means of transportation in cities because of its large volume, fast speed, dense shift and high punctuality, and the number of lines and operating mileage are still increasing. Therefore, as one of the industries with the largest energy consumption in the national economy, energy-saving operation of trains is particularly important. Among them, the traction energy consumption of trains accounts for half of the total energy consumption of urban rail transit. Therefore, it is of great practical significance to reduce the traction energy consumption by optimizing the recommended speed curve. Combining with the current situation that genetic algorithm and particle swarm optimization are easy to fall into local convergence, an artificial bee colony algorithm with high precision, fast convergence and strong global optimization ability is proposed to optimize the recommended speed curve of trains. The main work is as follows:

(1) The force of train in operation is analyzed and the dynamic model is established. Based on the dynamic equation and the maximum principle, the Hamilton function is established, and the Lagrangian operator is introduced to analyze the optimal control strategy of the train. Taking energy consumption and running time errors of stations as optimization objectives, a multi-objective optimization model is established, and the optimization problem of recommended speed curve is transformed into a path planning problem with the lowest energy consumption and running time errors in speed-distance two-dimensional space.

(2) The performance of the artificial bee colony (ABC) algorithm is verified by comparing the algorithms. Particle swarm optimization (PSO) and differential evolution (DE) are compared. Three algorithms are used to simulate the single-peak single-extremum function Sphere Model, multi-peak multi-extremum function Griewank and respectively generalized Rosenbrock from low-dimensional to high-dimensional in MATLAB. Each simulation runs 30 times, and the maximum, minimum and average values are generated into tables for analysis. A total of 1110 simulation comparisons verify the absolute superiority of ABC algorithm in search accuracy and stability. By comparing the fitness evolutionary curves of the three algorithms It is proved that the convergence speed of ABC algorithm is relatively faster. It is proved that the artificial bee colony algorithm can optimize the recommended

speed curve.

(3) Two methods are proposed for the optimization of recommended speed curve. One is to transform multi-objective optimization into single-objective optimization by using run-time errors as constraints. The other is to improve the artificial bee colony algorithm. According to the principle of Pareto domination, the method of calculating the fitness value of the algorithm is changed, and the Pareto optimal solution is stored in the external file, and according to the congestion distance to maintain the external archives, at the same time, improve the neighborhood search formula, the solution in the external archives can guide the search. The two methods are modeled and optimized respectively.

(4) Based on the line data of Beijing Metro Yizhuang Line, the optimization model is simulated and validated by using MATLAB. The advantages of multi-objective optimization method are verified by comparing single-objective optimization with multi-objective optimization. The validity of sub-section is validated by comparing the simulation between equal-section and non-equal-section. The simulation results obtained by setting different parameters of control strategy are simulated. The real results verify the influence of ATO control strategy on energy-saving optimization.

KEYWORDS: urban rail transit; artificial bee colony algorithm; recommended speed curve; multi-objective energy-saving optimization; ATO control strategy

目录

致谢	ii
摘要	iii
ABSTRACT.....	v
1 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 列车节能优化操纵策略研究现状	2
1.2.2 推荐速度曲线优化算法研究现状	3
1.2.3 现有研究方法的不足及改进	6
1.3 论文主要内容及章节安排	7
2 列车自动运行系统及运行模型	9
2.1 列车自动运行系统	9
2.2 列车运行动力学模型	11
2.2.1 列车牵引力	11
2.2.1 列车制动力	13
2.2.3 列车运行阻力	14
2.2.4 动力学模型	16
2.2.5 列车节能运行工况及其转换原则	17
2.3 其他约束指标	22
2.3.1 准点率	22
2.3.2 停车精度	23
2.3.2 乘客舒适度	23
2.4 本章小结	24
3 人工蜂群算法	25
3.1 生物学原理	25
3.2 基本模型	26
3.3 算法实现步骤	29
3.4 特点分析	31
3.5 寻优性能仿真验证	31
3.5.1 Sphere Model 函数	32

3.5.2 Griewank 函数	34
3.5.3 Generalized Rosenbrock 函数	37
3.5.4 维数、迭代次数对算法的影响	39
3.6 本章小结	42
4 基于人工蜂群算法的推荐速度曲线优化	43
4.1 问题与假设	43
4.2 多目标优化问题	44
4.2.1 多目标优化问题的数学模型	44
4.2.2 多目标优化问题的解决方法	47
4.3 列车节能优化设计策略	47
4.3.1 列车运行操纵策略	47
4.3.2 坡度等效策略	48
4.3.3 变量离散化	48
4.4 基于 ABC 的推荐速度曲线单目标节能优化	50
4.4.1 模型建立	51
4.4.2 算法求解过程	52
4.5 基于改进 ABC 的推荐速度曲线多目标节能优化	54
4.5.1 模型建立	54
4.5.2 多目标人工蜂群算法	55
4.5.3 算法求解过程	57
4.6 本章小结	58
5 仿真与分析	59
5.1 基础数据	59
5.1.1 线路数据	59
5.1.2 车辆数据	60
5.1.3 控制策略	61
5.2 单目标优化与多目标优化的仿真验证	61
5.3 等分区间与非等分区间的仿真验证	65
5.4 不同控制策略下的仿真验证	66
5.5 本章小结	68
6 总结与展望	69
6.1 总结	69

6.2 展望	70
参考文献	73
图索引	77
表索引	79
作者简历及攻读硕士学位期间取得的研究成果	81
独创性声明	83
学位论文数据集	85

1 引言

1.1 研究背景及意义

随着我国政治、经济、文化的飞速发展，人口规模的不断扩大给我国交通运输带来更多的压力。交通运输在能源消耗中占了很大比重，全球超过 40% 的石油资源应用于交通运输领域。据有关资料显示，在等量的运输情况下，铁路、公路和航空的能耗比为 1:9.3:18.6；铁路、公路、水路、航空的客运成本之比为 1:1.59:6:5.54；铁路、公路、水路、航空的货运成本之比为 1:6.23:0.64:17.2。由以上数据可得，轨道交通无论是从能源消耗还是运输成本上，都从众多交通运输方式中脱颖而出。除了节能环保，城市轨道交通作为城市中的主流交通运输工具，还具有运输人次多、等候时间短、时速高、安全舒适、准点率高、全天候、运费低等优点，深受国家及广大人民群众的青睐，并在越来越多的城市得到普及。

截止 2017 年 12 月 31 日，中国大陆包括北京、上海、广州等 35 座城市开通运营轨道交通线路，共 171 条线路，总里程高达 5083.45 公里，车站 3269 座。截止 2018 年 12 月 31 日，中国大陆地区城市轨道交通运营线路达 173 条，分布在上海、北京、广州、南京等全国 36 座城市，总里程达 5494.9 公里，车站 3513 座。近年来，我国城市轨道交通里程数不断增长，截止 2018 年底，共有 63 个城市的轨道交通网规划获批，意味着未来几年城市轨道交通的里程数还将持续增长。据有关统计，北京地铁的日均客运量已经达到 1086.55 万人次，工作日客运量达到 1210.03 万人次，为城市交通做出了重要贡献，但根据计算，1 条 25 公里的轨道交通运营线路，1 年的耗电量约在 1-2 亿千瓦时，轨道交通成为各城市的用电大户。数据显示，2015 年北京市轨道交通用电量达到 14 亿千瓦时，占地铁整体运营成本的四成，约相当于 73 万户三口之家一年的用电量。在如此巨大的能耗面前，每降低一个百分点的能耗都对于节约能源具有极其重大的意义。

轨道交通的运行能耗主要应用于车辆牵引系统以及其他辅助系统，能耗分布图如图 1-1 所示。其中，列车的牵引供电系统消耗的能量最多，占比为总能耗的 1/2；其次为通风空调系统，占比 1/3；占比最小的则是照明、水调节、机械装置等其他辅助系统的能耗。而列车的牵引供电系统耗能主要应用于列车运行过程中的牵引力做工，因此，对列车的运行过程进行分析，以减少列车运行过程中的牵引次数及牵引里程为出发点，对线路中列车的运行速度及操纵策略进行优化，从而

达到节能的目的具有重要的意义。

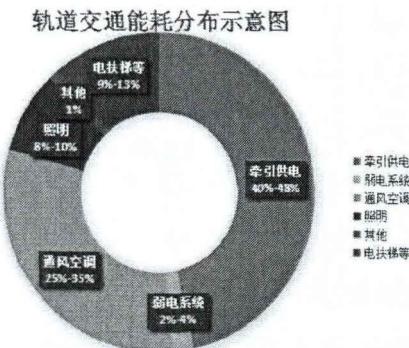


图 1-1 城轨能耗分布图

Figure 1-1 Urban rail transit energy consumption distribution map

在列车运行过程中，由于司机驾驶习惯的不同，在相同路况的条件下，不同司机驾驶同一辆列车在相同运行时间内所产生的能耗不同。因此，为了减少不必要的能量损失，优化列车的运行操纵策略是十分必要的。另一方面，列车自动控制系统 ATC (Automatic Train Control) 是保证列车安全、高效、准点的关键。ATC 由列车自动防护系统 ATP (Automatic Train Protection)、列车自动驾驶系统 ATO (Automatic Train Operation) 以及列车自动监督系统 ATS (Automatic Train Supervision) 组成。其中，ATO 在 ATP 的防护下，受 ATS 的监督，接收 ATS 发出的指令进行自动驾驶，根据路况计算推荐速度曲线并实时调整列车行驶速度，控制列车的运行^[1]。由于列车的自动驾驶是动态、非线性、实时性并且存在滞后的，所以车载 ATO 最复杂、最关键、最核心的功能就是列车的自动调速功能^[2]。ATO 的自动调速由两部分组成，第一部分是根据路况以及实时返回的速度信息，在不超过 ATP 防护的速度条件下，通过算法计算出安全、高效、节能的推荐速度曲线；第二部分是根据所得的推荐速度曲线对列车速度进行控制，保证列车的高效运行^[3]。因此，应用最佳的优化算法计算得出最优的推荐速度曲线成为列车行驶过程中达到能源节约的一条有效途径。

综上所述，从对列车操纵运行策略和列车推荐速度曲线的优化两方面出发，进行列车的节能减耗，具有可行的现实意义。随着我国铁路里程的不断增加，轨道交通已逐渐成为我国能源消耗最多的行业之一，研究列车运行中的节能优化问题，介绍列车运行过程中的能耗损失，将对我国的经济建设具有重要意义。

1.2 国内外研究现状

1.2.1 列车节能优化操纵策略研究现状

针对操纵策略的节能，国外研究开始的时间要早于国内，早在 70 年代末，美国就开始研究该方面相关内容。近年来，列车节能优化的理论方法更是层出不穷。1980 年，I.P.Milroy 发现在运行里程较短并且无临时限速的前提下，单列车运行在平直轨道或较为平坦的坡道时，列车的节能操纵由全力加速、惰行以及全力制动 3 个阶段组成，并应用庞氏最大值的方法求得了列车的速度距离曲线，得以验证该操纵策略的最优性^[4]。1982 年，Lee、Milroy 等又提出，当运行距离较长时，列车存在匀速运行的阶段可以达到节能的目的，这一发现对先前得出的结论进行了补充^[5]。1984 年，Howlett 和 Asnis 分别采用极小值原理，从理论方面验证了列车运行距离较长的条件下，最节能的运行操纵策略为加速-恒速-惰行-制动^[6]。1996 年，Howlett 将列车运行区间划分为多个独立的子区间，每个子区间的坡度近似为一个常数，建立离散的坡道线路数学模型，进行计算^[7]。1997 年，Howlett 对该离散的数学模型进行改进，提出了一种连续变化坡度模型，减小了误差^[8]。2000 年，Howlett 提出在建立离散的坡道线路数学模型时考虑路况限速这一因素，Howlett 等人提出了寻找列车运行工况转换的最佳位置进行列车运行操纵策略的节能优化，并分别在连续和离散控制两方面进行分析^[9]。

近年来，国内的很多学者依据我国轨道交通特点对操纵策略开始进行优化，并且在理论和实践领域都取得了很大的成功。1994 年，王自力根据下坡道列车受力的特点，提出提前惰行进入下坡道，充分利用下坡时由势能转化而成的动能，进而达到节能的目的^[10]。1998 年，金炜东等提出一种将局部寻优与全局寻优相搭配的结构，考虑线路坡度对能耗的影响，通过仿真结果得出局部寻优的规律，利用神经网络做数据组织，通过遗传算法进行仿真验证，取得良好成果^[11]。2007 年，李玉生、侯忠生以列车节能控制模型为基础，提出了在相同坡度的区间内最多进行两次手柄位转换的方法，以此将坡道分成三份进行优化，达到减小计算量的目的，并应用遗传算法对该问题完成验证^[12]。2011 年，丁勇等针对能耗和运行时间两个优化目标，提出先对惰行点的位置和次数进行优化，再对各小区间的运行时间进行合理分配的优化方法^[13]。2016 年，耿超对有限速约束和无限速约束两种不同情况进行研究，分别总结出列车运行工况的最佳节能切换策略^[14]。同年，王成莉提出先应用遗传算法对速度曲线进行全线的优化，再对曲线的中间部分进行惰行优化，找到最佳惰行点，两次优化得到节能率更高的速度曲线^[15]。

1.2.2 推荐速度曲线优化算法研究现状

目前对于推荐速度曲线优化的方法可以分为三大类，分别为解析法、数值法和智能算法，以下对三种算法的研究现状做详细介绍。

(1) 解析法与数值法

解决优化问题常用的解析法有极大值原理和动态规划算法，常用的数值法有梯度法和序列二次规划。2000年，Khmelnitsky等提出应用最大值原理对列车运行过程进行分析计算，得出最优操纵策略，根据策略控制列车的牵引和制动，达到在给定时间给定线路上能耗最小的目的，并且验证了该方法的有效性^[16,17]。2003年，Rachel等提出了一种新的最佳控制和方程序列，以此来找到最佳的控制变化点，完成对速度曲线的控制优化^[18]。2011年，Baranov L等提出应用最大值原理寻求列车的最优工况，并分析了列车动力学模型及其误差对最佳运行轨迹的影响^[19]。2013年，梁志成等利用极大值原理推导得出列车节能运行的最优工况集^[20]。2014年，Xu等提出了一种多尺度动态规划（MDP）的方法来优化列车的速度曲线，基于DP在求解其子问题的基础上解决较大问题的思想，MDP反复将距离部分划分为较小的部分进行优化，仿真结果证明MDP可以获得更好的列车速度曲线，能耗减少7.16%^[21]。同年，Qu等先应用最大值原理得出最优运行模式，然后在此基础上提出了一种数值算法，在考虑速度限制的情况下，在给定时间内构建节能速度曲线^[22]。同年，顾青等提出了一种新的将解析法和数值法进行结合得出最优控制策略的方法，该方法打破了大多数算法只能离线优化的局限性，可以做到对列车的运行速度进行实时优化，具有重要意义^[23]。2015年，唐海川应用动态规划算法分别研究了单列列车运行过程中的节能优化以及多列列车追踪运行过程的节能优化，并进行了仿真验证，得到良好的效果^[24]。2016年，蔡虎等提出根据区间限速的不同来离散化站间线路，再以每个区间为标准建立能耗和站间运行时间的函数关系，以进行时间的分配，经过仿真验证了可行性，并且应用硬件进行测试，取得良好的成果^[25]。

(2) 智能算法

智能算法因其操作简单、计算速度快、移植性好等优点成为解决优化问题的首选算法，常用的智能算法有遗传算法、粒子群算法、蚁群算法等，均为推荐速度曲线的优化做出贡献。

1) 遗传算法

2004年，Wong提出应用遗传算法寻找最佳惰行点，并采用分层遗传算法来确定惰行点的数量^[26]。2007年，Sentinella分别应用遗传算法和差分进化算法进行目标速度曲线的优化，仿真对比结果证实遗传算法具有更高的效率，然后将两种算法在多种群优化程序中进行结合，得到更优的速度曲线^[27]。2010年，Bocharknikov提出考虑再生制动能量利用的前提下，将列车能耗和运行时间的加权组合作为目标函数，并应用遗传算法实现推荐速度曲线的优化^[28,29]。2012年，王鹏玲等提出应用一种改进的自适应遗传算法优化速度曲线的方法，并预先设定制动曲线等以

提高算法中可行解的质量^[30]。2013 年, 卢启衡等提出一种应用多为并行遗传算法对追踪运行的两列车分别进行速度曲线优化的方法, 并且在移动闭塞仿真平台上得到验证^[31]。2014 年, 龙凤维应用遗传算法寻找在定时约束以及安全、准点、舒适度约束条件下的惰行工况转换关键点, 在节能的同时, 保证列车的运行效率及舒适度等人性化指标^[32]。2016 年, 王成莉提出应用两次遗传算法, 第一次算法应用于列车运行的全过程, 寻找优化后的速度曲线, 第二次应用算法寻找列车运行中间阶段的最佳惰行点, 两次算法叠加取得了更好的节能效果^[33]。2017 年, 桂行东对遗传算法进行改进, 使其成为基于 Pareto 支配原则的多目标算法, 对速度曲线进行多目标优化^[34]。2018 年, 纪云霞等对遗传算法进行改进, 对算法中邻域搜索的方向进行引导, 加快算法的收敛速度, 将改进的算法应用于速度曲线的寻优中取得了良好成果^[35]。同于 2018 年, 何彤等提出采用非支配排序遗传算法 II (NSGA-II) 对模型进行求解, 得到列车运行的最优速度曲线, 并且结合模糊控制器算法和预测控制设计智能控制器进行列车的追踪运行^[36]。2019 年杨彦强等提出在应用遗传算法对推荐速度曲线进行优化的基础上加入分别对时间和能耗进行惩罚的双重机制, 以加快算法收敛速度, 提高解的质量, 达到更优的节能效果^[37]。

2) 粒子群算法

2010 年, Hui 等提出在优化模型中, 在对时间、速度进行约束的同时, 对时间步长也进行约束, 使其在线路上等分, 后应用粒子群算法对提出的单目标优化模型进行仿真验证, 取得良好的成果^[38-40]。2014 年, Gago 等提出应用多目标粒子群算法优化列车的推荐速度曲线, 得到能耗和时间的 Pareto 前端, 并将该方法与非支配排序遗传算法进行对比, 验证其适应性^[41-43]。2015 年, 任啸宇提出对粒子群算法进行改进以减少其后期陷入局部收敛的可能性, 并应用改进后的算法先对速度曲线进行优化, 后对时间进行分配, 优化运行时刻表的方法^[44]。2016 年, 叶庆仕等提出一种改进的基于高斯白噪声扰动变异的粒子群算法, 分别进行单车和多车的速度曲线优化, 并讨论了延时的情况^[45]。同于 2016 年, 李玲玉提出一种动态的粒子群算法以解决列车节能运行这一多目标优化问题, 并进过仿真证明该方法在追踪运行中具有良好的节能效果^[46]。2017 年, 谭文举等提出将改进的免疫粒子群算法应用于速度曲线的优化, 并考虑再生制动产生的能量, 对列车运行过程进行优化^[47]。2018 年, 高坚提出引入实数交叉的方法, 对粒子群算法进行改进, 应用于速度曲线的离线优化, 并将该算法应用于 PID 控制器的设计中, 实现跟踪运行^[48]。同于 2018 年, 李烨等提出将列车节能优化模型中的约束条件应用罚函数的思想转化成为目标函数中的一个变量, 以此在无约束的条件下应用粒子群算法进行优化, 并通过验证取得良好效果^[49]。

3) 蚁群算法

2009 年 Bwo-Ren Ke 等提出将连续的站间线路能耗最小寻优问题理解成组合优化问题，并应用智能算法 MMAS 来优化列车的速度轨迹^[50]。2013 年，Hillmanssen 等分别应用遗传算法、蚁群算法和动态规划算法对推荐速度曲线进行离线优化，发现蚁群算法相较于遗传算法稳定性较好且优化质量较高，而动态规划算法的计算工作量过于庞大，因此得出的多种群算法更适合优化速度曲线的结论^[51,52]。2015 年，范礼乾通过对列车自动控制系统的分析与研究，提出应用蚁群算法对列车自动运行系统中的推荐速度曲线进行节能优化，以达到列车节能运行的目的，并搭建出仿真平台，为推荐速度曲线节能优化的研究做出重要贡献^[53]。2016 年，张志明对蚁群算法进行改进，在原算法的基础上提出两阶段的方法以优化目标速度曲线，并经过仿真验证其可行性^[54]。同年，李卓玥分别应用粒子群算法、蚁群算法以及两种算法相结合的方法对推荐速度曲线进行优化，仿真结果证明两种算法相结合能达到更优的效果^[55]。2017 年，张靖林将蚁群算法和粒子群算法相结合应用于目标速度曲线的求解，并提出应用动态矩阵控制算法来控制列车的追踪运行^[56]。

4) 其他算法

1975 年，Hoang 等提出了一种采用直接搜索算法的启发式算法，并将其用于轨迹优化，以减少列车在轨道上双向行驶所消耗的能量之和^[57]。1999 年，Chang 结合 Pareto 最优集合，提出了一种新的差分进化方法（DE），通过调整公共交通系统中的模糊隶属函数来优化列车运动^[58,59]。2013 年，杨文等提出了一种对推荐速度曲线进行在线优化的算法，该算法结合无模型自适应控制和预测控制，并给出了三种解决约束问题的方法^[60]。2015 年，Liu 提出了两种改进的禁忌搜索（TS）算法，分别为加速率决定修正（ARDM）和距离决定修正（DDM），基于该模型对列车推荐速度曲线进行优化^[61]。2017 年，Chang 对差分进化算法进行改进，提出了三个新的试验向量方程，生成非支配排序微分进化算法（NSDE），利用秩和拥挤距离对每个迭代的父代和子代的解进行排序，提高了推荐速度曲线优化中解的质量以及算法的优化精度^[62]。同年，陶细华提出将遗传算法与标准粒子群算法相结合应用于推荐速度曲线的优化中，并根据层次分析法和熵权法计算各目标约束的权重^[63]。同年，汪仁智等提出应用预测控制算法对晚点车辆的目标速度曲线及跟踪控制进行优化的方法^[64]。

1.2.3 现有研究方法的不足及改进

优化算法方面，极大值原理、动态规划法等解析算法是直接用代数法求解，从理论上可以得到最优解，但此类算法在使用时结构、建模较为复杂，且算法本身存在大量假设，有些参数的选择会影响计算速度，使得求解过程缓慢，不易实

现。梯度算法、序列二次规划算法等数值算法能够较好地解决多个输入的控制问题，但由于计算复杂、计算量过大，不利于使用。智能算法因其操作简单、计算速度快、移植性好等优点受到广大学者的喜爱，并在列车节能运行优化中得到广泛应用。尤其是群智能算法，根据研究现状得知，遗传算法、粒子群算法、蚁群算法等都在速度曲线的节能优化中取得了良好的成果，但以上几种智能算法或多或少的都存在容易陷入局部收敛并且后期算法的搜索速度变慢的弊端，因此，问题的解决还应从对算法进行优化以及寻找新的算法着手。

多目标优化方面，列车的节能运行不仅仅是在一段封闭线路上寻找能耗最低方法的简单优化，因其受线路本身的影响、受速度、加速度等约束条件的制约，同时还要考虑站间的运行时间等，故而是一个复杂的多目标优化问题，优化要求在保证能耗最低的同时，要确保列车的准点率、停车精度、乘客的舒适度以及最重要的列车运行安全问题。列车的实际运行中，以上因素都在必要考虑范围之内，现有研究对于列车节能运行的多目标优化还有所欠缺，难以真正投入到实际应用中。

针对现有研究方法的不足，本文提出将收敛速度快、寻优精度高、不易陷入局部收敛的人工蜂群算法应用于列车推荐速度曲线节能优化的新思路，并针对节能优化这一多目标问题，结合 Pareto 支配原则对人工蜂群算法进行改进，使其适应于多目标优化问题的求解。

1.3 论文主要内容及章节安排

本文对近几年的轨道交通现状作出分析，结合各部分耗能情况，得出列车节能运行的必要性及重要性。对列车自动控制系统进行深入研究，得出可以通过优化ATO系统中的推荐速度曲线达到节能优化的目的。对列车运行过程中受的所有力进行分析，通过每种运行工况的受力得出各工况的能耗情况，寻找最佳的工况组合作为能耗最低的运行操纵策略。应用改进的人工蜂群算法对推荐速度曲线进行节能优化，并经过实例仿真结果进行验证。本文具体的章节安排及主要内容如下：

第一章为绪论，首先介绍了本文研究的背景及意义，通过大量数据体现我国轨道交通的发展之迅猛、能耗量之大，找到耗能最多的牵引供电部门，证明列车运行过程中节能的重要性。其次，对国内外列车运行操纵策略及列车节能优化算法的研究现状进行了分析，找出现有问题的不足，提出新思路。最后介绍了文章的主要内容及章节安排。

第二章首先介绍了列车自动控制系统 ATC，并主要介绍了推荐速度曲线所应

用于的列车自动驾驶系统 ATO，分析了列车的控制模型。其次，对列车运行过程中的受力情况进行分析，建立动力学模型，进而得到能耗模型，通过对能耗模型的研究，得出最佳操纵策略，建立列车运行模型，最后，对影响列车 ATO 性能的其他指标进行分析。

第三章详细介绍了人工蜂群算法（ABC）。首先，通过其生物学原理、基本模型以及寻优步骤、特征分析四个方面分别介绍了 ABC 算法的寻优机理。其次，通过对三个基准函数进行优化仿真，并与粒子群算法（PSO）、差分进化算法（DE）的仿真结果进行对比分析，验证 ABC 算法在寻优精度、收敛速度以及稳定性方面的性能，证明人工蜂群算法应用于推荐速度曲线节能优化的可行性。

第四章将推荐速度曲线优化问题进行分析，转化为在速度-距离二维空间上的路径规划问题。对优化条件作出假设，对优化线路进行离散化，确定列车运行操纵策略。将列车推荐速度优化这一多目标优化问题分别应用多目标转化为单目标和直接应用多目标函数的方法进行建模，并对具体的优化步骤做出详细介绍。

第五章通过 MATLAB 仿真平台，应用亦庄线的限速、坡度、车辆等数据进行仿真，根据数据结果进行案例分析，证明应用人工蜂群算法优化推荐速度曲线能够达到节能减排的目的，且效果良好，并通过与等分分区方法的结果对比证明非等分分区的优越性，分析控制参数不同下的各种控制策略得到的节能效果，验证合理的控制策略能够提高节能效果的结论。

第六章是总结及展望，对本文的研究及结论进行总结，提出需要改进的问题，对未来的研究做出了展望。

2 列车自动运行系统及运行模型

基于通信的列车自动控制系统 CBTC (Communication Based Train Control System) 根据功能的不同分为列车控制和信息传输两个部分。其中负责列车控制的为列车自动控制系统 ATC，ATC 系统由系统 ATP 系统、ATS 系统、ATO 系统三个子系统组成。ATS 系统负责控制列车进路、时刻表、自动折返、列车运行图、运行模式等，并对列车进行实时跟踪，监控列车的车次号、停站、车门关闭等指标。ATP 的功能是对列车运行速度进行实时防护，一旦列车运行的实际速度超过最高限速，则对列车进行紧急制动。ATO 系统控制列车运行，计算列车推荐运行速度曲线，并根据列车实时返回的速度、线路等信息，调整列车跟踪速度，达到列车安全、节能、准点、舒适运行的目的，并控制列车车门的开关、自动折返以及精准停车等。

2.1 列车自动运行系统

列车自动运行系统 ATO 是列车自动控制系统 ATC 的重要组成部分，ATC 系统各部分的分工与合作如图 2-1 所示，列车自动运行系统 ATO 在列车自动防护系统 ATP 的超速防护下，接收列车自动监督系统 ATS 的指令，控制列车的运行。车载部分安装车载记录器，记录 ATO、ATP 等系统的信息，DCS 系统实现车地的无线通信。

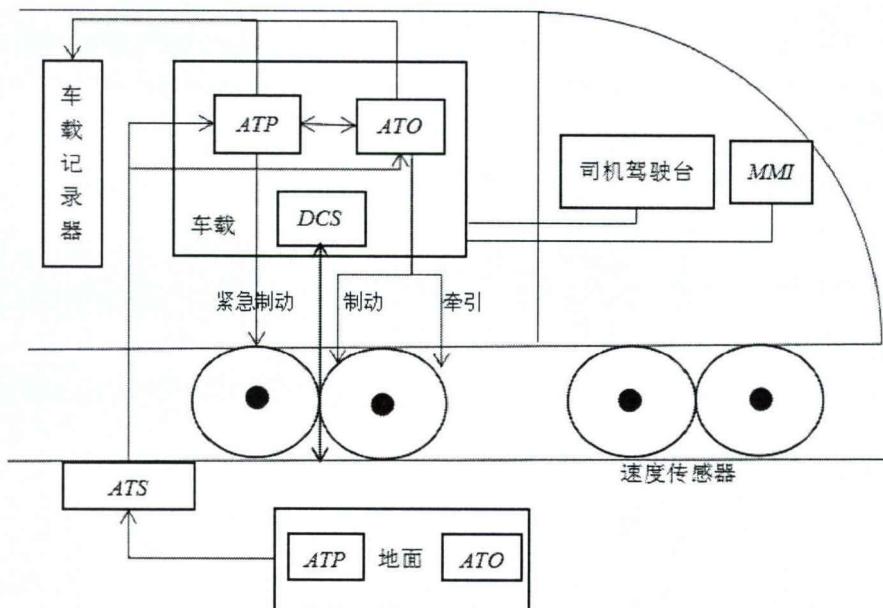


图 2-1 ATC 系统的工作原理

Figure 2-1 The working principle of the automatic train control system

列车自动运行系统ATO的内部结构分为两层，如图2-2所示。上层结构为优化部分，根据列车运行的优化目标以及列车的车辆信息、运行道路信息等计算出指导速度变化的推荐速度曲线。下层结构则为控制部分，根据计算得到的推荐速度曲线，结合实时返回的路况、速度等信息，控制列车进行牵引或制动，调整速度的大小，完成跟踪运行。

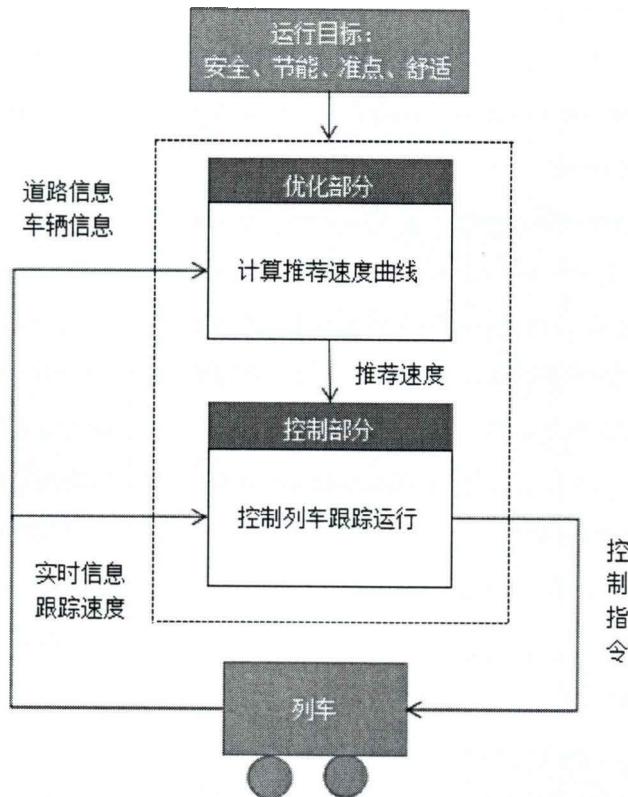


图 2-2 ATO 系统的分层控制结构

Figure 2-2 The hierarchical control structure of the automatic train operation system

列车自动运行系统代替了司机对列车的操纵运行，完成列车的自动驾驶、车站精准停车以及车门和屏蔽门的联动工作。下面以一列列车的自动运行为例，对ATO的功能进行阐述：

(1) 出站启动阶段

首先，列车在站台内停稳，乘客上下车时由ATS对停站时间进行计算，当达到列车运行时刻表中的停站时间，并且ATS未发布扣车等不允许列车出站的命令时，列车满足出站的要求，此时，ATP对发车条件进行检查，若满足发车信号开放、已完成移动授权的办理、所有车门、屏蔽门均已关闭、ATO正常工作且于ATP通信正常等条件，则列车可以正常出站，司机对ATO系统进行确认后，列车开始自动驾驶。

(2) 站间运行阶段

列车在站间自动运行时，ATO 系统模拟司机驾驶过程，以处理器代替人脑，在限速条件的约束下，考虑站间运行时间、节能、精准停车等因素计算出当前的推荐速度，并与测速传感器测得的当前速度相比较，根据推荐速度和实际速度的差值确定牵引、制动指令，以调整列车运行速度，完成自动驾驶过程。由 ATO 控制的列车间自动运行过程是一个闭环反馈控制的过程，其控制原理如图 2-3 所示，推荐速度曲线中给出的目标速度作为列车跟踪运行控制器的输入，控制器根据该输入速度发布指令列车运行，同时列车又将实时的速度信息与目标速度信息相对比，并将结果反馈给控制器，使控制器调整控制命令，更好的跟踪推荐速度曲线运行。

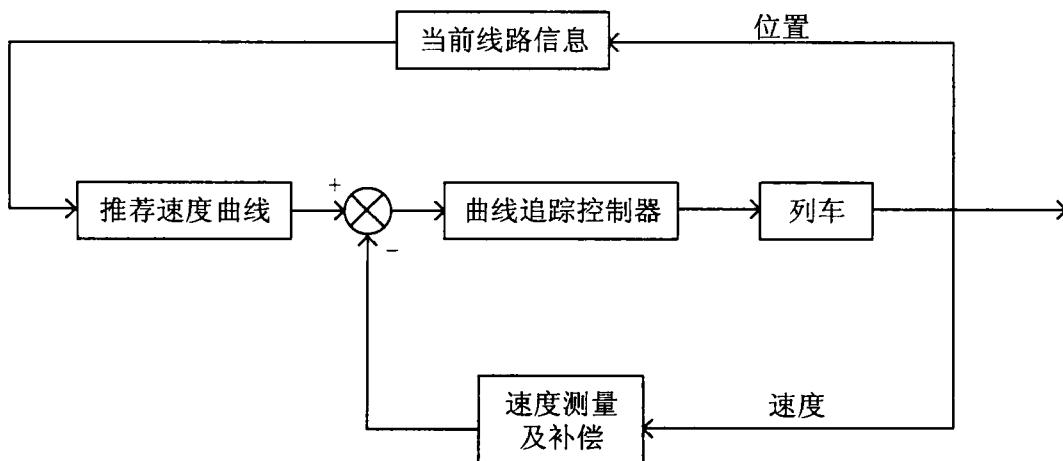


图 2-3 ATO 控制原理示意图

Figure 2-3 The figure of control principle of the automatic train operation system

(3) 进站停车阶段

列车在进站停车阶段，一旦接收到列车的停车位置信息，便计算目标制动曲线，以保证列车在恒定的制动下运行到停车点，并能够做到精准停车。当 ATP 确认列车停稳后，发布允许打开车门的命令，乘客进行换乘，ATS 计算停车时间，当达到计划的站间停车时间，ATP 检查 ATO 的发车条件，进行下一次的出站运行。

2.2 列车运行动力学模型

列车运行模型中存在着众多的输入变量，列车自身的车辆条件、牵引性能、制动性能等都对模型产生影响，列车运行区段的坡度、曲率、隧道等外界条件也都对模型产生影响，因此该模型的建立是复杂的并且为非线性的，以下对列车运行过程中受的各种外力做详细分析，得到列车运行动力学模型。

2.2.1 列车牵引力

城市轨道交通中的牵引力由列车组中的动车提供，动车上装有多个电机，各电机的作用是进行能量转换，牵引电网或第三轨的交流电通过变压整流成为直流电供给电机，电机产生一个旋转力矩，通过传送装置给列车的动轮，利用车轮与轨道之间的粘着现象，将牵引电机的旋转力矩转化成为水平的轮周牵引力，完成电能到机械能的转换^[36]。

列车牵引力示意图如图 2-4 所示，列车牵引运行时，动车上的电机产生一个旋转力矩 M ，并将这个力矩作用到动轮上，此时动轮与轨道之间由于黏着现象的存在，动轮给轨道一个摩擦力 F' ，同时动轮受到轨道的反作用力，产生一个大小相等、方向相反的摩擦力 F ，在 F 的作用下，动轮以 O 为圆心进行转动，形成向力 F 方向运行的趋势，该力 F 即为牵引力。

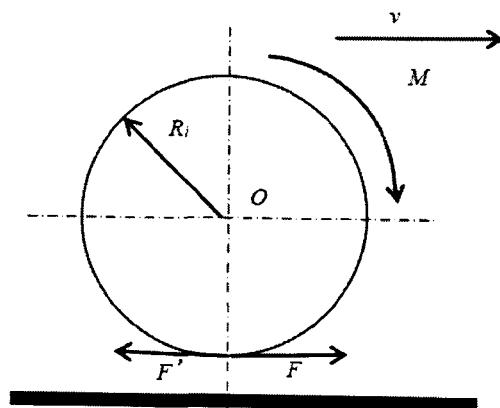


图 2-4 列车牵引力示意图

Figure 2-4 The schematic diagram of train traction

一般情况下，机车车辆确定后，列车的牵引力如式（2-1）所示

$$F_p = f_p(v) \quad (2-1)$$

由上式可知，列车牵引力的大小与当前运行速度的大小有关，图 2-5 为列车牵引特性曲线的示意图。

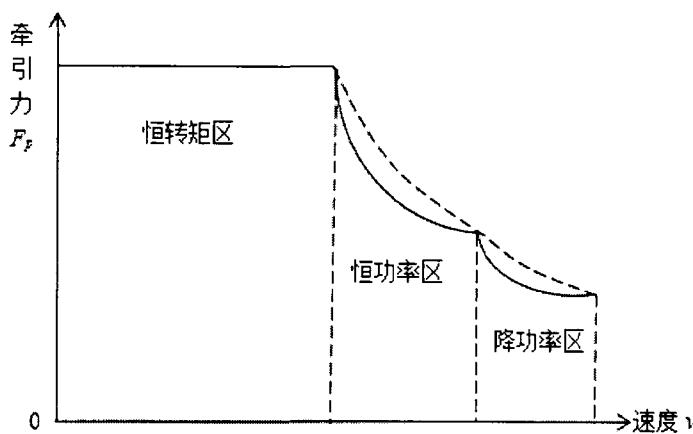


图 2-5 列车牵引特性曲线示意图

Figure 2-5 The schematic diagram of train traction characteristic curve

由图 2-5 可知，列车的牵引特性曲线分为三部分，分别是横转矩区、恒功率区和降功率区。其中，恒转矩区持续时间较长，该区间内，牵引力不变，列车运行速度呈线性增长，该区间持续到速度达到列车运行最大速度的二分之一；恒功率区持续时间较短， F_p 与 v 成反比；降功率区 F_p 与 v^2 成反比，列车运行速度将在该区间达到最大值。由于恒功率区时间较短，常常将恒功率区和降功率区的牵引特性曲线拟合为一个二次函数，有利于方便牵引力的计算。

由于列车牵引特性曲线的参数是一组离散值，而列车运行速度为连续的，因此，在求解某一速度下的牵引力时，采用线性插值法。已知 v_x 计算 F_x 的计算公式如下式（2-2）所示，其中 (v_1, F_1) 和 (v_2, F_2) 为相邻两点， (v_x, F_x) 为该相邻两点间的任一点。

$$F_x = F_1 + \frac{(v_x - v_1)(F_2 - F_1)}{(v_2 - v_1)} \quad (2-2)$$

2.2.2 列车制动力

列车制动力的产生有两种方式，分别是电制动和空气制动。电制动是利用电动机的可逆性原理，通过能量的转换，使得牵引电动机成为发电机，产生一个与列车运行方向相反的旋转力矩 M ，通过列车安装的制动装置传递给动轮，使得动轮给轨道一个力 B' ，并且动轮受到大小相等、方向相反的力 B ，即为列车制动力，列车制动力示意图如图 2-6 所示。

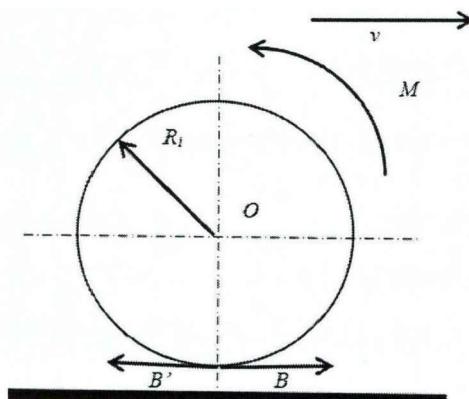


图 2-6 列车制动力示意图

Figure 2-6 The schematic diagram of train braking force

列车的电制动又由电阻制动以及再生制动两种方式组成。再生制动的制动原理为将列车运行过程中产生的动能转化成电能，进行储存，而电阻制动的制动原理为将产生的电能通过大电阻进行应用，最终以热能的形式散失。虽然再生制动是列车节能运行上的一大成果，但其实现需要满足两大条件，一是再生电压需

大于电网电压，二是再生制动产生的能量需被本列车的辅助电源或同一电网的其他列车所吸收。再生制动将产生的电能反馈给接触网，当接触网的电压值超过限定值时，剩余部分通过电阻制动的方式最终以热能的形式散失。空气制动是以压缩空气为动力，通过控制压缩空气压强的变化控制制动力的大小，由闸片对轮对产生的阻力矩产生制动力。目前城市轨道交通中使用的是电空混合制动，一般情况下，优先使用电制动，当电制动不能满足需求时，再使用空气制动，几种制动方式的优先级排序为再生制动、电阻制动、空气制动。制动力的公式如下式(2-3)，可由线性插值法求取某一速度下的制动力。

$$F_b = f_b(v) \quad (2-3)$$

2.2.3 列车运行阻力

列车运行的过程中，还受到一些外力的影响，这些外力的大小不定量，与列车运行线路、运行条件以及列车本身的车辆参数有关，以上所述的外力均为列车运行阻力。其中，根据阻力作用范围的不同，可将阻力分为总阻力和单位阻力，分别用 W 和 w 表示，单位分别为 KN 和 N/KN，其关系式如下式(2-4)所示。

$$w = \frac{W \times 1000}{(P + G) \cdot g} \quad (2-4)$$

式中 P ——机车的质量(t)；

G ——车辆的质量(t)。

根据产生原因的不同，将列车运行阻力分为基本阻力和附加阻力两种，分别用 W_0 和 W_{add} 表示，则列车运行阻力计算公式为式(2-5)。

$$W = W_0 + W_{add} \quad (2-5)$$

(1) 基本阻力

列车的基本阻力由车辆本身决定，与列车运行速度有关。基本阻力由五部分组成，以下分别对该五种力进行介绍。其中，轴承摩擦阻力是轮对滚动时，轴承的滚动体与内外圈之间发生相对运动产生的摩擦力；滚动阻力是指列车运行时，车轮滚动，碾压轨面，产生弹性波，弹性波受车轮推动向前移动，从而产生的轮轨之间的滚动摩擦力，其大小与列车运行速度有关；滑动摩擦力是指由于同一轮对的两车轮直径不同、列车的蛇形运动、轮对组装不完美以及轮踏面与轨面各接触点的直径不同等原因导致的车轮滚动时与轨道产生微小滑动，从而产生的滑动摩擦力；冲击与振动阻力指轨道不直、接头不平顺、车轮磨损等原因加剧车辆振动，从而产生的阻力；空气阻力是指列车运行过程中与空气进行相对运动，产生的摩擦力，其大小与列车运行速度、列车外形以及截面积等因素有关。列车的单

位基本阻力计算公式如下式 (2-6) :

$$w_0 = a + bv + cv^2 \quad (2-6)$$

式中 a 、 b 、 c ——均为经验常数，其取值与列车车型相关。

(2) 附加阻力

1) 坡道附加阻力

坡道附加阻力是指在有坡度的轨道线路上运行时，列车所受的重力沿斜坡的水平方向作用在列车上的一个分力。列车在上坡路段，该分力的方向与列车的运行方向相反，产生的阻力值为正，阻碍列车的运行，列车在下坡路段，该分力的方向与列车的运行方向相同，产生的阻力值为负，加速列车的运行。列车在坡道上的受力分析如图 2-7 所示：

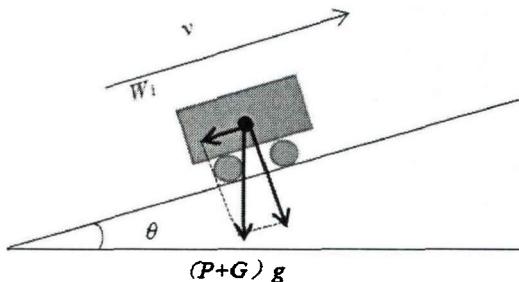


图 2-7 坡道附加阻力示意图

Figure 2-7 The schematic diagram of additional resistance of ramp

分析图 2-7，得到坡道附加阻力的表达式，如下式 (2-7) :

$$W_i = (P + G) \cdot g \cdot \sin \theta \quad (2-7)$$

则由式 (2-4) 和式 (2-7) 可得出单位坡道附加阻力的计算公式 (2-8) :

$$w_i = \frac{W_i \times 1000}{(P + G) \cdot g} = 1000 \sin \theta \quad (2-8)$$

坡度千分数的定义为在坡长 1000 米的前提下，坡度终点与起始点的高度之差，由坡度千分数的定义可知，坡度千分数的计算公式为时 (2-9) :

$$i = 1000 \sin \theta \quad (2-9)$$

根据式 (2-8) 和式 (2-9)，可得到 (2-10) :

$$w_i = i \quad (2-10)$$

由 (2-10) 所知，列车单位坡道附加阻力 w_i 在数值上与坡度千分数 i 相等。

2) 曲线附加阻力

曲线附加阻力是指列车运行于曲线轨道时，列车车轮的边缘与钢轨内侧边缘之间的摩擦力增大而产生的附加阻力，其大小受曲线轨道的曲率影响。《列车牵引计算规程》中规定了单位曲线附加阻力的计算公式为 (2-11) :

$$w_r = A / R \quad (2-11)$$

式中 A ——经验常数，取值范围为 [450,800]，通常取 $A=600$ 参与计算；

R ——曲线轨道的半径。

3) 隧道附加阻力

隧道附加阻力是指列车在隧道中运行时，由于空气流通速度加快以及列车头部空气被压缩、列车尾部空气被稀释情况加重，导致列车与空气之间的摩擦力增大，而产生的空气阻力。牵轨中对单位隧道附加阻力的计算进行了规定，其计算公式为（2-12）：

$$w_s = 0.00013L_s \quad (2-12)$$

式中 L_s ——隧道长度（m）。

总的单位附加阻力为（2-13）：

$$w_{add} = w_i + w_r + w_s \quad (2-13)$$

综上所述，单位列车运行阻力的计算公式为式（2-14）：

$$w = w_0 + w_{add} = w_0 + w_i + w_r + w_s \quad (2-14)$$

2.2.4 动力学模型

列车的运行模型有两种，一种是将一列列车分为多个部分，每部分看做一个质点，建立多质点模型，多质点模型不仅考虑列车所受外力的影响，还考虑列车内部机车和车辆之间的受力，另一种是把一列列车当做一个整体，看做一个质点，仅考虑外力作用，并将所有受力归结到一点上的单质点模型。本文应用列车单质点模型，对列车运行过程中的受力分析如图 2-8 所示：

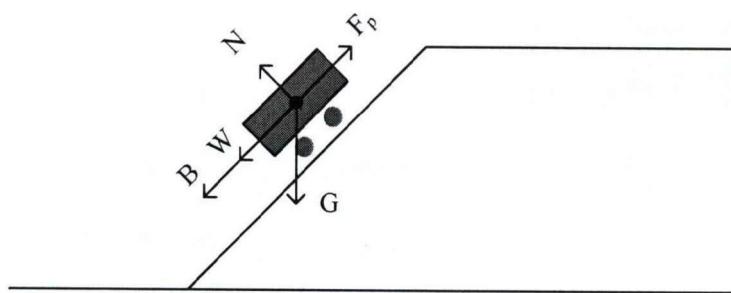


图 2-8 列车运行受力分析

Figure 2-8 The force analysis of train operation

实际运行过程中，列车不仅受到上图所示的纵向力，还会受到侧风等一些横向力，本文仅研究列车运行过程中收到的纵向力，由牛顿第二定律，根据上图受力分析可得出式（2-15）所示的列车单质点模型。

$$\begin{cases} \frac{dv}{dx} = \frac{F_p(v) - B(v) - W(v, x)}{mv} \\ \frac{dt}{dx} = \frac{1}{v} \end{cases} \quad (2-15)$$

式中 F_p ——列车牵引力 (kN)

W ——列车总阻力 (kN)

B ——列车制动力 (kN)

m ——列车总质量 (t)

根据对列车受力情况的分析, 可得出列车在线路中行驶的四种工况, 分别是牵引、巡航、惰行以及制动工况, 下面分别对四种工况进行受力分析, 总结各个工况的特点、能耗及其运行、转换状态。

(1) 牵引工况

列车运行于牵引工况时, 受牵引力 F_p 和运行阻力 W 两个相反方向的力, 合力方向与列车运行的方向相同, 加速度大于零, 速度不断增大, 所受合力为:

$$F_{total} = F_p - W \quad (2-16)$$

(2) 巡航工况

列车处于巡航工况时, 依然受到牵引力 F_p 和运行阻力 W 两个方向相反的力, 但此时 F_p 与 W 大小相等, 故列车所受合力为:

$$F_{total} = 0 \quad (2-17)$$

(3) 惰行工况

列车运行于惰行工况中时, 仅受运行阻力 W 的影响, 其方向与列车运行的方向相反, 故此工况中, 速度处于不断降低的过程, 故列车所受合力为:

$$F_{total} = -W \quad (2-18)$$

(4) 制动工况

列车处于制动工况时, 受到制动力 B 和运行阻力 W 两个方向相同且合力方向与列车运行方向相反的力, 加速度小于零, 列车速度持续降低, 所受合力为:

$$F_{total} = -B - W \quad (2-19)$$

2.2.5 列车节能运行工况及其转换原则

在实际计算时, 由于可以通过对牵引、制动特性曲线进行拟合, 得出某一速度下的最大牵引力以及最大制动力的计算公式, 故牵引力和制动力可以表示为式 (2-20)。

$$\begin{cases} F_p(v) = pF_{max}(v) \\ B(v) = bB_{max}(v) \end{cases} \quad (2-20)$$

式中 $F_{max}(v)$ ——列车最大牵引力 (kN);

$B_{max}(v)$ ——列车最大制动力 (kN);

p 、 b ——分别为列车牵引力和制动力的系数。

由于列车的牵引力和制动力的大小受最大值的制约如式 (2-21)

$$\begin{cases} 0 \leq F_p(v) \leq F_{\max}(v) \\ 0 \leq B(v) \leq B_{\max}(v) \end{cases} \quad (2-21)$$

故 p 、 b 的取值受到制约, 如式 (2-22) 所示。

$$\begin{cases} 0 \leq p \leq 1 \\ 0 \leq b \leq 1 \end{cases} \quad (2-22)$$

设列车的起始位置为 0, 终止位置为 s , 在起始和终止位置的速度均为 0, 并且列车的区间运行时间应按照运行时刻表规定的时间设置, 因此, 约束条件如式 (2-23) 所示。

$$\begin{cases} v(0) = 0 & v(s) = 0 \\ t(0) = 0 & t(s) = T_{plan} \end{cases} \quad (2-23)$$

在运行线路中的任意时刻, 为了保证列车运行安全, 对运行速度进行约束, 使其始终小于道路限速值, 如式 (2-24) 所示。

$$v(x) \leq v_{lim}(x) \quad (2-24)$$

式中 $v_{lim}(x)$ 表示在 x 处的限速值。

列车的节能优化目标如式 (2-25) 所示。

$$J = \int \frac{F_p(v)}{\eta} dx \rightarrow \min \quad (2-25)$$

式中 η —— 列车牵引系统效率, $0 < \eta < 1$ 。

本文应用极大值原理, 结合式 (2-20) 的动力学模型, 建立 Hamiltonian 函数, 对各种工况进行分析, 寻找一种使得式 (2-25) 取得最小值, 且满足式 (2-21) -

$$H = -\frac{F_p(v)}{\eta} + \frac{\theta_1(F_p(v) - B(v) - W(v, x))}{mv} + \frac{\theta_2}{v} \quad (2-26)$$

式 (2-24) 的约束条件的节能操纵策略, 建立的 Hamiltonian 函数如式 (2-25)。

式中, 伴随变量 θ_1 、 θ_2 应满足

$$\frac{d\theta_1}{dx} = -\frac{\partial H}{\partial v} \quad (2-27)$$

$$\frac{d\theta_2}{dx} = -\frac{\partial H}{\partial t} \quad (2-28)$$

由于 H 函数中不存在变量 t , 故

$$\frac{d\theta_2}{dx} = -\frac{\partial H}{\partial t} = 0 \quad (2-29)$$

因此, θ_2 恒为常数。

求解式 (2-27) 可得

$$\frac{d\theta_1}{dx} = \frac{F_p(v)}{\eta} + \frac{\theta_2}{v^2} + \frac{\theta_1(F_p(v) - B(v) - W(v, x))}{mv^2} - \frac{\theta_1(F_p(v) - B(v) - W(v, x))}{v} \quad (2-30)$$

整理式 (2-26) 可得式 (2-31)

$$H = \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) F_p(v) - \frac{\theta_1}{mv} B(v) - \frac{\theta_1}{mv} W(v, x) + \frac{\theta_2}{v} \quad (2-31)$$

根据极大值原理, 为使式 (2-25) 中的 J 取得极小值, 需要令哈密顿函数 H 在牵引力和制动力的约束下取得极大值, 因此定义式 (2-32)。

$$L = H + \alpha_p F_p(v) + \beta_p (F_{\max}(v) - F_p(v)) + \alpha_b B(v) + \beta_b (B_{\max}(v) - B(v)) \quad (2-32)$$

式中 α_p 、 β_p 、 α_b 、 β_b ——均为拉格朗日乘子, 是非负的。

根据 KKT 条件, 可得式 (2-33) 和式 (2-34)。

$$\alpha_p F_p(v) = \beta_p (F_{\max}(v) - F_p(v)) = 0 \quad (2-33)$$

根据式 (2-33) 可知, α_p 和 β_p 不能同时大于 0。

$$\alpha_b B(v) = \beta_b (B_{\max}(v) - B(v)) = 0 \quad (2-34)$$

根据式 (2-34) 可知, α_b 和 β_b 不能同时大于 0。

式 (2-32) 分别对 $F_p(v)$ 和 $B(v)$ 求偏导, 根据 KKT 条件得到式 (2-35) 和式 (2-36)。

$$\frac{\partial L}{\partial F_p(v)} = \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) + \alpha_p - \beta_p = 0 \quad (2-35)$$

$$\frac{\partial L}{\partial B(v)} = -\frac{\theta_1}{mv} + \alpha_b - \beta_b = 0 \quad (2-36)$$

令 $\lambda = \theta_1 \eta / mv$, 由式 (2-35) 和式 (2-36) 可知, λ 存在 0 和 1 两个临界点, 以下对 λ 的取值情况进行详细分析。

(1) $\lambda > 1$

由于 $0 < \eta < 1$, 是非负的, 故

$$\begin{aligned} \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) &> 0 \\ -\frac{\theta_1}{mv} &< 0 \end{aligned} \quad (2-37)$$

要使得式 (2-35) 中的等式成立, β_p 的取值应大于 0, 又由于 α_p 和 β_p 不能同时大于 0, 故 $\alpha_p = 0$, 结合式 (2-20) 及式 (2-33) 可知, 此时 $p=1$, $F_p(v) = F_{\max}(v)$ 。同理, 要使得式 (2-36) 中的等式成立, α_b 的取值应大于 0, 又由于 α_b 和 β_b 不能同时大于 0, 故 $\beta_b = 0$, 结合式 (2-20) 及式 (2-34) 可知, 此时 $b=0$, $B(v) = 0$ 。因此, 列车处于最大牵引状态。

(2) $\lambda = 1$

$$\begin{aligned} \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) &= 0 \\ -\frac{\theta_1}{mv} &< 0 \end{aligned} \quad (2-38)$$

此时, 由式 (2-35) 可得 $\alpha_p = \beta_p$, 由于 α_p 和 β_p 均为非负数, 结合式 (2-33) 可得 $\alpha_p = \beta_p = 0$, 此时 $0 \leq F_p(v) \leq F_{\max}(v)$, 要使得式 (2-36) 等式成立, α_p 大于 0, 则 $\beta_p = 0$, 结合式 (2-34) 得出 $B(v) = 0$, 因此, 列车处于部分牵引状态。

$\lambda = 1$, 即 $\theta_1 \eta / mv = 1$, 则有

$$m \frac{dv}{dx} = \eta \frac{d\theta_1}{dx} \quad (2-39)$$

结合式 (2-30)、式 (2-39) 以及 $B(v) = 0$, 可得

$$\theta_2 + v^2 W'(v, x) = 0 \quad (2-40)$$

令 $\psi(v) = v^2 W'(v, x)$, 根据列车运行阻力的计算公式易知 $\psi(v)$ 为单调递增函数, 因此, 式 (2-40) 存在唯一解, 故列车匀速运行, 处于巡航状态。

(3) $0 < \lambda < 1$

$$\begin{aligned} \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) &< 0 \\ -\frac{\theta_1}{mv} &< 0 \end{aligned} \quad (2-41)$$

此时, 根据式 (2-35) 可知 α_p 大于 0, 则 $\beta_p = 0$, 结合式 (2-33) 可得 $F_p(v) = 0$, 同理, 由式 (2-36) 可知 α_b 大于 0, 则 $\beta_b = 0$, 结合式 (2-34) 可得 $B(v) = 0$ 。因此, 列车既不受牵引力作用也不受制动力作用, 处于惰行状态。

(4) $\lambda = 0$

$$\begin{aligned} \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) &< 0 \\ -\frac{\theta_1}{mv} &= 0 \end{aligned} \quad (2-41)$$

此时, 根据式 (2-35) 可知 α_p 大于 0, 则 $\beta_p = 0$, 结合式 (2-33) 可得 $F_p(v) = 0$, 由式 (2-36) 可知 $\alpha_b = \beta_b = 0$, 结合式 (2-34) 可得 $0 \leq B(v) \leq B_{\max}(v)$ 。

由式 (2-41) 可知 $\theta_1 = 0$, 则 $d\theta_1/dx = 0$, 带入式 (2-30) 可得

$$\frac{\theta_2}{v^2} = 0 \quad (2-41)$$

由于 $\theta_2 \neq 0$, 故不存在 $\lambda = 0$ 的情况。

(5) $\lambda < 0$

$$\begin{aligned} \frac{1}{\eta} \left(\frac{\theta_1 \eta}{mv} - 1 \right) &< 0 \\ -\frac{\theta_1}{mv} &> 0 \end{aligned} \quad (2-41)$$

要使得式(2-35)中的等式成立, α_p 的取值应大于0, 又由于 α_p 和 β_p 不能同时大于0, 故 $\beta_p=0$, 结合式(2-20)及式(2-33)可知, 此时 $p=0$, $F_p(v)=0$ 。同理, 要使得式(2-36)中的等式成立, β_p 的取值应大于0, 又由于 α_p 和 β_p 不能同时大于0, 故 $\alpha_p=0$, 结合式(2-20)及式(2-34)可知, 此时 $b=1$, $B(v)=B_{max}(v)$ 。因此, 列车处于最大制动状态。

综上所述, 列车最优操纵策略包括四种工况, 分别是最大牵引、巡航、惰行以及最大制动, 最优工况及操纵变量的取值如表2-1所示。

表 2-1 列车最优操纵工况

Table 2-1 The table of train optimal operating conditions

伴随变量	工况	牵引/制动力
$\lambda > 1$	最大牵引	$F_p(v) = F_{max}(v), B(v) = 0$
$\lambda = 1$	巡航	$0 \leq F_p(v) \leq F_{max}(v), B(v) = 0$
$0 < \lambda < 1$	惰行	$F_p(v) = 0, B(v) = 0$
$\lambda < 0$	最大制动	$F_p(v) = 0, B(v) = B_{max}(v)$

列车运行操纵策略虽然由四种不同的运行工况组成, 但工况之间的转换并不是自由的, 需要受有关规则约束, 根据表2-1中伴随变量的取值情况及其连续变化的性质, 对各种工况之间的转换关系总结如表2-2所示。其中, \checkmark 表示可以转换, \times 表示不能直接进行转换, \circledcirc 表示无需进行转换。

表 2-2 列车运行工况转换原则表

Table 2-2 The table of train operation conversion principle

工况	牵引	巡航	惰行	制动
牵引	\circledcirc	\checkmark	\checkmark	\times
巡航	\checkmark	\circledcirc	\checkmark	\checkmark
惰行	\checkmark	\checkmark	\circledcirc	\checkmark
制动	\times	\checkmark	\checkmark	\circledcirc

对列车运行速度曲线的节能优化, 首先要确定的是列车的运行工况。现有的列车运行优化策略主要有三种, 分别为: 牵引-巡航-惰行-制动、牵引-巡航-制动以

及牵引-惰行-制动。当列车运行区间较长时，充分考虑列车的节能以及乘客舒适度等条件，通常选择牵引-巡航-惰行-制动的运行策略，利用巡航模式使得乘客舒适度较高，惰行时既不受牵引力影响也不受制动力影响，仅应用本身的势能，大大的减少了能耗的浪费；当应用于地铁等列车运行线路较短的情况下，通常则会选择牵引-惰行-制动的运行策略，以确保在达到列车准点率的前提下，提高列车的节能效率；而当重点追求列车运行时乘客舒适度的情况下，牵引-巡航-制动的运行策略更为适合，此时，列车在启动后制动前的中间运行过程中保持匀速运行，乘客体验更为舒适。反映以上四种工况的列车站间运行曲线如图 2-9 所示：

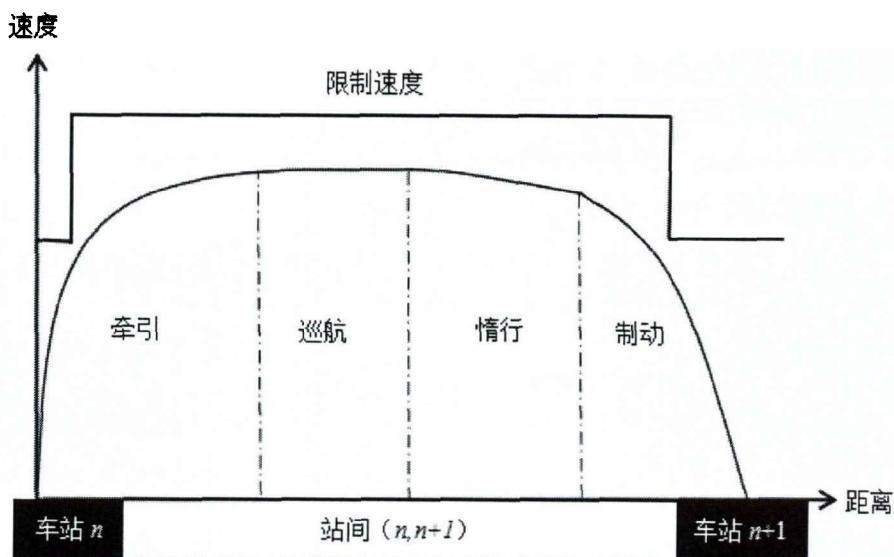


图 2-9 列车运行工况示意图

Figure 2-9 The schematic diagram of train operation conditions

2.3 其他约束指标

实际的列车节能优化是一个多目标问题，对于列车节能运行速度曲线的优化需要考虑的因素除了能耗本身之外，还有列车的准点率、乘客的舒适度、精准停车以及列车安全运行的问题，以下分别进行介绍。

2.3.1 准点率

轨道交通作为现如今我国占比最多的出行方式，其班次密、运行效率高以及准时性好等优点做出了突出贡献，且列车的准点率在安全运行中也起到重要作用。列车准点率通过列车在站间的运行时间进行评价，其评价函数为式（2-20）：

$$K_t = |T_{plan} - T| / T_{plan} \quad (2-20)$$

式中 T_{plan} ——列车自动监督系统 ATS 给出的计划站间运行时间 (s)；
 T ——列车在站间的实际运行时间 (s)。

当 $T_{plan} > T$ 时，证明列车提前到站，此时可在列车运行过程中增加列车惰行工况的运行时间，既不会影响节能效果，又能提高列车的准点率。当 $T_{plan} = T$ 时，列车准点到站。当 $T_{plan} < T$ 时，列车晚点，需适当增大列车运行过程中的速度，减少站间运行时间，达到准点的目的。 K_t 作为评价列车准点率的指标，其数值越小，表示列车的准点率越高。

2.3.2 停车精度

屏蔽门和车门是列车保障乘客安全的两道屏障，由于屏蔽门位置是固定的，因此列车的停车精度决定了屏蔽门与车门的相对位置，停车精度的评价函数为式 (2-21)：

$$K_s = |S_{stop} - S_0| \quad (2-21)$$

式中 S_{stop} ——列车实际停车点 (m)；

S_0 ——列车目标停车点 (m)。

K_s 表示停车精度，即列车到站停车后车门与屏蔽门之间的距离。列车的停车误差至少要保持在列车车门宽度与站间屏蔽门宽度之间差值的一般以内才可以，为保证乘客的正常上下车，要求停车误差在 [-30,30] 范围之内，单位为 cm，当停车误差超过 50cm 时，认为列车精准停车失败，需要由司机调整列车位置。

2.3.3 乘客舒适度

乘客舒适度主要是由列车运行过程中的加速度绝对值大小和司机驾驶列车时手柄位变换次数决定的。当列车运行加速度绝对值过大或手柄变换次数过于频繁时，乘客能够感受到列车的冲击。乘客舒适度的评价指标用冲击率 $Jerk$ ，即加速度变化率来表示，公式如式 (2-22) 所示：

$$Jerk = \int |da/dt| dt \quad (2-22)$$

$Jerk$ 的值越小，旅客舒适度越高。常用的三种舒适度评价模型为三角形模型、高斯模型和钟形模型，在实际检测舒适度时，将使用三种模型的集成。当三组模型得出的舒适度等级一致时，该等级为最终结果；当三种模型得出两种结果时，根据少数服从多数的原则，选择其中之一最为最终的舒适度等级；当三种模型的结果各不相同时，取三者的中间值最为最终的舒适度等级。国际标准 ISO2631 给出的舒适度评价标准如下表 2-2 所示。

表 2-3 乘客舒适度评价表

Table 2-3 The table of passenger comfort assessment

舒适度等级	非舒适度值	评定等级
1 级	<0.315	非常舒适
2 级	0.313-0.63	舒适
3 级	0.63-1.0	比较舒适
4 级	1.0-1.6	不舒适
5 级	1.25-2.5	非常不舒适
6 级	>2.5	极度不舒适

2.4 本章小结

本章对列车自动运行系统从外部应用到内部结构都进行了详细的分析，并对运行中列车所受的各种力及其计算方式进行了分析，得出列车运行的动力学模型，最后对于列车节能优化中需要考虑的其他指标进行介绍。2.1 节中首先对 ATO 在 ATC 系统中发挥的作用及与 ATP、ATS 的工作关系、相互作用进行介绍，其次详细介绍了 ATO 系统的内部结构及工作原理；2.2 节中，首先对列车运行过程中受到的牵引力、制动力以及运行阻力进行了详细分析并给出具体计算公式，后根据受力分析及牛顿定律得出列车运行动力学模型，并根据对不同工况的分析，对动力学模型进行进一步阐释，最后应用极大值原理根据列车的动力学模型建立哈密尔顿函数，引入拉格朗日算子进行分析，得到了列车的节能操纵策略；2.3 节对于影响列车节能运行的其他指标（准点率、停车精度、乘客舒适度）及评价方式进行详细介绍。

3 人工蜂群算法

人工蜂群算法（ABC,Artificial Bee Colony Algorithm）是一种群智能思想的优化算法，最早于 2005 年，由 Karaboga 提出，应用于解决代数的优化问题。在优化问题的解决上，人工蜂群算法最大的优点在于不对问题本身的特殊性及复杂性做过多考虑，仅对问题的优劣进行比较，类比蜜蜂采蜜时对蜜源的好坏进行评估，选择最佳的蜜源^[65-67]。通过每只蜜蜂的局部寻优及蜜蜂之间信息交流、对蜜源的判断选择，寻求到全局最优解。由于只对问题的优劣进行比较，ABC 算法在解决优化问题时具有较快的收敛速度。简单的寻优机理及快速的收敛速度使人工蜂群算法成为一种很好的优化算法。

3.1 生物学原理

人工蜂群算法是类比自然界中蜜蜂选择良好蜜源的生物行为提出的优化算法^[68]。自然界中负责采蜜的蜜蜂种类为工蜂。工蜂可以利用自身具有的生物罗盘进行定向，外出侦查、寻找蜜源。找到合适的蜜源后回到蜂巢以跳舞的方式向其他工蜂传递蜜源的信息。其中可以通过圆圈舞、镰刀舞和 8 字舞三种不同形状的舞蹈表示蜜源的位置分别在 10 米以内、10 米至 40 米之间以及 40 米之外。通过舞蹈，工蜂可以将太阳与蜜源位置的夹角以及蜂巢位置与蜜源位置的夹角进行准确的传达。并且工蜂通过舞蹈时转动的频率和腹部抖动的节奏表达出所寻得蜜源的大小、开采难易程度等信息。其他工蜂根据这些信息对蜜源进行了解、评估，组织采蜜。

人工蜂群算法中，引入蜜源、雇佣蜂、非雇佣蜂三个概念，并根据工作性质的不同，将所有参与采蜜行为的蜜蜂分为三类，分别是：采蜜蜂、观察蜂、侦察蜂。其中采蜜蜂为雇佣蜂，观察蜂和侦察蜂为非雇佣蜂。

蜜蜂采蜜行为如图 3-1 所示，A、B 为采蜜蜂发现的两个蜜源，以 A 蜜源为例，采蜜蜂发现蜜源 A 时可选择的路径有三，分别是 UF、EF1、EF2。

UF：采蜜蜂将采得的花蜜卸下后，直接放弃该蜜源，回到蜂巢中成为一只非雇佣蜂。可以选择成为观察蜂等待其他采蜜蜂带回好的蜜源信息，也可以成为侦察蜂，去随机寻找新蜜源。

EF1：采蜜蜂回到蜂房 A 将花蜜卸下，来到舞蹈区，通过舞蹈传递蜜源信息，招募更多观察蜂一同去采蜜。

EF2：采蜜蜂回到蜂房 A 卸下花蜜，不去舞蹈区传递蜜源信息，只身返回蜜源继续采蜜。

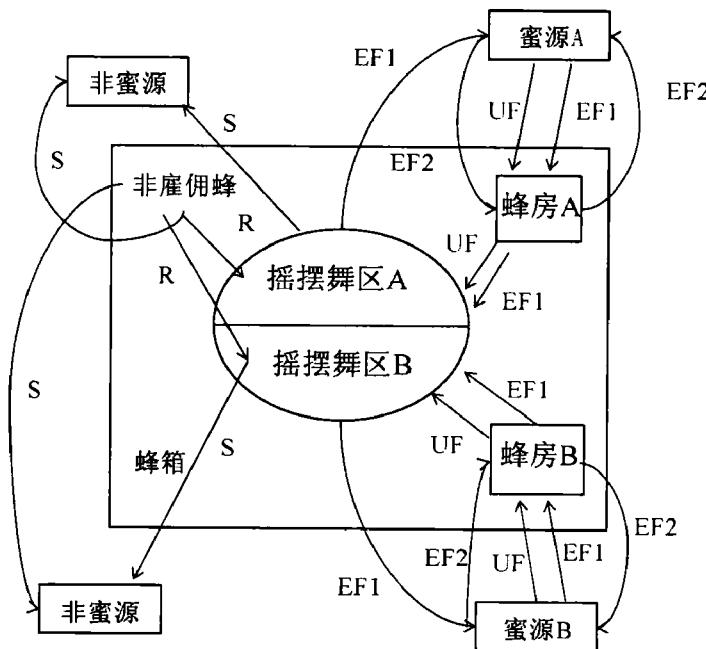


图 3-1 蜜蜂采蜜行为示意图

Figure 3-1 The schematic diagram of Bee's Honey Collection Behavior

蜂巢中的非雇佣蜂可以通过 R 路线, 到舞蹈区成为跟随蜂, 也可以通过 S 路线随机搜索新蜜源。而舞蹈区的跟随蜂也可以根据对蜜源的判断选择跟随采蜜或不跟随。三种蜜蜂的转换关系图如图 3-2 所示。

在实际生活中, 发现蜜源不回到舞蹈区传递蜜源信息的采蜜蜂为极少数, 因此, 在充分考虑有利于算法简单高效的前提下, 忽略 UF 路线, 默认每只采蜜蜂都回到舞蹈区传递蜜源信息, 招募观察蜂参与采蜜。

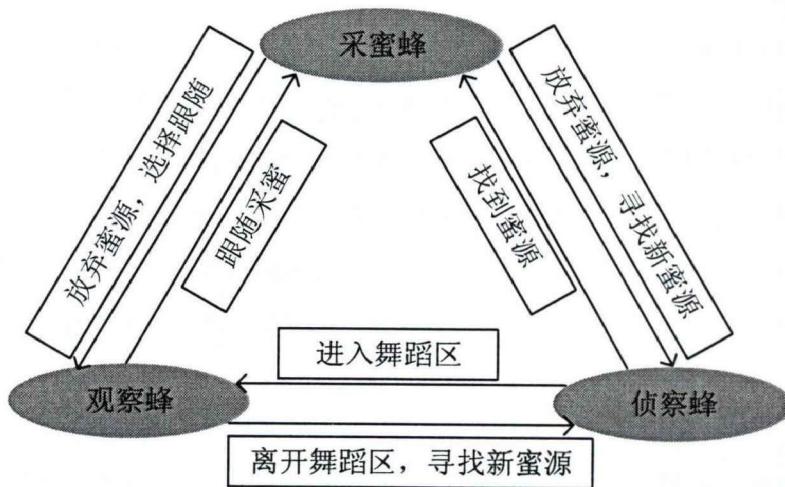


图 3-2 三种蜜蜂之间的转换关系图

Figure 3-2 The conversion diagrams among three kinds of Bees

3.2 基本模型

ABC 算法是一种典型的群智能算法^[69], 其在优化问题中寻找最优解的过程依据自然界中蜜蜂寻找最佳蜜源位置的方法得出, 以下将对人工蜂群算法中的常用术语进行介绍。

蜜源: 代表解空间内的各种可能解, 最终的最优化结果将从食物源中获得。

收益度: 是对蜜源进行优劣评价的指标, 收益度最高的解即为所求最优解。

采蜜蜂: 属于被雇佣的蜜蜂, 进行采蜜, 将蜜源信息带回蜂巢, 通过舞蹈方式向其他蜜蜂进行传达, 能够记录自己以前寻得的最佳蜜源, 并根据记忆在邻域内进行搜索。

观察蜂: 属于非雇佣蜂, 又称跟随蜂。在蜂巢中等待采蜜蜂带回的蜜源信息, 可以根据对蜜源信息的判断, 选择跟随采蜜蜂采蜜或者不跟随。

侦察蜂: 属于非雇佣蜂, 随机的在新位置搜索蜜源。

放弃蜜源算子: 蜜源资源是有限的, 为蜜源设置一个开采极限, 当超过该极限值, 采蜜蜂则放弃该蜜源, 变成侦察蜂, 随机的搜寻新蜜源。该算子能有效的避免优化问题陷入局部最优, 并且设置极限能提高收敛性能, 避免在枯竭的资源上浪费时间, 节省优化速度。

变异算子: 是指在算法初始化之初以及当采蜜蜂或观察蜂放弃一个蜜源时, 随机产生新的解的方式, 该算子的好坏影响到算法整体的搜索方向, 进而直接影响到最终优化解的质量。

选择算子: 是指当有两个解需要进行对比时的选择规则, 一般遵从择优而取的原则, 最常用的方法是轮盘赌法, 其次还有随机遍历法等其他的方法, 选择算子的好坏能够影响算法的计算速度以影响整体的优化性能。

应用 ABC 算法解决优化问题时, 将算法中蜜蜂寻找最佳蜜源的行为与优化问题中寻找最优解的过程相对应, 得出各部分的对应关系如表 3-1 所示。

表 3-1 蜜蜂采蜜行为与优化问题的对应关系表

Table 3-1 The table of relations between Bee honey collection behavior and optimization problem

蜜蜂采蜜行为	优化问题
蜜源	可行解
蜜源收益度	可行解质量(适应度函数值)
最佳蜜源	最优解

人工蜂群算法的基本模型包括初始化模型、采蜜蜂模型、观察蜂模型以及侦察蜂模型^[70,71]。

(1) 初始模型

人工蜂群算法在进行算法的初始化时，假设算法中蜜蜂总数为 N_s ，采蜜蜂数量等于观察蜂数量为 N_e 。首先随机产生 N_s 个蜜源，由式（3-1）得到第 i 个蜜源 $X_i = (x_{i1}, x_{i2}, \dots, x_{iD})$, D 为各蜜源的维度，即优化问题中控制变量的数量。

$$x_{ij} = x_{ij\min} + \varphi_{ij}(x_{ij\max} - x_{ij\min}) \quad (3-1)$$

式中 $x_{ij\max}$ 、 $x_{ij\min}$ ——分别为第 i 个蜜源第 j 维参数的上下限；

φ_{ij} ——随机数，取值范围为 $[0,1]$ 。

（2）采蜜蜂模型

在该模型中，一个采蜜蜂对应一个蜜源，采蜜蜂会在当前所处位置的附近进行随机的搜索行为，以找到一个新的解，其搜索公式为（3-2）。

$$x_{ij}' = x_{ij} + \phi_{ij}(x_{kj} - x_{ij}) \quad (3-2)$$

式中 x_{ij}' ——新产生的第 i 个蜜源 X_i 的第 j 维参数， j 的取值范围为 $\{1, 2, \dots, D\}$

ϕ_{ij} —— $[-1, 1]$ 之间的任意数；

k ——随机数，取值范围为 $\{1, 2, \dots, N_e\}$ ， $k \neq i$ 。

采蜜蜂每搜索到一个新蜜源，都会对蜜源的收益度（即计算优化问题中目标函数的适应度值）进行计算，算法中对适应度值的计算公式为（3-3）。

$$\hat{fit}_i = \begin{cases} \frac{1}{f_i + 1}, & f_i \geq 0 \\ 1 + |f_i|, & f_i < 0 \end{cases} \quad (3-3)$$

式中 f_i ——第 i 个蜜源的目标函数值。

采蜜蜂对蜜源的收益度有记忆功能，通过贪婪选择算子判断新蜜源是否能够代替旧蜜源，如公式（3-4）所示，适应度值越大，代表优化问题的目标函数值越小，此时的蜜源收益度越高，因此若新蜜源的适应度值大于旧蜜源，则代替旧蜜源，否则，放弃新蜜源。

$$X_i' = \begin{cases} X_i, & \hat{fit}_i' > \hat{fit}_i \\ X_i, & \hat{fit}_i' \leq \hat{fit}_i \end{cases} \quad (3-4)$$

（3）观察蜂模型

携带蜜源信息的采蜜蜂回到蜂巢招募蜜蜂时，观察蜂根据蜜源的适应度值大小判断是否跟随，观察蜂选择跟随的概率计算公式为（3-5）。

$$P_i = \frac{\hat{fit}_i}{\sum_{j=1}^{N_s} \hat{fit}_j} \quad (3-5)$$

跟随蜂在判断是否跟随采蜜蜂时，会随机产生一个 $[0,1]$ 之间的数，如果产生的随机数小于 P_i ，则跟随蜂成为采蜜蜂，跟随采蜜，根据式（3-5）在蜜源附近随机

搜寻新蜜源，并根据贪婪选择算子进行选择，否则，放弃跟随。

(4) 侦察蜂模型

当采蜜蜂、观察蜂在一个蜜源的搜寻次数（即蜜源未更新次数）达到预先设置的上限 $Limit$ 时，代表该蜜源陷入局部收敛，此时，采蜜蜂、观察蜂变成侦察蜂，按式（3-1）在全局范围内进行随机搜索，产生一个新蜜源用以代替旧蜜源，避免算法进入局部最优。

3.3 算法实现步骤

ABC 算法的具体实现步骤如下：

(1) 初始化阶段。对人工蜂群算法中的参数进行初始化设置，包括蜜蜂总数 N_s ，采蜜蜂数量 N_e 和观察蜂数量相同为蜜蜂总数的一半、蜜源采集的最大限度 $Limit$ 以及最大迭代次数 $maxCycle$ ，并根据式（3-1）随机产生 N_s 个蜜源。

(2) 适应度计算。分别对 N_s 个蜜源的适应度进行计算，并按从大到小的顺序进行排列。

(3) 选择采蜜蜂。将适应度排名前一半的蜜源作为采蜜蜂。

(4) 设置迭代次数 $iter=0$ ，初始化标志向量 $trial(i)=0$ ，开始循环。

(5) 采蜜蜂阶段：每只采蜜蜂在其对应的蜜源附近根据式（3-2）随机产生新蜜源，由式（3-3）计算新产生蜜源的适应度值，根据式（3-4）对蜜源进行贪婪选择，若新蜜源较优，则利用新蜜源来代替原蜜源，令 $trial(i)=0$ ，否则，保留原蜜源， $trial(i)$ 的数值加 1。

(6) 观察蜂阶段：每只观察蜂在 $[0,1]$ 之间产生一个随机数 k ，并根据式（3-5）计算观察蜂对采蜜蜂的跟随概率 P_i ，若 $P_i > k$ ，则观察蜂跟随采蜜，成为采蜜蜂，在该蜜源附近随机产生新蜜源，计算新蜜源的适应度值，并根据贪婪选择判断新蜜源是否能够代替原蜜源，若能代替，则设置 $trial(i)=0$ ，否则， $trial(i)$ 的数值加 1。

(7) 避免蜜源进入局部收敛。根据 $trial(i)$ 的值判断第 i 个蜜源是否达到最大开采极限，若 $trial(i) > Limit$ ，则进入步骤（8），否则，进入步骤（9）。

(8) 侦察蜂阶段：当第 i 个蜜源达到开采极限，此时的采蜜蜂或跟随蜂变成侦察蜂，根据式（3-1）在全局范围内随机的产生一个新解代替旧解。

(9) 记录所有蜜蜂当前寻找到的最优解，并对其适应度值、目标函数值进行记录，迭代次数 $iter$ 的次数加 1。

(10) 判断迭代次数是否达到上限。若 $iter \leq maxCycle$ ，则回到步骤（5），若 $iter > maxCycle$ ，则跳出循环，算法结束。

ABC 算法的流程图如图 3-3 所示：

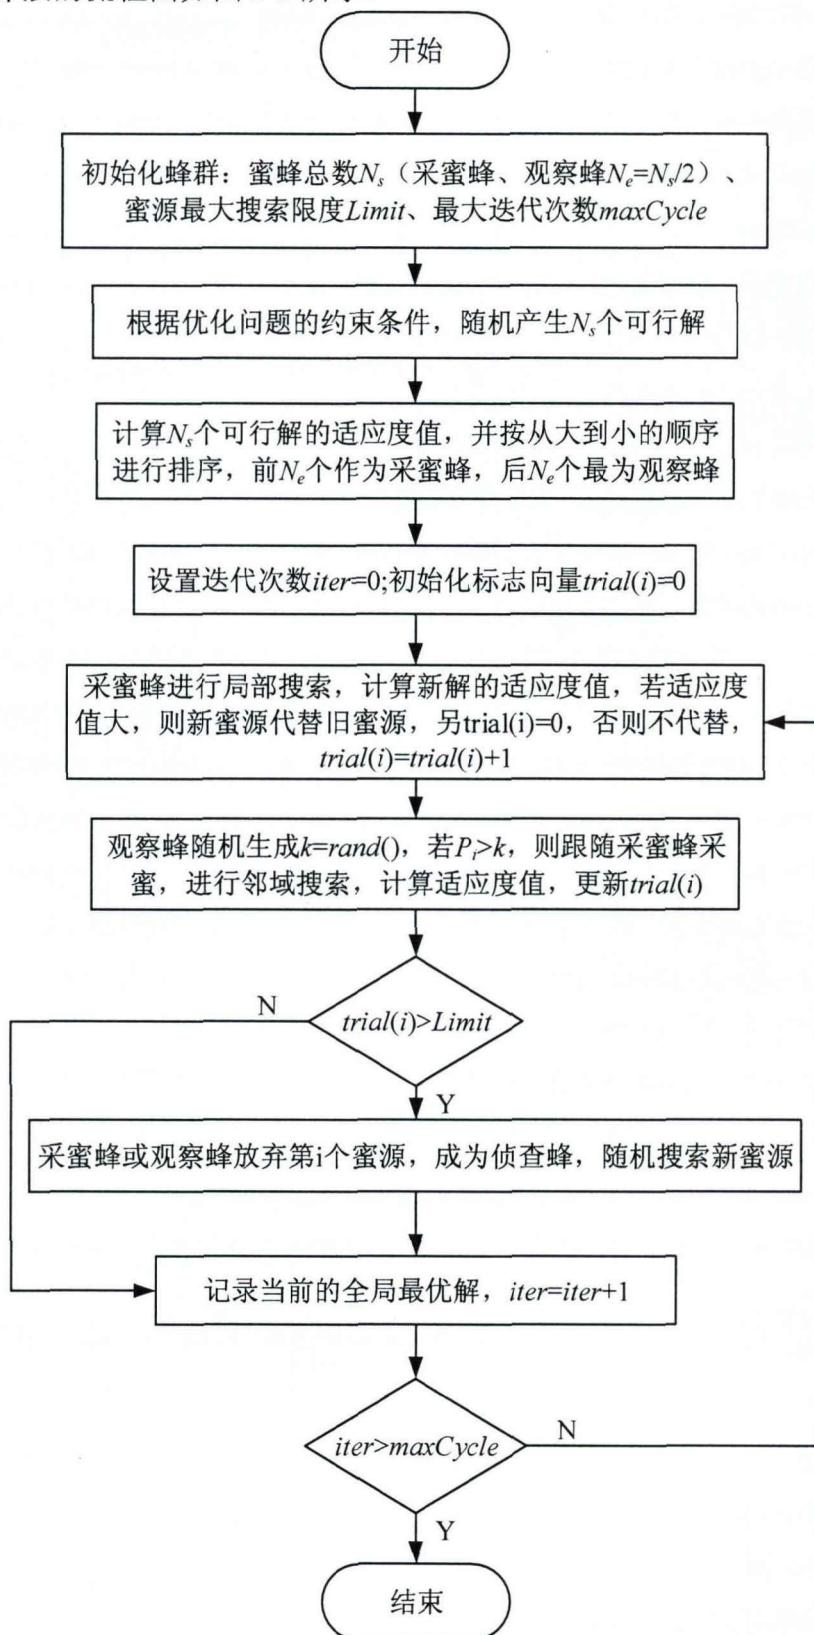


图 3-3 人工蜂群算法流程图

Figure 3-3 The flow chart of artificial bee colony algorithm

3.4 特点分析

人工蜂群算法的寻优过程包括四部分，分别是：区域选择过程、全局选择过程、贪婪选择过程和随机选择过程。

区域选择过程：应用于采蜜蜂和观察蜂。初始化后采蜜蜂进行采蜜时，在蜜源附近搜索新蜜源，进行收益度比较，确定所要开采的蜜源；观察蜂决定跟随采蜜蜂采蜜时，也会在相应采蜜蜂发现蜜源的附近进行搜索，确定要采集的蜜源。该邻域搜索行为，能将已知蜜源附近的花蜜信息进行比较，选择出该区域内最优的蜜源，进行采集，得到优化问题中的局部最优解。

全局选择过程：应用于采蜜蜂和观察蜂阶段，无论是采蜜蜂还是观察蜂，在采蜜的过程中，不仅会对蜜源收益度进行分析，判断是否采蜜，同时也会对蜜源的开采程度进行分析，当蜜源的开采程度超过最大开采程度 $Limit$ 时，放弃该蜜源，成为侦察蜂，在解空间内随机的搜索新蜜源。此行为有效的避免了蜜源的过度开采，帮助采蜜蜂和观察蜂跳出局部搜索，能有效地避免算法进入局部收敛，得到全局最优解。

贪婪选择过程：还过程应用于所有蜜蜂，以及算法的初始化阶段。在算法初始化阶段，计算随机生成的蜜源的收益度，进行排序，选取前百分之五十的蜜源做为采蜜蜂携带的蜜源。对于所有蜜蜂而言，当寻找到新蜜源，就会进行收益度计算，与原蜜源比较，再根据贪婪选择，选取收益度高的蜜源，放弃收益度低的。贪婪选择类比于自然界中“适者生存”的自然法则，对于蜜源进行优胜劣汰的选择，是找到最优解的必要过程。

随机选择过程：应用于算法初始化阶段以及侦察蜂阶段。算法初始化阶段，随机产生蜜源；侦察蜂寻找新蜜源时，也是在解空间内随机产生。通过该过程选择出的解具有随机性，受外界干扰小，误差小。

3.5 寻优性能仿真验证

本节通过对比验证的方法体现 ABC 算法的寻优性能，选取三个典型的基准测试函数、两种常用的智能算法作为对比，应用 MATLAB 平台进行仿真，根据结果做出分析。其中，三个基准函数分别为单峰值函数 Sphere Model、多峰多极值函数 Griewank 和病态函数 Generalized Rosenbrock，两种智能算法分别为粒子群算法 PSO（Particle Swarm Optimization）和差分进化算法 DE（Differential Evolution Algorithm）。根据前文所述，PSO 算法和 DE 算法均在列车推荐速度曲线的优化中得到应用，并且取得良好的节能效果，因此，选用该两种算法作为参照，进行

性能分析，并得出将 ABC 算法应用于推荐速度曲线优化的可行性。

仿真中对于三种算法的控制参数设置如下：ABC 算法中设置蜂群总数为 30，采蜜蜂和观察蜂数量各为 15，最大未更新次数 $Limit=50$ ，最大迭代次数 $maxCycle=100$ ；PSO 算法中设置种群数为 30，惯性权重为 $w=0.8$ ，学习因子 $c1=c2=1.5$ ；DE 算法中设置种群数为 30，交叉概率为 $CR=0.5$ ，变异率为 $F=0.6$ 。

分别应用三种算法对三种函数 10 维 500 代、20 维 1000 代、30 维 1000 代和 50 维 5000 代的情况进行仿真验证，每种情况下进行 30 次仿真，记录结果，进行分析，得出 30 次仿真中的最大值、最小值以及计算得到的平均值，以此消除结果的随机性可能，并且通过数据对算法的稳定性进行对比验证。

3.5.1 Sphere Model 函数

Sphere Model 函数的表达如下式（3-6）：

$$f(x_i) = \sum_{i=1}^n x_i^2 \quad (3-6)$$

其中， $-100 \leq x_i \leq 100$ 。

应用 MATLAB 画出 Sphere Model 函数的三维图形如图 3-4 所示

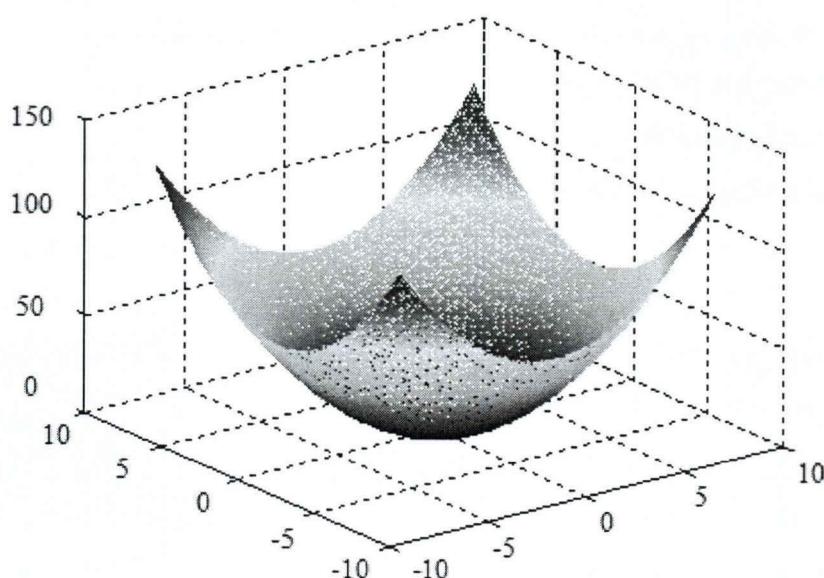


图 3-4 Sphere Model 函数图形

Figure 3-4 The figure of Sphere Model

由图 3-4 可知，Sphere Model 是一个典型的对称的单峰单极值函数，其全局最优值为当 $x=(0,0, \dots, 0)$ 时， $f(x)=0$ 。该函数由于较为简单，寻优方向较为明确，没有近似最优值的干扰，不易陷入局部收敛，容易寻得全局最优值，因此多

数算法能够成功寻优，故可以通过对 Sphere Model 函数的寻优仿真结果对算法的寻优精度及收敛速度进行对比验证。表 3-2 为三种算法分别在不同维数、不同迭代次数下对 Sphere Model 函数进行优化的仿真结果。

表 3-2 Sphere Model 仿真数据

Table 3-2 The simulation data of Sphere Model

维数	迭代次数	算法	最小值	平均值	最大值	运行时间
10	500	ABC	4.54377e-17	1.608022e-16	2.712010e-16	0.55
		PSO	5.314853e-11	5.275254e-07	6.6699e-06	0.16
		DE	3.843059e-10	2.820629e-09	9.138944e-09	0.57
	1000	ABC	2.95906e-16	4.503848e-16	7.69023e-16	1.02
		PSO	3.345004e-02	1.162113e-01	3.210181e-01	0.24
		DE	8.6785e-06	1.9532e-05	4.6327e-05	1.2
20	1000	ABC	8.37436e-12	7.40547e-11	2.97243e-10	1.03
		PSO	2.258694e-01	6.283433e-01	1.111647	0.25
		DE	0.26	0.780605	1.630700	1.2
	5000	ABC	1.19513e-15	1.678414e-15	2.54203e-15	4.9
		PSO	5.971804e-01	1.624634	2.589969	1.2
		DE	3.3487e-05	1.2213e-04	2.5438e-04	6.2

根据表 3-2 中对 Sphere Model 函数优化仿真的数据结果分析可得，无论是低维还是高维的优化，ABC 算法的寻优精度都明显优于 PSO 算法和 DE 算法。虽然三种算法从低维到高维的寻优精度均有所降低，但 ABC 算法的寻优精度波动极小，维数从 10 变化到 50 时，平均值的优化精度仅改变一个数量级，且最佳的寻优精度能达到 10^{-17} 的数量级，证明人工蜂群算法具有较高的寻优精度。

通过对表 3-2 中每仿真 30 次得到的最大值、最小值及平均值的分析得出，无论维数高低，ABC 算法优化结果中的最小值与最大值之间差距最小，故其算法稳定性最高，其次是 DE 算法，最后是 PSO 算法。

当维数为 30 时，ABC 算法和 DE 算法的优化结果与其他维数的结果具有较大差异，差距多达 6 个数量级，证明当迭代次数达到 1000 代时，ABC 算法和 DE 算

法都在收敛过程中，此时的仿真结果并非真正的全局最优解。

图 3-5 为三种算法分别对 Sphere Model 函数进行优化时的适应度变化曲线，其中 x 的取值范围为 $[-1,1]$ ，由于程序中设置适应度值的大小即为函数值大小，故适应度值曲线呈下降趋势。根据适应度变化曲线分析可知，在对单峰单极值函数 Sphere Model 进行优化时，ABC 算法的收敛速度最快，在 50 代左右算法完成收敛，而 PSO 算法和 DE 算法均在 100 代以后完成收敛。并且由图 3-5 可知，三种算法中最优解的质量最好的为 ABC 算法，其次是 DE 算法，最后是 PSO 算法，与分析表 3-2 中仿真数据精度得出的结论一致。

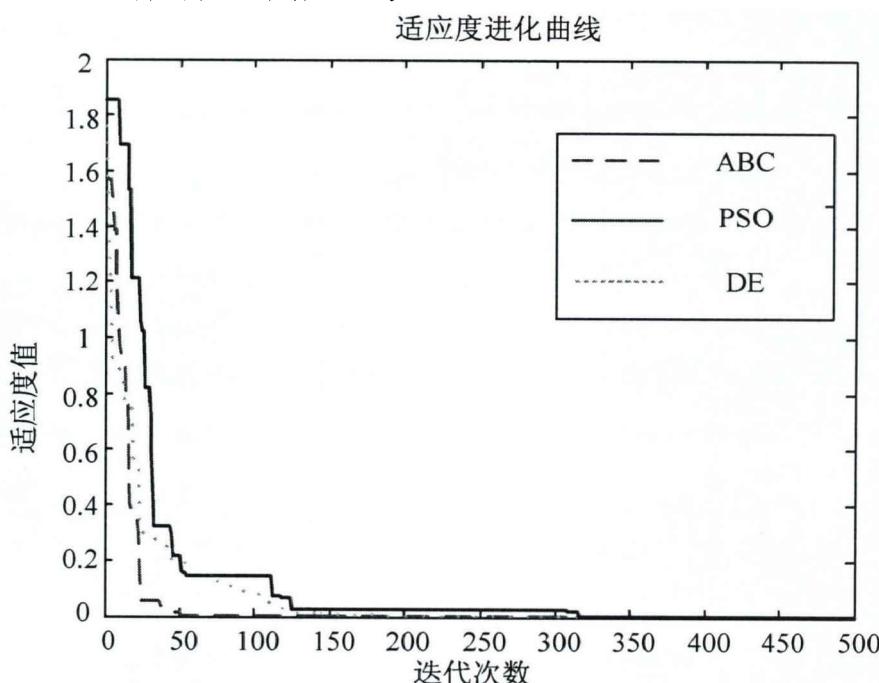


图 3-5 Sphere Model 的适应度进化曲线

Figure 3-5 The fitness evolution curve of Sphere Model

3.5.2 Griewank 函数

Griewank 函数的表达式如下式 (3-7) :

$$f(x_i) = \sum_{i=1}^N \frac{x_i^2}{4000} - \prod_{i=1}^N \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1 \quad (3-7)$$

其中， $-600 \leq x_i \leq 600$

应用 MATLAB 画出的 Griewank 函数的三维视图如图 3-6 所示，当 $x=(0,0,\dots,0)$ 时， $f(x)=0$ ，取得全局最优解。函数中由于存在余弦函数，导致函数有多处极小值存在，并且随着变量维数的增加，极小值的数量也会增加。因此 Griewank 函数是一个典型的多峰多极值函数，此类函数在优化过程中，由于极值数量多，

且由一个极值到另一个极值的变化趋势比较复杂，故当算法搜索到局部最优解时，很难跳出局部最优解继续搜索，即便跳出搜索方向也难以确定，易造成后期收敛速度慢的问题。因此，通过该函数测试算法跳出局部最优的全局寻优能力以及搜索能力具有有效性。

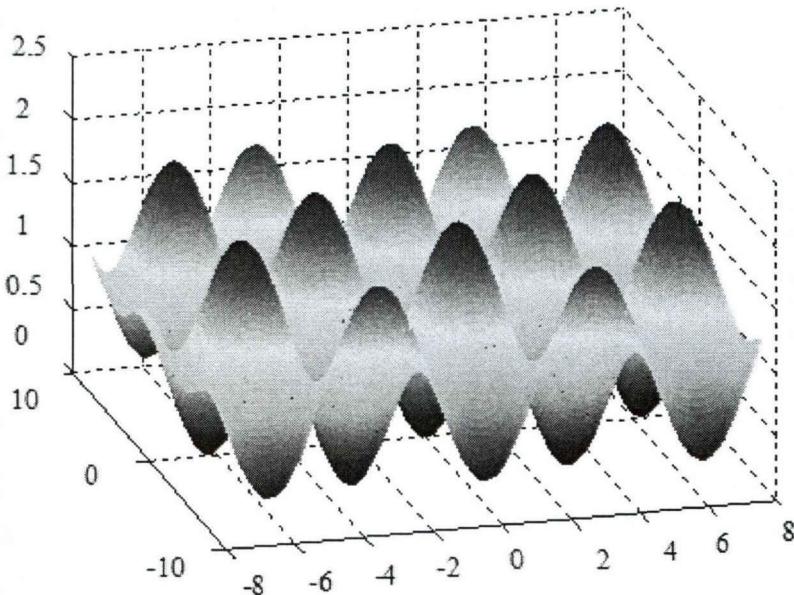


图 3-6 Griewank 函数图形

Figure 3-6 The figure of Griewank

表 3-3 为三种算法分别在不同维数、不同迭代次数下对 Griewank 函数进行优化的仿真结果。根据表 3-3 中数据结果分析可得，ABC 算法在对多峰多极值函数 Griewank 的优化上仍然具有较高的寻优精度，最佳的优化结果其精度可以达到 10^{-14} ，相较 PSO 算法和 DE 算法，寻优精度领先 14 个数量级，证明 ABC 算法在对多峰多极值函数的优化上仍具有良好的全局寻优能力，PSO 算法次之，最后是 DE 算法。

根据对表 3-3 中多次仿真得到的最大值、最小值以及平均值的分析可知，ABC 算法在对 Griewank 函数进行优化时其稳定性相比较 Sphere Model 函数的优化明显降低，最大值与最小值之间的波动范围达到 6-7 个数量级。而 DE、PSO 算法稳定性虽然相对较好，但由于后期陷入局部收敛导致寻优精度过低，得到的优化值质量较差，且维数越高，算法的稳定性越好，解的质量越差，后期越容易陷入局部收敛。

当维数为 30 时，ABC 算法的寻优结果较其他维度来比，依旧具有很大的差距，证明 1000 代不足以满足 30 维的搜索。

表 3-3 Griewank 仿真数据

Table 3-3 The simulation data of Griewank

维数	迭代次数	算法	最小值	平均值	最大值	运行时间
10	500	ABC	8.52651e-14	6.601308e-09	1.15563e-07	0.59
		PSO	2.984878	9.901619	26.86401	0.14
		DE	8.9104	12.5637	19.4230	0.67
20	1000	ABC	4.206410e-12	7.253019e-07	1.42175e-05	1.12
		PSO	21.76717	31.21556	41.85069	0.33
		DE	64.152138	79.925092	88.523961	1.3
30	1000	ABC	2.36566e-06	1.081857	2.988210	1.14
		PSO	46.02057	78.64069	100.1	0.36
		DE	163.304747	178.078737	198.275936	1.4
50	5000	ABC	1.42109e-12	4.809095e-07	9.53866e-06	5.4
		PSO	142.478	210.027275	277.6818	2.1
		DE	320.917776	342.386432	367.530562	7.7

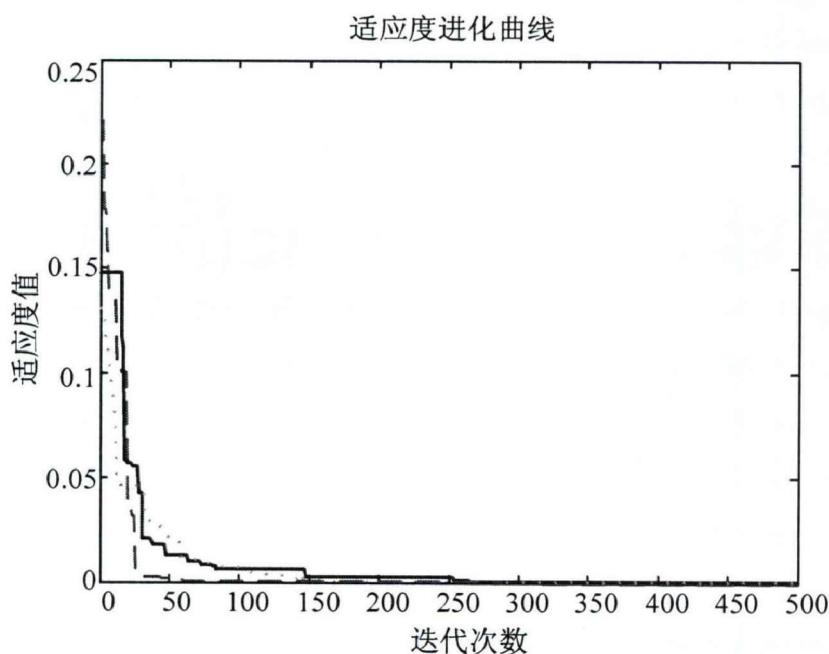


图 3-7 Griewank 的适应度进化曲线

Figure 3-7 The fitness evolution curve of Griewank

图 3-7 为三种算法分别对 Griewank 函数进行优化时的适应度变化曲线，其中 x 的取值范围为 $[-1,1]$ 。根据适应度变化曲线分析可知，在对多峰多极值函数 Griewank 进行优化时，ABC 算法的收敛速度仍然较快且最优解的质量较好，但在解决多峰多极值问题时，PSO 算法相较于 DE 算法无论是从收敛速度还是寻优精度上都有较优的性能。

3.5.3 Generalized Rosenbrock 函数

Generalized Rosenbrock 函数的表达式如下式（3-8）：

$$f(x_i) = \sum_{i=1}^{D-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2] \quad (3-8)$$

其中， $-2.048 \leq x_i \leq 2.048$ 。

由 MATLAB 画出的 Generalized Rosenbrock 函数的三维视图如图 3-8 所示，有图可知 Generalized Rosenbrock 函数是一个典型的病态函数，当 $x = (1, 1, \dots, 1)$ 时， $f(x) = 0$ 为全局最优解。此函数中在寻找到局部最优解后，函数值下降最快的方向与算法继续搜索的方向几乎处于垂直的关系，导致算法在前期的搜索方向明确，搜索速度较快，但后期搜索到局部最优解后，难以找到真正最优解的搜索方向，导致后期收敛速度变慢并且极其容易陷入局部收敛，难以跳出局部最优搜索全局最优解。因此，应用该基准测试函数可以有效地测试算法的搜索能力和跳出局部的全局寻优能力。

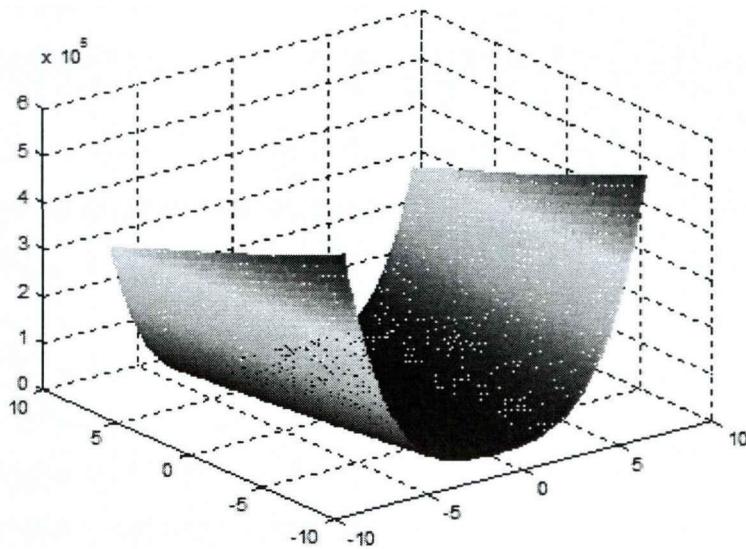


图 3-8 Generalized Rosenbrock 函数图形

Figure 3-8 The figure of Generalized Rosenbrock

表 3-4 为三种算法分别在不同维数、不同迭代次数下对病态函数 Generalized Rosenbrock 进行优化的仿真结果。从表 3-4 中的仿真数据结果分析可得，对于病态函数的优化，ABC 算法的寻优精度依然为以上三种方法之最，其次为 DE 算法，最后为 PSO 算法，并且 ABC 算法的寻优精度相较于 PSO 算法和 DE 算法高出 3-4 个数量级，证明人工蜂群算法具有良好的搜索能力和寻优能力。

根据对表 3-4 中多次仿真得到的最大值、最小值以及平均值的分析可知，对于病态函数的优化，ABC 算法仿真得到的数据中最大值与最小值之间的差距达到 3 个数量级，而 DE 算法与 PSO 算法的最大值与最小值均保持在同一数量级，说明 ABC 算法在对难以确定搜索方向的病态函数进行优化时，其稳定性降低。

当维数为 30，最大迭代次数为 1000 时，ABC 算法和 DE 算法的优化结果与其他维度的结果相比仍存在差异，但差异相对较小，证明在对病态函数进行优化时，由于搜索方向难以确定，导致算法的寻优精度有所降低，因此迭代次数对寻优结果的影响相对搜索方向明确的函数较小。

表 3-4 Generalized Rosenbrock 仿真数据

Table3-4 The simulation data of Generalized Rosenbrock

维数	迭代次数	算法	最小值	平均值	最大值	运行时间
10	500	ABC	0.422906	7.207312	30.146300	0.62
		PSO	3.245814	7.050904	9.6056	0.15
		DE	5.75560	6.291295	8.1423	0.5
	1000	ABC	0.020694	6.914436	27.0363	1.17
		PSO	20.69552	34.478726	68.70037	0.28
		DE	17.1837	18.689495	21.2985	1.17
	30	ABC	0.688423	14.854828	79.8744	1.22
		PSO	53.03534	93.782882	144.9783	0.3
		DE	317.489	584.8079	1109.5	1.2
50	1000	ABC	0.041276	4.335075	18.584	5.8
		PSO	107.9972	215.99277	347.0616	1.8
	5000	DE	52.0646	64.67664	88.6307	6.7

图 3-9 为三种算法分别对 Generalized Rosenbrock 函数进行优化时的适应度变化曲线，其中 x 的取值范围为 [-1,1]。根据适应度变化曲线分析可知，在对病态函

数 Generalized Rosenbrock 进行优化时，ABC 算法的收敛速度与 PSO 算法相近，均在 50 代左右趋于稳定，而 DE 算法在 200 代左右趋于稳定，明显收敛速度低于 ABC 算法与 PSO 算法，证明 ABC 算法和 PSO 算法都具有较强的搜索能力。由 PSO 算法的适应度进化曲线可知，在迭代次数达到 320 代左右，算法跳出局部收敛，找到质量更好的解，但最终的优化值与 ABC 算法的优化值相比质量仍然较差。

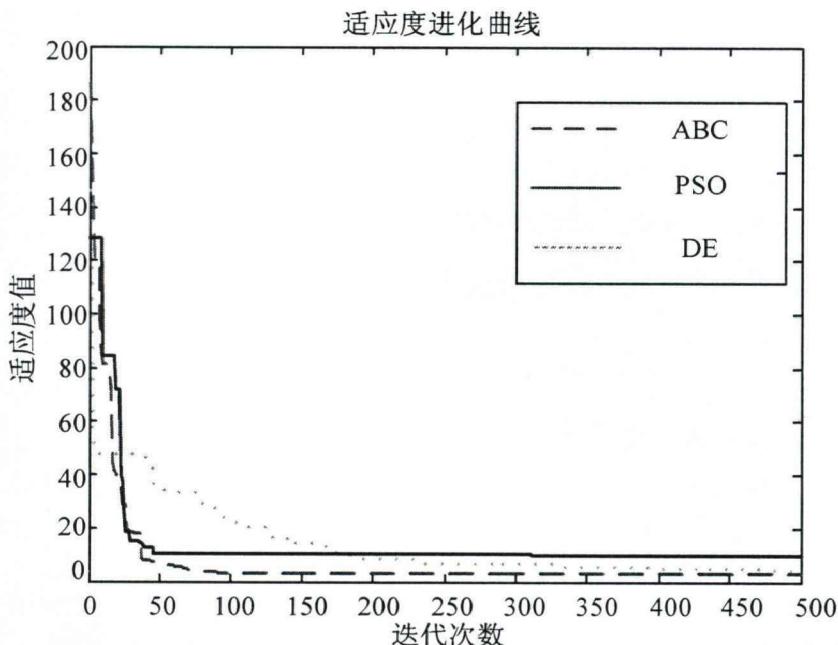


图 3-9 Generalized Rosenbrock 的适应度进化曲线

Figure 3-9 The fitness evolution curve of Generalized Rosenbrock

3.5.4 维数、迭代次数对算法的影响

图 3-10~3-12 分别为 ABC 算法、PSO 算法和 DE 算法对 Sphere Model 函数从低维到高维的适应度函数比较，其中， x 的取值范围为 $[-100,100]$ 。

通过图 3-10~图 3-12 可知，无论优化函数为低维还是高维，ABC 算法均有较快的收敛速度，对一个函数从 10 维到 50 维的优化均能在 500 代之前完成收敛，收敛速度从低维到高维均为三种算法之最。DE 算法与 PSO 算法的收敛速度相对较慢，均在迭代次数过半后呈现平稳趋势，但在高维寻优时，PSO 算法相较 DE 算法有更强的搜索能力和更快的收敛速度。

根据表 3-2~3-4 中数据的分析可知，当维数为 30，最大迭代次数为 1000 时，ABC 算法的寻优精度较低，且稳定性差，为验证最大迭代次数及维数对 ABC 算法的寻优能力的影响，以 Sphere Model 函数的寻优仿真为例进行分析，仿真数据如表 3-5 所示。

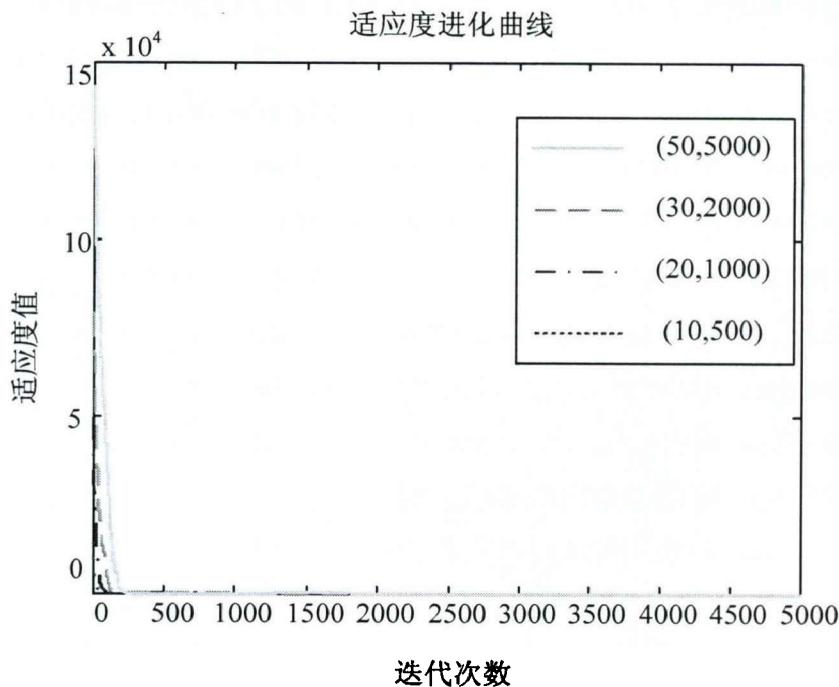


图 3-10 ABC 算法优化的适应度进化曲线

Figure 3-10 The fitness curve optimized by Artificial Bee Colony algorithm

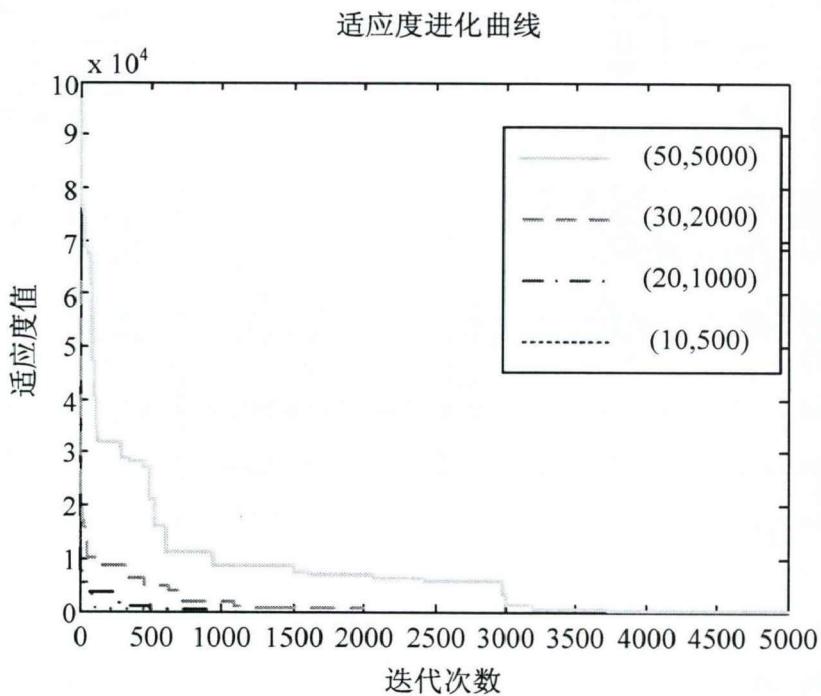


图 3-11 PSO 算法优化的适应度进化曲线

Figure 3-11 The fitness curve optimized by Particle Swarm Optimization

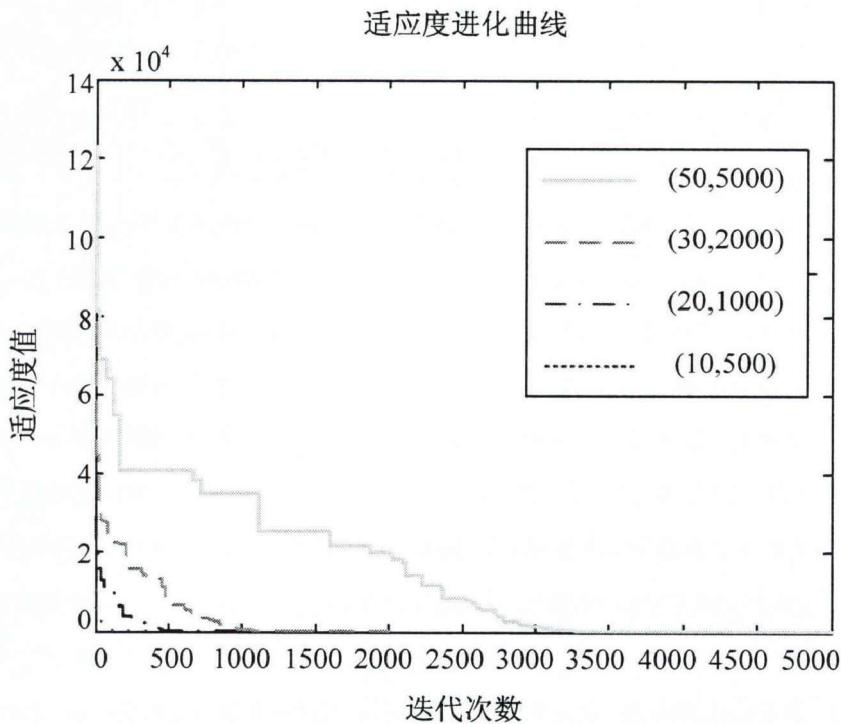


图 3-12 DE 算法优化的适应度进化曲线

Figure 3-12 The fitness curve optimized by Differential Evolution Algorithms

表 3-5 不同迭代次数下 Sphere Model 的仿真数据

Table 3-5 The simulation data of Sphere Model under different iteration numbers

维数	迭代次数	最小值	平均值	最大值
10	500	4.54377e-17	1.608022e-16	2.712010e-16
20	1000	2.95906e-16	4.503848e-16	7.69023e-16
30	1000	8.37436e-12	7.40547e-11	2.97243e-10
30	3000	6.551810e-16	8.063285e-16	1.08883e-15
50	5000	1.19513e-15	1.678414e-15	2.54203e-15

根据表 3-5 数据进行分析可知，当维数设置为 30 时，若最大迭代次数设置为 1000，则最终 20 次仿真后最优值的平均值精度为 10^{-11} ，且最大值与最小值之间具有 3 个数量级的误差，证明优化结果不稳定；若最大迭代次数设置为 3000，则 20 次仿真后最优值的平均值精度为 10^{-16} ，最大值、最小值之间的误差较小，且与其他维数的寻优精度相近。因此，ABC 算法的寻优性能受维数及最大迭代误差影响较大，应用 ABC 算法寻优应根据不同维数设定不同的最大迭代次数，当控制参数

设置合理时，人工蜂群算法能保持高精度且稳定的寻优能力。

3.6 本章小结

本章从生物学原理、模型分析、实现步骤等方面对人工蜂群算法进行了详细介绍，并通过与粒子群算法、差分进化算法的仿真结果对比，得出人工蜂群算法在解决优化问题中的优势及特点。3.1 节中介绍了 ABC 算法的生物学原理，并将优化问题与蜜蜂采蜜行为进行一一对应，建立起联系；3.2 节中对于 ABC 算法中的基本模型（初始化模型、采蜜蜂模型、观察蜂模型、侦察蜂模型）做了详细介绍，并给出计算公式；3.3 节中介绍了 ABC 算法的具体实现步骤，并以程序流程图的形式进行呈现；3.4 节通过四个选择过程对 ABC 算法的特点进行分析；3.5 节中选取已经在推荐速度曲线优化问题中取得良好成果的 PSO 算法和 DE 算法为对照，分别对单峰单极值函数 Sphere Model、多峰多极值函数 Griewank 以及病态函数 Generalized Rosenbrock 三个典型的基准函数进行优化，并设置不同的维数和最大迭代次数以对比算法在高低维度下寻优性能的差别，每组参数下进行 30 次仿真，取其最大值、最小值、平均值进行分析，共计 1110 次仿真结果汇总成为 4 个表以及 9 张适应度进化曲线图，根据对仿真结果的分析，得出 ABC 算法收敛速度快、寻优精度高、搜索能力强的结论，并通过相同维数不同迭代次数的仿真对比并验证了 ABC 算法的寻优精度受迭代次数影响的结论，通过不同维度的优化精度对比得出 ABC 算法从低维到高维寻优能力稳定的结论。证明选取 ABC 算法优化列车推荐速度曲线的合理性和可行性。

4 基于人工蜂群算法的推荐速度曲线优化

列车在两站之间的自动运行需要依靠自动控制系统(ATC)中各子系统的协调配合来完成,其中列车自动防护系统(ATP)进行超速防护,列车自动监督系统(ATS)监督列车运行、调整运行计划,而两站间的自动运行主要依靠列车自动驾驶系统(ATO)对列车运行时的速度进行调控。ATO系统在对速度进行调控时,首先会根据道路、车辆等信息应用算法计算出合理的推荐速度曲线,再以该速度曲线为基础,根据合理的运行策略控制列车的牵引、制动等行为,进行列车在站间的追踪运行。由于不同运行工况下,列车的受力不同,所需能量不同,因此不同的工况组合对于列车运行能耗产生了影响,体现出操纵策略的重要性。

4.1 问题与假设

对于列车自动运行过程的优化,需要考虑的因素有很多。安全性,即列车必须在限速范围内运行,不能触及紧急制动触发速度,并最终能够在安全距离内进行精准停车;准时性,即对列车在两站之间的运行时间进行把控,使列车实际到站时间与要求时间之间的误差降到最小,达到准时的效果;节能,即列车在站间以一定的控制策略跟踪ATO系统给出的推荐速度曲线运行,得到实际运行的跟踪速度曲线,能够降低运行能耗,达到节能的效果。对于列车运行节能优化的研究,安全性和准时性是必要的考虑因素,且三者之间的优化方向存在矛盾,难以找到能使得三项指标同时最优的解,因此,对列车运行过程中的节能优化是一种典型的多目标优化问题。

城轨列车在两站之间进行自动运行时,ATO系统会根据线路、限速、车辆等因素应用合理的算法得出推荐速度曲线,之后再以该速度曲线为基础,按照一定的控制策略,控制列车的速度,完成对推荐曲线的跟踪,得到跟踪速度曲线。由此得到的跟踪速度曲线即为列车实际运行的速度曲线,对于列车运行过程中的节能优化即为对该跟踪速度曲线进行优化,已知在控制策略完全一致的条件下,每条推荐速度曲线根据控制策略所得到的跟踪速度曲线是固定的,由此可以得出,对于列车跟踪速度曲线的优化可以转化为对推荐速度曲线的优化来进行研究。

基于以上分析,可以将对于推荐速度曲线的节能优化问题转化为在速度-距离二维空间内寻找有限速约束的能耗最小、时间误差最小的多目标路径寻优问题,如图4-1所示。

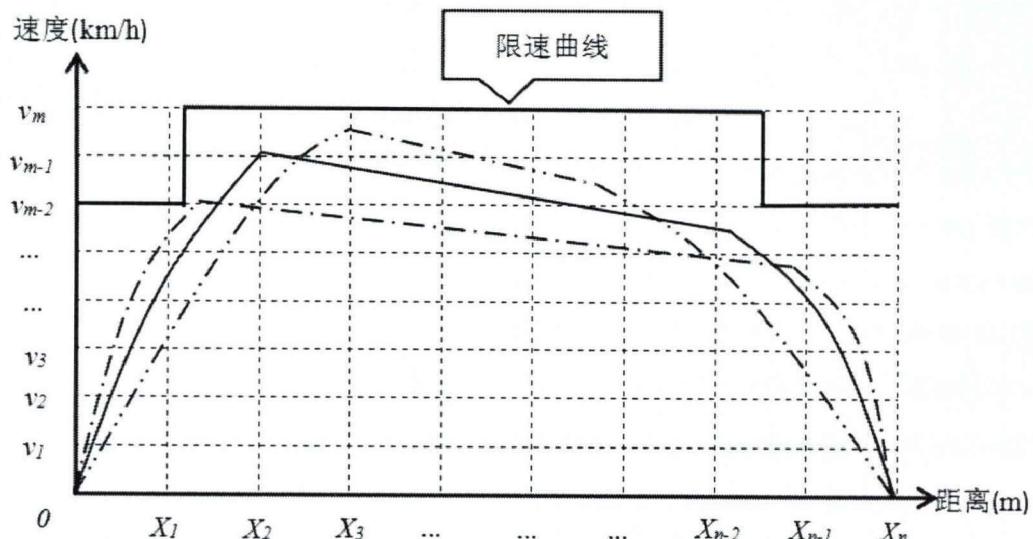


图 4-1 列车推荐速度曲线优化示意图

Figure 4-1 The schematic diagram for optimizing the train recommended speed curve

对于节能优化模型，在建立之前，我们做以下假设：

- (1) 列车在站间运行时，对于进路和移动授权的办理已经完成。
- (2) 模型中的道路信息、车辆信息、列车牵引、制动特性、计算公式均为已知条件。
- (3) 列车在站间运行时仅与自身道路、车辆有关，不受任何其它车辆影响。
- (4) 列车车载辅助设备的用电功率不变，是恒定的。

4.2 多目标优化问题

4.2.1 多目标优化问题的数学模型

多目标优化问题是需要同时优化的目标在两个以上（包含两个）时的优化问题，现实生活中，这一类的优化问题占多数。而在同时拥有多个需要优化的目标时，需要优化的多个目标往往存在不同的优化方向，即一个目标有变好的趋势时，往往会有另一个目标有变差的趋势，因此，想要找到同时满足多个目标达到最优的理想解是无法实现的。故而对于此类优化问题的最优解，只能是对多个目标函数进行权衡，得到的尽量使所有目标函数达到最优的解。因此，严格意义上来说，多目标优化问题得不到最优解，只能得到不坏的解，我们称之为非劣解。由于目标函数多、决策标量多，因而得到的非劣解不是单一的，而是一个集合，其中所有的解都是能够作为最优解来使用的，我们称这些非劣解为 Pareto 最优解，非劣解集为 Pareto 最优解集。

多目标优化问题的数学模型包括三个部分，分别是决策变量、目标函数和约束条件，三者都是不可或缺的要素，下面分别进行介绍。

决策变量，即为函数中的控制变量，根据其维数的不同可以将决策变量看做n维空间中的一个点，即：

$$x = (x_1, x_2, x_3, \dots, x_{n-1}, x_n) \in \Omega \quad (4-1)$$

其中， Ω 为可行域。

目标函数为待优化的函数，也就是待求极值的函数，其自变量为决策变量，因变量为需要优化的目标因素，其极值点为多目标优化问题的帕累托最优解。假设需要优化的目标有 m 个，则该数学模型中的目标函数为：

$$f(x) = [f_1(x), f_2(x), \dots, f_{m-1}(x), f_m(x)] \quad (4-2)$$

约束条件，即对决策变量的约束，其可以是等式约束，如：

$$g_i(x) = 0, i = 1, 2, 3, \dots, k \quad (4-3)$$

也可以为不等式约束，如：

$$h_j(x) \leq 0, j = 1, 2, 3, \dots, l \quad (4-4)$$

或

$$h_j(x) \geq 0, j = 1, 2, 3, \dots, l \quad (4-5)$$

假如需要优化的所有目标函数均需求最小值，那么该多目标优化函数的数学模型可以表示为式 (4-6)：

$$\begin{aligned} \min f(x) &= [f_1(x), f_2(x), \dots, f_{m-1}(x), f_m(x)] \\ \text{s.t.} &\begin{cases} g_i(x) = 0, i = 1, 2, \dots, k \\ h_j(x) \leq 0, j = 1, 2, \dots, l \\ x_k^{\alpha} \leq x_k \leq x_k^{\beta}, k = 1, 2, \dots, n \end{cases} \end{aligned} \quad (4-6)$$

若需要优化的所有目标函数均需求最大值，那么该多目标优化函数的数学模型可以表示为式 (4-7)：

$$\begin{aligned} \min f(x) &= [-f_1(x), -f_2(x), \dots, -f_{m-1}(x), -f_m(x)] \\ \text{s.t.} &\begin{cases} g_i(x) = 0, i = 1, 2, \dots, k \\ h_j(x) \leq 0, j = 1, 2, \dots, l \\ x_k^{\alpha} \leq x_k \leq x_k^{\beta}, k = 1, 2, \dots, n \end{cases} \end{aligned} \quad (4-7)$$

若需要优化的所有目标函数有一部分需要求最小值，另一部分需要求最大值，那么该多目标优化函数的数学模型可以表示为式 (4-8)：

$$\begin{aligned} \min f(x) &= [-f_1(x), -f_2(x), \dots, -f_s(x), f_{s+1}(x), \dots, f_m(x)] \\ \text{s.t.} &\begin{cases} g_i(x) = 0, i = 1, 2, \dots, k \\ h_j(x) \leq 0, j = 1, 2, \dots, l \\ x_k^{\alpha} \leq x_k \leq x_k^{\beta}, k = 1, 2, \dots, n \end{cases} \end{aligned} \quad (4-8)$$

其中前 s 个目标函数需要求最大值，后 $p-s$ 个目标函数需要求最小值。

以下对多目标优化函数中常用到的两个概念分别进行介绍：

(1) 可行解

满足约束条件的决策变量，即为目标函数的可行解，所有可行解的集合为可行解集，由以上可行解定义可知，可行解集 X_f 可以表示为：

$$X_f = \{x \in \Omega \mid g_i(x) = 0, h_j(x) \leq 0\} \quad (4-9)$$

(2) Pareto 支配

给出两个不同的决策变量 x_1 和 x_2 ，若 x_1 、 x_2 对应的函数满足条件：

$$\begin{aligned} f_i(x_1) &\leq f_i(x_2), \forall i = 1, 2, \dots, n \\ f_i(x_1) &< f_i(x_2), \exists i = 1, 2, \dots, n \end{aligned} \quad (4-10)$$

则称 x_1 Pareto 支配 x_2 ，表示为 $x_1 \succ x_2$ ，即解 x_1 优于解 x_2 。

(3) Pareto 最优

如果一个决策变量 x^* 满足：

$$\neg \exists x : x \succ x^* \quad (4-11)$$

那么 x^* 为 Pareto 最优解，所有满足该条件的决策变量的集合为 Pareto 最优解集。

(4) Pareto 前端

将 Pareto 最优解集中所有的解带到目标函数中，得到的目标函数值的集合即为 Pareto 前端。

如图 4-2 所示， $x_1, x_2, x_3, x_4, x_5, x_6, x_7$ 为满足约束条件的 7 个决策变量，即为目标函数 $f_1(x)$ 和 $f_2(x)$ 的可行解。其中， $f_1(x_2) < f_1(x_6)$ 且 $f_2(x_2) < f_2(x_6)$ ，则 x_2 支配 x_6 ，记为 $x_2 \succ x_6$ 。同理，因为 $f_1(x_3) < f_1(x_7)$ 且 $f_2(x_3) < f_2(x_7)$ ，所以 x_3 支配 x_7 ，记为 $x_3 \succ x_7$ 。因此， x_6, x_7 仅为函数的可行解，而非 Pareto 最优解。由于 x_1, x_2, x_3, x_4, x_5 在进行两两比较时，若其目标函数 1 占优势则目标函数 2 相对占劣势，故此 5 个解是无差别的，均为非劣解，即 Pareto 最优解。由 x_1, x_2, x_3, x_4, x_5 带到目标函数中，所得值的集合为 Pareto 前端。

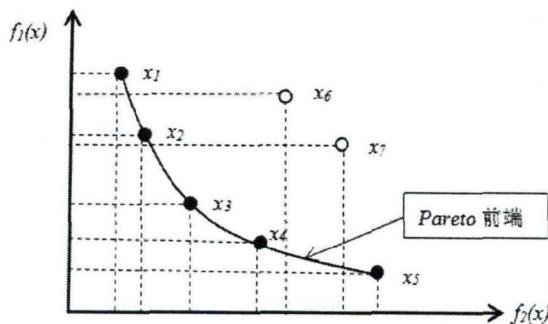


图 4-2 Pareto 前端示意图

Figure 4-2 The schematic diagram of Pareto front

4.2.2 多目标优化问题的解决方法

多目标优化问题的解决方法可以简单概括为两大类，一类是将多目标转化为单目标的化繁为简的思路，另一类是直接应用智能算法解决的思路。将多目标转化为单目标最常用的方法为权重系数法，即为每一个目标函数 $f_i(x)$ 附一个权重值 w_i ，组成一个新的目标函数，则转化后的数学模型可表示为式（4-12）。权重系数法虽然能够把多目标优化化繁为简，使求解过程得到简化，但由于各优化问题的优化目标、评价指标各不相同，对权重系数的赋值没有统一标准，因此，该方法主观操纵性太强。

$$\begin{aligned} \min f(x) &= w_1 f_1(x) + w_2 f_2(x) + \dots + w_{m-1} f_{m-1}(x) + w_m f_m(x) \\ s.t. &\left\{ \begin{array}{l} g_i(x) = 0, i = 1, 2, \dots, k \\ h_j(x) \leq 0, j = 1, 2, \dots, l \\ x_k^{\alpha} \leq x_k \leq x_k^{\beta}, k = 1, 2, \dots, n \end{array} \right. \end{aligned} \quad (4-12)$$

其中， $w_i > 0$ ，且 $\sum_{i=1}^m w_i = 1$ 。

多目标优化转化为单目标优化的另一个方法是保留众多目标函数中的一个，其他目标函数根据理想值的大小变成约束条件，约束决策变量的取值范围，使得到的可行解的值朝着目标函数的方向发展，转化后的数学模型表达式为式（4-13）。

$$\begin{aligned} \min f_h(x) \\ s.t. &\left\{ \begin{array}{l} f_u(x) \leq \delta_u, u = 1, 2, \dots, m (u \neq h) \\ g_i(x) = 0, i = 1, 2, \dots, k \\ h_j(x) \leq 0, j = 1, 2, \dots, l \\ x_k^{\alpha} \leq x_k \leq x_k^{\beta}, k = 1, 2, \dots, n \end{array} \right. \end{aligned} \quad (4-13)$$

目前，应用最多的求解多目标优化的方法为智能优化算法。遗传算法、群智能算法、神经网络等都在解决多目标优化问题中做出重要贡献。群智能算法中，蚁群算法和粒子群算法在很多领域内解决多目标优化问题中均有所成就，根据第三章使用基准测试函数进行 MATLAB 仿真对比的结果可以看出，人工蜂群算法在优化精度等方面都更有优势，因此，本文选择应用人工蜂群算法解决列车运行推荐速度曲线节能优化这一多目标优化问题。

4.3 列车节能优化设计策略

4.3.1 列车运行操纵策略

列车运行过程中应用不同的运行工况列车受力不同，导致能耗不同，因此，设计合理的工况组合能够减少不必要的能量损失，达到节能的效果。因此，对于推荐速度曲线的优化，首先要确定的是列车运行操纵策略。根据第二章对多种工况的受力、能耗情况分析，考虑城市轨道交通两站间距离较短，采用最大牵引-惰行-最大制动的操纵策略。在列车运行的启动阶段，在道路限速的约束下，采用最大牵引做加速运动；列车中间运行过程中，由于需要考虑准时性，站间运行时间不能过长，故无法做到全程惰行，采用牵引-惰行的工况组合，跟踪推荐速度曲线运行；列车的停车阶段，采用最大制动做减速运动，直到列车停车，速度为零。

对推荐速度曲线优化时将列车看做一个质点进行分析计算，优化过程中，设置列车的最大最小加速度分别为 1 和 -1，单位为 m/s²。

4.3.2 坡度等效策略

对于计算过程中应用到的坡度值，在以往的研究中，大多会将列车当作一个质点来看待，将其在运行过程中某一位置的坡度值，作为列车实际的坡度值来处理。但由于实际的列车是由多节车厢组成，且具有一定的不可忽略的长度，故将线路中某一点的坡度值作为列车实际坡度值进行计算会产生较大的误差，对优化过程产生不利的影响。因此，虽然本文在构建模型、分析受力时将列车看做一个质点，但为了减小计算误差，应用一种考虑列车长度影响的等效坡度策略，来计算列车在某一点的等效坡度。

等效坡度策略的具体计算方法为，将一列长度为 l 的列车，等距离离散成为多个点，则每个点相对应的坡度值或许相同或许不同，对所有点的坡度值进行求和，再取平均值，得到的平均坡度值即为所求的等效坡度值，公式如式（4-14）所示。

$$G(s) = \begin{cases} \frac{\sum_{i=1}^s g_i}{s}, & s < l \\ \frac{\sum_{i=s-l+1}^s g_i}{l}, & s \geq l \end{cases} \quad (4-14)$$

式中 l ——列车的长度（m）；

s ——列车在运行过程中的位置（m）；

g_i ——列车上第 i 个离散点处对应的坡度值。

4.3.3 变量离散化

本文采用的人工蜂群算法对离散数据进行组合优化，取得最终优化结果的方法，因此，在模型设计中，要对连续的数据进行离散化处理。数据离散化最常用的方法即为等分法，由于两站之间里程已知、限速信息已知，可以迅速得到等分后的离散化变量，如图 4-3 所示。

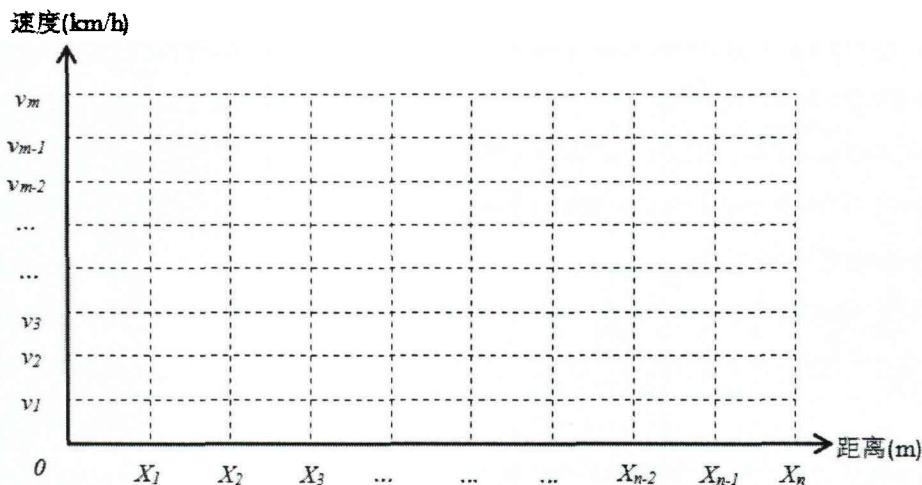


图 4-3 线路等分分区示意图

Figure 4-3 The schematic diagram of equal division of lines

在对列车推荐速度曲线的优化过程中，由第二章对列车受力的分析可知，列车运行过程中的受力情况和能耗情况均与线路坡度有关，并且列车在实际运行时，速度要严格受限速标准的把控，故限速和坡度大小对于离散数据的组合优化起到重要作用，合理分区能够简化算法的计算过程，达到加快收敛速度的作用。因此，本文对连续数据的离散化处理将以限速曲线和坡度曲线为依据，进行不等分处理，如图 4-4 所示。

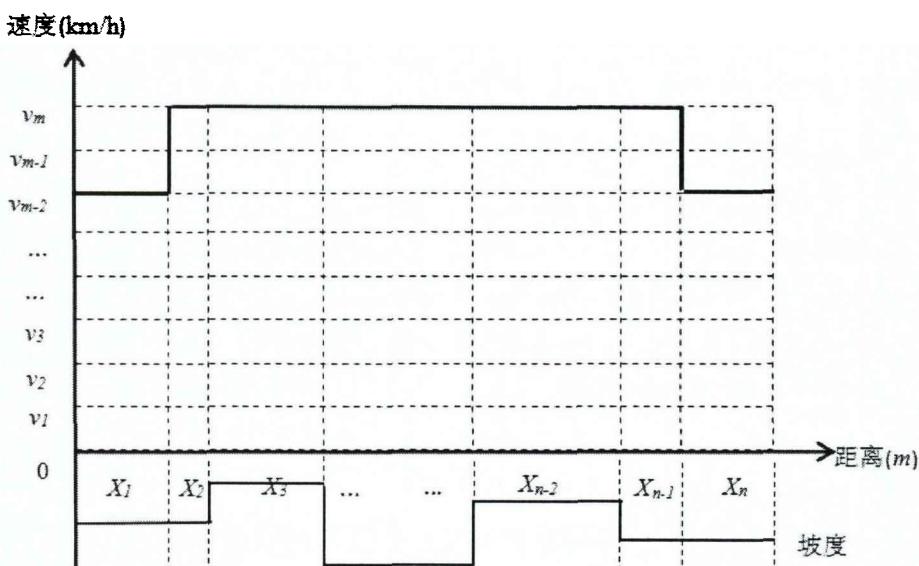


图 4-4 线路非等分分区示意图

Figure 4-4 The schematic diagram of unequal division of lines

4.4 基于 ABC 的推荐速度曲线单目标节能优化

本节直接应用人工蜂群算法优化列车的推荐速度曲线，是将列车节能优化这一多目标优化简化成单目标优化来解决，具体的实施办法为将列车运行时间这一目标函数作为能耗目标函数的约束条件来处理，如此，列车运行推荐速度曲线的节能优化问题便转化成了在速度-距离二维控间内寻找有时间约束的能耗最小的路径规划问题。

对于列车推荐速度曲线的寻优，做出以下假设：

- (1) 将列车作为质点进行处理
- (2) 列车运行启动阶段，应用牵引工况，使用最大牵引力，设置最大牵引加速度为 1m/s^2 ；列车停车阶段，应用制动工况，设置最大制动加速度为 1m/s^2 。
- (3) 推荐速度曲线中，当列车运行处于工况转换点，根据工况运行达到推荐速度码，未达到另一工况转换点时，采用巡航工况运行到下一速度转换点。如图 4-5 所示，A、B、C 为三个工况转换点，由 A 点到 B 点，速度增大，应用牵引工况，在实施牵引工况后，列车未运行到 B 点，已达到推荐速度码，则以巡航工况运行到 B 点。同理，B 点到 C 点，推荐速度曲线中采用惰行加巡航的工况实现速度转换。
- (4) 列车跟踪推荐速度曲线运行时，在初始阶段和最终阶段，分别实行牵引、制动工况进行精准跟踪，在运行的中间阶段，由于受时间因素约束，不能全程实行惰行工况，采用牵引-惰行的工况组合对推荐速度曲线进行跟踪运行。

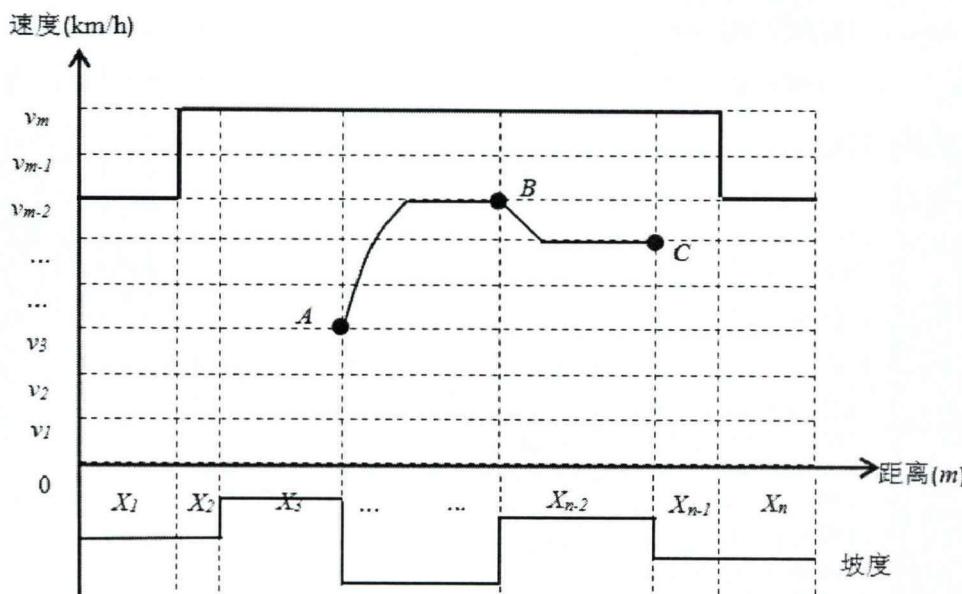


图 4-5 不同速度码之间的连接策略

Figure 4-5 The connection strategy between different speed codes

4.4.1 模型建立

将列车推荐速度曲线的节能优化转化为单目标优化问题后，模型中的目标函数即为列车能耗函数，如下式（4-15）所示。

$$\begin{aligned} \min E &= \sum_{i=1}^n E(X_i, v_i) \\ X_i &\in (0, s), v_i \in (0, v_{\text{lim}}) \\ \sum_{i=1}^n X_i &= s \end{aligned} \quad (4-15)$$

式中 $E(X_i, v_i)$ ——列车在第 i 个离散区间内的能耗；

X_i 、 v_i ——分别指第 i 个离散区间的长度和速度；

E ——列车运行过程的总能耗；

v_{lim} ——道路限速值， v_{lim} 不是一个固定值，但线路的限速曲线确定；

s ——两站之间的距离；

n ——线路中离散区间的个数。

模型中的约束条件有以下几方面：

(1) 速度约束：列车在出发车站的初始速度和到达车站的末速度均为 0，在站间运行时，列车运行速度不得超过道路规定的限速值。

(2) 时间约束：为满足列车的准时性，需要对列车的站间运行时间进行约束，本文对运行时间的约束为使列车运行时间等于列车运行时刻表规定的站间运行时间。

(3) 距离约束：为满足停车精度需要对列车运行距离进行约束，本文对距离的约束为使列车运行距离等于两站间的实际距离，不允许误差的存在。

(4) 舒适度约束：由式（2-19）可知，乘客舒适度与列车运行过程中加速度的大小有关，为了保证模型中的舒适度，需要将列车的加速度限制在一定范围内。

故模型的约束条件为式（4-16）

$$\begin{aligned} T &= T_{\text{plan}} \\ v_0 &= 0, v_n = 0 \\ 0 \leq v_i &\leq v_{\text{lim}} \\ \sum_{i=1}^n X_i &= s \\ -1 < \alpha &< 1 \end{aligned} \quad (4-16)$$

式中 v_0 、 v_n ——分别为列车的初速度和末速度；

T_{plan} ——列车运行时刻表的计划运行时间；

T ——列车站间实际运行时间，计算公式如式（4-17）。

$$T = \sum_{i=1}^n T(X_i, v_i) \quad (4-17)$$

式中 $T(X_i, v_i)$ ——列车在第 i 个离散空间上列车的运行时间。

综上所述，列车推荐速度曲线节能优化的优化模型为：

$$\begin{aligned} \min E &= \sum_{i=1}^n E(X_i, v_i) \\ s.t. &\left\{ \begin{array}{l} T = T_{plan} \\ v_0 = 0, v_n = 0 \\ 0 \leq v_i \leq v_{lim} \\ \sum_{i=1}^n X_i = s \end{array} \right. \end{aligned} \quad (4-18)$$

4.4.2 算法求解过程

(1) 初始化数据

解决优化问题时，首先要明确优化对象的数据参数，在对列车推荐速度曲线的优化问题中，需要初始化的数据主要有线路数据、车辆数据和算法初始化参数。

- 1) 线路数据：线路长度、线路坡度、线路曲度、道路限速等。
- 2) 车辆数据：列车车型、编组、列车重量、列车长度、列车基本阻力参数、最大加速度、最大减速度、列车牵引及制动的计算公式等。
- 3) 算法初始化参数：在算法开始之初，设置蜂群总数 N （其中采蜜蜂和观察蜂分别为 $N_e=N/2$ ）、蜜源最大采集限度 $Limit$ 、最大迭代次数 $maxCycle$ 。

(2) 根据坡度和限速值对线路进行离散化

(3) 种群初始化，根据模型中的约束条件式(4-8)，通过动力学模型式(2-15)，在速度-距离二维空间内随机产生 N 个可行解。

(4) 对 N 个可行解的适应度值进行求解，计算公式为式 (4-19)，由公式可知，能耗值越小则适应度值越大，将得到的 N 个适应度值按由大到小的顺序进行排列，选取前 $N/2$ 个可行解作为采蜜蜂，后 $N/2$ 个作为观察蜂。

$$P_i = \frac{1}{E} \quad (4-19)$$

(5) 局部寻优，采蜜蜂在附近位置进行邻域搜索，计算搜索到的新可行解的适应度值，并与原位置的适应度值进行比较，根据式 (3-4) 的选择算子，保留适应度值较大的可行解，淘汰较小的，若保留的解为原解，则 $trial=trial(i)+1$ ，否则 $trial=0$ 。

(6) 观察蜂采用轮盘赌的选择方式决定是否跟随采蜜蜂。根据概率跟随公式

(4-20) 计算 P_i , 产生一个随机数 $rand()$, 若 $P_i > rand()$, 则跟随采蜜蜂, 并在采蜜蜂附近进行邻域搜索, 保留适应度值较大的可行解, 赋值 $trial=0$ 。否则观察蜂不跟随采蜜, 保留原解, 令 $trial=trial(i)+1$ 。

$$P_i = \frac{0.9 \cdot fit}{fit_{max}} + 0.1 \quad (4-20)$$

(7) 若蜜蜂在一处经过 $Limit$ 次迭代后可行解位置不变, 即 $trial(i) > Limit$, 则该采蜜蜂或观察蜂变成侦察蜂, 根据式 (3-1) 的搜寻方法随机产生一个新的可行解代替该可行解。

(8) 当满足条件 $iter$ 大于 $maxCycle$ 时, 进行步骤 (9), 否则, 进行步骤 (5)。

(9) 输出推荐速度曲线和适应度值, 结束。

算法流程图如下图 4-6:

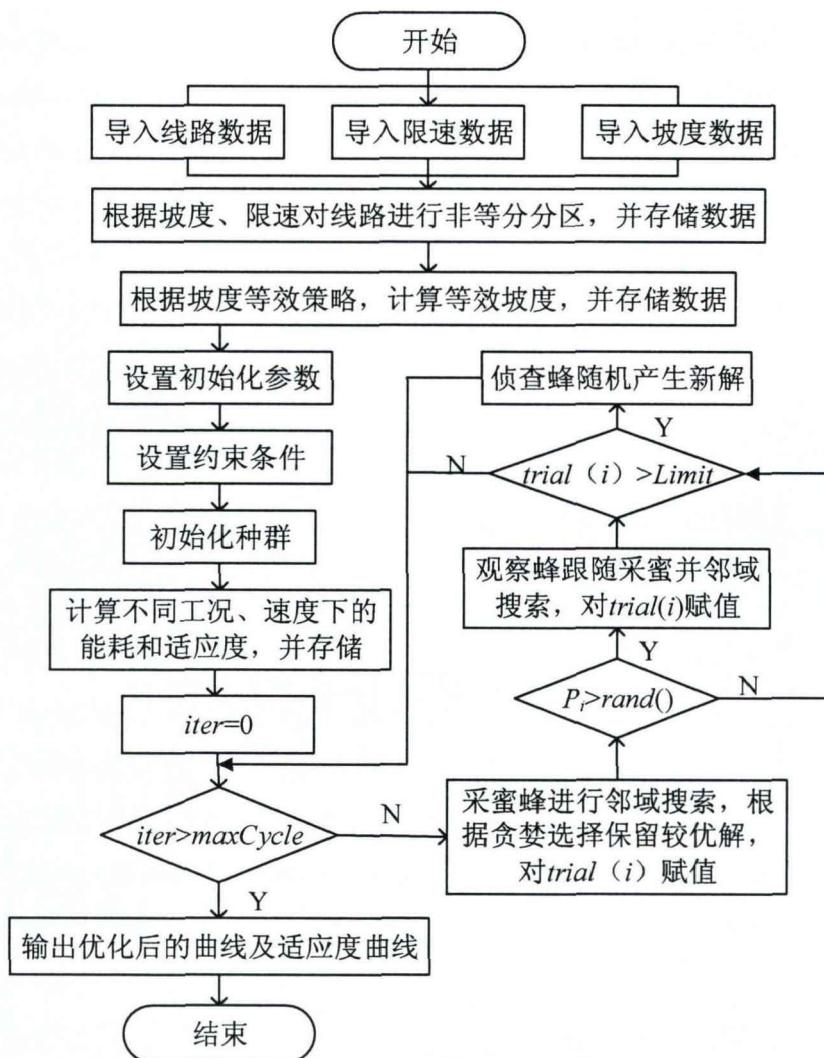


图 4-6 单目标优化流程图

Figure 4-6 The optimization flow chart

4.5 基于改进 ABC 的推荐速度曲线多目标节能优化

应用多目标人工蜂群算法直接对推荐速度曲线进行多目标优化，即如 4.1 节对于问题的分析，将该问题转化为在速度-距离二维空间内寻找能耗最小、运行时间误差最小的路径规划问题。

对于列车节能优化问题的假设与前文 4.4.1 中假设相同，假设列车为质点，规定最大加/减速度不超过 1m/s^2 ，两工况转换点之间采用牵引-巡航及惰行-巡航的组合方式，列车运行启动阶段及最终的制动阶段进行精确跟踪，中间运行阶段采用牵引-惰行的运行工况组合。

4.5.1 模型建立

本文中对于推荐速度曲线的多目标优化为两个方面，一是节能，二是准时，故模型中的两个目标函数为式（4-21）

$$\begin{aligned}\min E &= \sum_{i=1}^n E(X_i, v_i) \\ \min \Delta T &= |T - T_{plan}|\end{aligned}\quad (4-21)$$

模型中的约束条件主要有速度约束以及距离约束，表达式为式（4-22）

$$\begin{aligned}v_0 &= 0, v_n = 0 \\ 0 \leq v_i &\leq v_{\text{lim}} \\ \sum_{i=1}^n X_i &= s \\ -1 \leq a &\leq 1\end{aligned}\quad (4-22)$$

综上所述，列车推荐速度曲线的节能优化模型为（4-23）：

$$\begin{aligned}\min E &= \sum_{i=1}^n E(X_i, v_i) \\ \min \Delta T &= |T - T_{plan}| \\ s.t. &\left\{ \begin{array}{l} v_0 = 0, v_n = 0 \\ 0 \leq v_i \leq v_{\text{lim}} \\ \sum_{i=1}^n X_i = s \\ -1 \leq a \leq 1 \end{array} \right.\end{aligned}\quad (4-23)$$

4.5.2 多目标人工蜂群算法

在解决多目标优化问题时，由于需要优化的目标不再单一化，导致选择判断标准发生改变，算法中的适应度计算、邻域搜索、全局搜索方式、观察蜂的跟随选择方式、蜜蜂对蜜源的选择算子都应做出相应的改变，以适应对多目标问题的优化，找到 Pareto 最优解集。

从基本人工蜂群算法到多目标人工蜂群算法的主要转换策略如下：

(1) 适应度值-解的评估标准：

在基本的人工蜂群算法中，适应度值的大小仅与单一的目标函数值有关，由于多数优化问题寻求目标函数的最小值，因此常常将目标函数值的倒数作为算法中的适应度值进行比较。而多目标优化中，由于存在多个目标函数，且难以求得使得所有目标函数都达到最优的解，故对算法中适应度的计算进行更新，从寻找 Pareto 最优解的角度出发，进行适应度值的计算。具体改进方法为：对所有随机生成的蜜源进行目标函数的计算，并两两比较，得出两个可行解之间的支配关系。若两个可行解 Food1、Food2，满足式 (4-24) 中的逻辑关系之一，则 $Food1 \succ Food2$ ，即可行解 Food1 优于 Food2，那么 Food1 在种群中的可支配数量 $dom(1)$ 加 1，确认 Food1 与所有可行解之间的支配关系，得到 Food1 最终的可支配数量 $dom(1)$ 。

$$\begin{aligned} & E1 < E2, \Delta T1 \leq \Delta T2 \\ & E1 \leq E2, \Delta T1 < \Delta T2 \\ & E1 < E2, \Delta T1 < \Delta T2 \end{aligned} \quad (4-24)$$

适应度值的大小为可行解在种群中的可支配数量与种群可行解总数之比，计算公式为式 (4-25)，其中， N 为种群总数。

$$fit(i) = \frac{dom(i)}{N} \quad (4-25)$$

(2) 贪婪准则：

蜜蜂在进行邻域搜索时，对两个解的选取标准依从贪婪准则，基本人工蜂群算法中的贪婪准则即对比新旧两解的适应度值，选择适应度值大的解保留，抛弃小的。由于解质量好坏的判断标准不再是单一的目标函数值，该贪婪准则在 MOABC 算法中不再适用，根据 Pareto 支配关系进行改进得到新的贪婪准则：当蜜蜂在邻域搜索到新解时，判断新解与当前解的支配关系，若新解支配当前解，保留新解，同时计数变量 $trial=0$ ，若当前解支配新解，则保留当前解，同时计数变量 $trial=trial+1$ 。

(3) Pareto 最优解的存储：

对于已经找到的 Pareto 最优解，利用外部档案对其进行存储，每当有一轮搜

索结束，会对外部档案中的解进行更新，加入搜索到的支配能力更强的新解，剔除掉档案中相对较差的旧解。

(4) 外部档案的维护：

随着搜索次数的增加，寻找到的符合条件的解的数量不断增多，若不对外部档案的规模进行控制，则算法的计算量将大大增加，因此，为了简化计算，对外部档案的规模进行控制，设置一个可容纳解数目的最大值，一旦档案中解的个数超过该限制值，则计算每个解的拥挤距离，删除拥挤距离最小的个体，即通过删除相似解的方法控制外部档案的规模，并且根据拥挤距离的大小剔除掉相似解容纳新的解，能够使得算法在解空间不变的条件下，丰富解的多样性。

拥挤距离是指对可行解按一定次序进行排列后，某一可行解与其前后两解之间的距离，常用拥挤距离的大小作为种群密度的评判标准，拥挤距离越小，则种群密度越大，反之，拥挤距离越大，表示种群密度越小。在外部档案中，拥挤距离可以判断档案中 Pareto 最优解的多样性，拥挤距离越小，说明档案中相似的解越多，解的多样性越差，造成局部收敛的概率越大，反之，拥挤距离越大，解的多样性越好，越容易找到全局最优解。通过拥挤距离维护外部档案的过程可以描述为以下几个步骤：

- 1) 根据第 m 个目标函数值的大小对所有解进行排序
- 2) 将排序后目标函数值最小的解的拥挤距离设置为无穷大，保留该解，不再进行拥挤距离的计算。
- 3) 若所有解的目标函数值相同，则拥挤距离全部为 0，否则，第 i 个解的拥挤距离等于第 $i+1$ 个解和第 $i-1$ 个解的目标函数值之差与该目标函数值的最大最小值之差的比值，计算公式为式 (4-26)

$$L_m(i) = (f_m(i+1) - f_m(i-1)) / (f_m^{\max} - f_m^{\min}) \quad (4-26)$$

式中， $L_m(i)$ 为第 i 个解的拥挤距离， $f_m(i+1)$ 为第 m 个目标函数在第 $i+1$ 个解处的目标函数值， $f_m(i-1)$ 为第 m 个目标函数在第 $i-1$ 个解处的目标函数值， f_m^{\max} 为所有解中目标函数 f_m 的最大值， f_m^{\min} 为所有解中目标函数 f_m 的最小值。

- 4) 根据档案规模的限制，剔除多余的拥挤距离小的解，保留拥挤距离大的解，使档案中的解分布更均匀，有利于保持解的多样性。

(5) 邻域搜索方法：

对于邻域搜索，为了避免后期解过于集中，造成局部最优的情况，以全局信息作为搜索指导，从外部档案集中随机选取任意非劣解为蜂群的邻域搜索提供搜索方向，使搜寻到的解分布更均匀，更有利保证解的多样性，达到全局寻优的目的。改进的邻域搜索方法如下式 (4-27)。

$$x_i = x_i + w_1 \cdot rand(0)(x_i - x_k) \quad (4-27)$$

式中, w_1 为比例因子, $rand()$ 为随机产生的[0,1]之间的任意数, x_k 为外部档案集中的任意非劣解。

4.5.3 算法求解过程

程序流程图如图 4-7 所示。

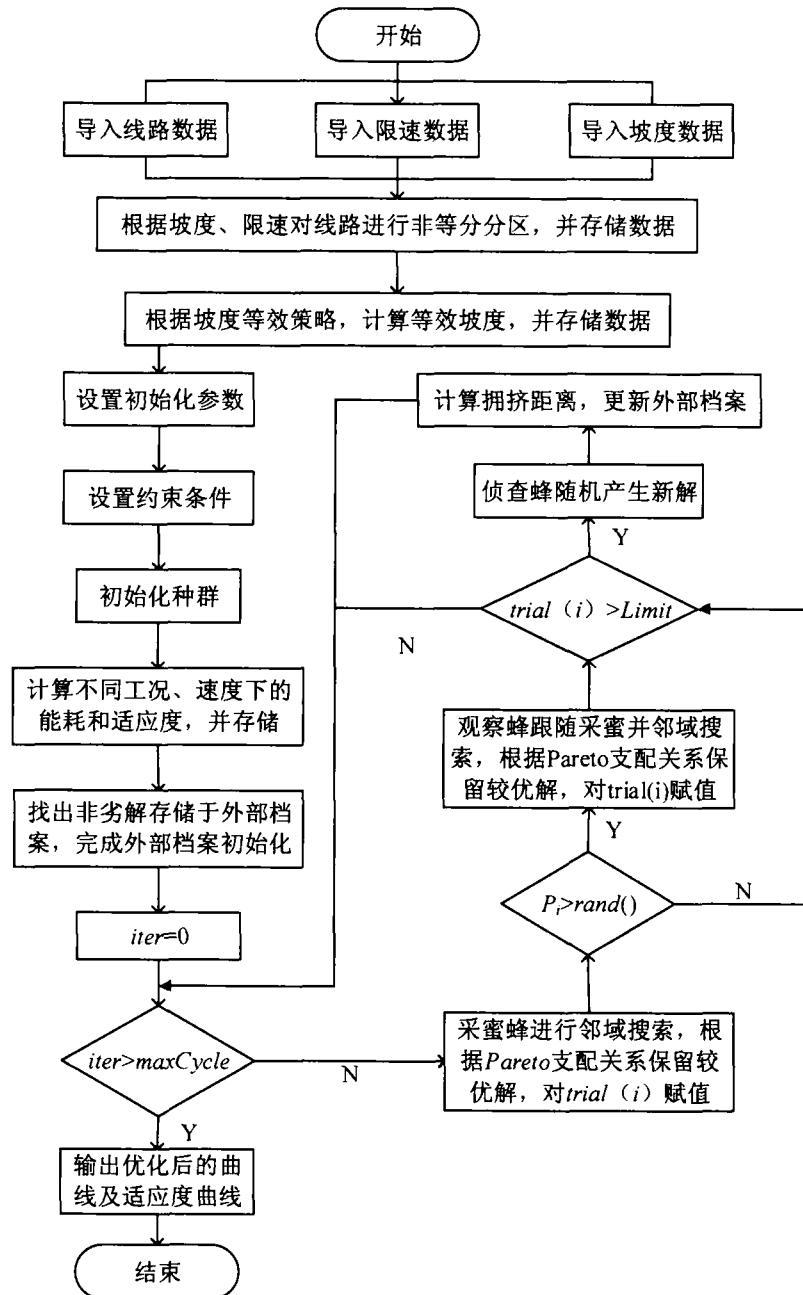


图 4-7 多目标优化流程图

Figure 4-7 The flow chart of multi-objective optimization

应用算法进行优化的具体过程如下：

(1) 初始话数据，包括道路数据和车辆数据，并对算法中的种群进行初始化，设置种群数量、最大迭代次数 $maxCycle$ 、最大蜜源开采量 $Limit$ 。

(2) 根据坡度等效策略计算出等效坡度，并根据限速值和坡度对线路进行不等分分区。

(3) 初始化种群，根据 Pareto 支配原则，找出初始化种群中的非劣解，存储到外部档案中。并根据式 (4-18) 计算出初始化种群的适应度值，对适应度值进行排序，选前 $N/2$ 个为采蜜蜂，后 $N/2$ 个为观察蜂。

(4) 采蜜蜂根据式 (4-20) 进行局部搜索，在外部档案中任意一个非劣解的指导下在邻域内搜索到新解，并确定原解与新解之间的 Pareto 支配关系，保留非支配解，若保留的解为原解，则 $trial(i) = trial(i) + 1$ ，否则 $trial(i) = 0$ 。

(5) 根据式 (3-5) 计算跟随概率 P_i ，随机产生一个 0-1 之间的随机数，根据跟随概率与随机数之间的大小关系，选择是否跟随采蜜蜂。若 P_i 大，则跟随，并且进行邻域搜索，按 Pareto 支配关系选择所保留的解，若保留的解为原解，则 $trial(i) = trial(i) + 1$ ，否则 $trial(i) = 0$ 。

(6) 当 $trial(i) > Limit$ 时，抛弃该解，该采蜜蜂或观察蜂变为侦察蜂，随机产生一个新解。

(7) 当外部档案中的非劣解数量达到上线值时，计算外部档案中所有非劣解的拥挤距离，并按照大小进行排序，从拥挤距离最小的解中去除多余的非劣解，完成外部档案的维护。

(8) 当 $iter > maxCycle$ 时，进行步骤 (9)，否则进行步骤 (4)。

(9) 输出推荐速度曲线和适应度值，结束。

4.6 本章小结

本章对列车节能优化问题进行了分析，将其转化为在速度-距离二维空间中寻找能耗最小、运行时间最短的路径规划问题。并提出了两种应用人工蜂群算法解决该问题的方式，一种为将运行时间这一目标函数转化为约束条件，将多目标优化问题转变成单目标优化问题，应用 ABC 算法进行解决，另一种为基于 Pareto 支配准则对 ABC 算法进行改进以适应多目标优化问题。本章提出了根据限速、坡度的不同对线路进行不等分区的离散法，对于计算中的坡度提出了等效坡度的计算方法，并对应用 ABC 算法优化推荐速度曲线的两种方法的步骤和算法流程图进行了详细的介绍。

5 仿真与分析

本文应用 MATLAB 仿真平台，以北京地铁亦庄线的线路、车辆数据为基础，对前文提出的方法进行仿真验证，分别通过对单目标优化方法和多目标优化方法的对比、区间等分和不等分的对比以及不同跟踪策略的对比三个方面对仿真结果进行分析比较，得出结论。

5.1 基础数据

亦庄线是一条连接北京市区到经济开发区，全长达 23.3 千米、最高运行时速在 80km/h 的线路，其中间经过 14 座车站，13 个区间，线路中既存在地上车站又存在地下车站，且线路中间存在陡坡，是进行节能优化的最佳之选。

5.1.1 线路数据

本文中选取同济南路到经海路的站间运行作为实例进行分析，其运行方向属于从宋家庄到亦庄的上行方向，站间全长为 2265 米，最高限速为 80km/h，列车运行时刻表中的站间运行时间为 150 秒，车站的停车时间为 30 秒。根据现有的列车运行策略按运行时刻表的时间进行运行时列车的能耗为 22.73kwh，该站间的坡度相对全线其他区间较缓，在距离两车站各 130 米左右对列车运行的限速为 55km/h，其他位置的限速均为 80km/h，具体的线路数据详见表 5-1。

表 5-1 同济南路-经海路线路数据

Table 5-1 The data of Tongjinan road-Jinghai road

位置 (m)	坡度 (%)	限速 (km/h)
0-130	0	55
130-248	0	80
248-568	-8	80
568-938	-3	80
938-1378	5	80
1378-2058	1	80
2058-2155	0	80
2155-2265	0	55

5.1.2 车辆数据

根据规定，我国地铁线路的列车通常选择 A 型车或 B 型车运行，亦庄线的运行列车为 B 型车，采用三动三拖组合的六节编组方式，具体的车辆数据详见表 5-2。

表 5-2 同济南路-经海路车辆参数表

Table 5-2 The data of vehicle parameter from Tongjinan road-Jinghai road

列车参数	参数值
车型	B 型车
列车编组	三动三拖
列车长度 (m)	140
	194.295 (AW0)
列车重量 (t)	282.375 (AW2)
	307.095 (AW3)
列车最大运行速度 (km/h)	80
基本阻力参数 a	2.031
基本阻力参数 b	0.0622
基本阻力参数 c	0.001807

列车运行过程中的速度调节需要依靠牵引或制动，不同列车或相同列车不同载重下的牵引力/制动力的计算方式各不相同，《列车牵引规程》中给出了列车的牵引特性曲线及列车制动特性曲线，图 5-1 为列车在不同速度下的最大牵引/制动力特性。

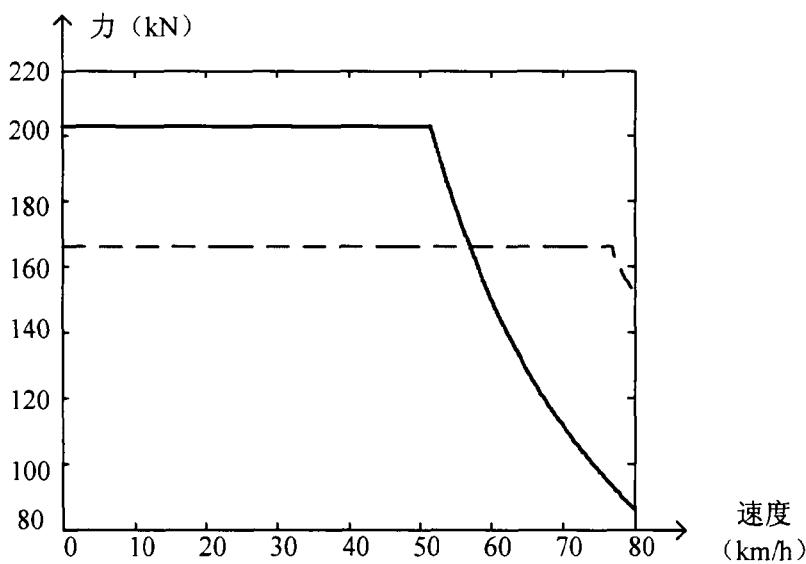


图 5-1 AW0 下的列车牵引制动特性曲线

Figure 5-1 The train traction and braking characteristic curve under AW0

在列车空载（AW0）的条件下，根据北京地铁亦庄线采用的牵引特性曲线拟合后得到列车的最大牵引力计算公式为：

$$F_{\max} = \begin{cases} 203 & 0 \leq v \leq 51.5 \\ -0.002032v^3 + 0.4928v^2 - 42.13v + 1343 & 51.5 \leq v \leq 80 \end{cases} \quad (5-1)$$

拟合生成的最大制动力公式为：

$$B_{\max} = \begin{cases} 166 & 0 \leq v \leq 77 \\ 0.134v^2 - 25.07v + 1300 & 77 \leq v \leq 80 \end{cases} \quad (5-2)$$

式中，最大牵引力、最大制动力的单位为 kN。

5.1.3 控制策略

本文中的列车跟踪运行策略，采用启动阶段精确跟踪列车推荐速度曲线中的牵引启动部分，停车阶段精确跟踪列车推荐速度曲线的制动停车部分，中间运行部分采用牵引-惰行相结合的工况跟踪运行推荐速度曲线中的巡航部分的策略。对于中间部分的跟踪运行策略如下图 5-2 所示，当列车的跟踪速度接近推荐速度且与推荐速度之间的差值小于 A 时，列车开始惰行，适当降低速度，当跟踪速度与推荐速度之间的差值大于 B 时，列车实施牵引工况，进行提速，达到使列车的跟踪速度保持在 A 与 B 之间运行的目的。

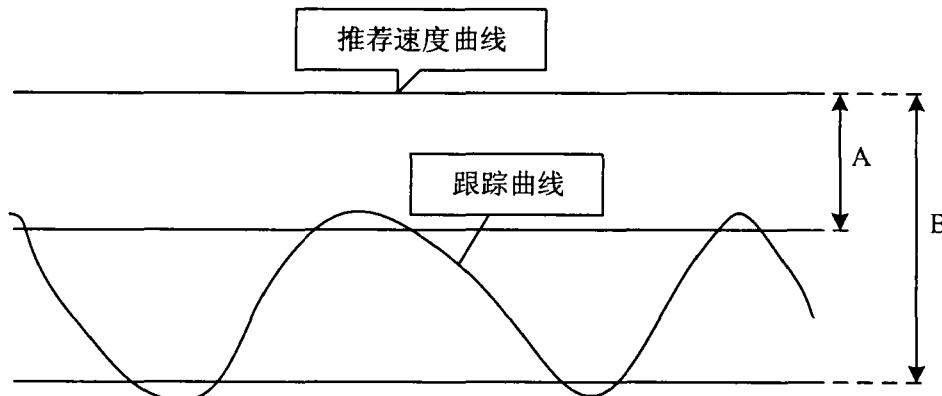


图 5-2 跟踪策略示意图

Figure 5-2 The tracking strategy diagram

5.2 单目标优化与多目标优化的仿真验证

对于列车运行推荐速度曲线的单目标优化，如前文所述，将运行时间设置为时刻表计划的运行时间，即 150 秒，速度为 0 的位置为 2265 米，即默认达到精准

停车。应用人工蜂群算法对进行优化，设置初始参数，蜜蜂种群总数为 40，其中采蜜蜂数量为 20，观察蜂数量为 20，最大的迭代次数 $maxCycle$ 设置为 100，最大开采限度 $Limit$ 设置为 50，根据北京地铁亦庄线的线路数据、车辆参数及拟合计算公式，应用 MATLAB 进行仿真，得到能耗值的进化过程如图 5-3 所示，推荐速度曲线如图 5-4 所示。

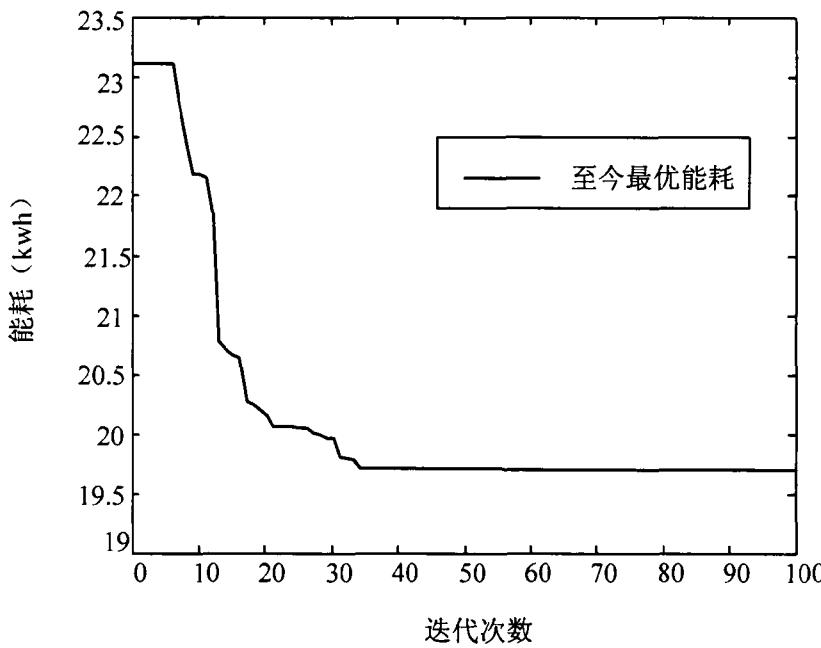


图 5-3 最优能耗进化曲线

Figure 5-3 The optimal energy consumption evolution curve

如图 5-3 所示，算法运行到迭代次数为 33 次左右，至今最优能耗基本趋于稳定状态，迭代次数达到 55 次左右，寻找到最终的最优能耗，与 33 次的最优能耗值之间的误差特别小，说明算法跳出 33 次时的局部最优，寻找到了最终的全局最优值。图中的迭代次数反映了算法的收敛速度较快，能耗坐标轴反映了算法的寻优精度较高。

如图 5-4 所示，在坡度和限速的约束下，将线路分为多个不等分区间，图中红色实线为列车推荐速度曲线，有人工蜂群算法根据实际数据计算出推荐速度码的集合，后根据第四章中的策略将推荐速度码之间的部分应用牵引-巡航或制动-巡航的方式相连接，得到完整的推荐速度曲线。图中蓝色虚线为应用 simulink 生成的列车的跟踪速度曲线，控制策略如 5.1.3 节所述，其中 $A=2$, $B=3$ ，仿真后得到的最佳能耗结果为 19.68kwh。程序中应用 `tic` 函数计时，得到算法的计算时间为 19.25s，已知列车的站间停车时间为 30s，故将该方法应用到实际线路中具有可行性。

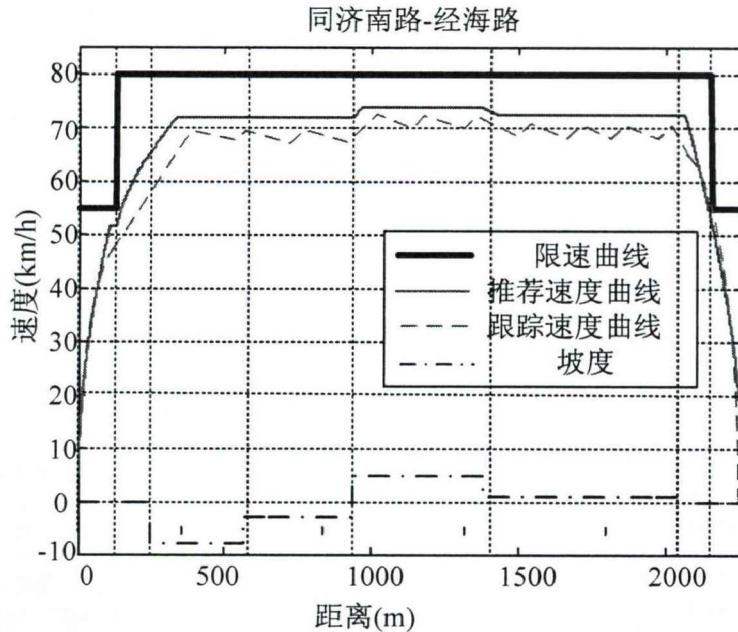


图 5-4 单目标优化仿真图

Figure 5-4 The single-objective optimization simulation diagram

表 5-3 为优化前后数据结果的对比，由表中数据可知，将运行时间这一目标函数转化为约束条件以将多目标优化转化为单目标优化这一方法得出的推荐速度曲线，其能耗与优化前相比，减少了 1.76kwh，节能率达到 8.2%，节能效果明显。

表 5-3 单目标优化前后数据结果对比

Table 5-3 Comparison of data results before and after single objective optimization

优化前后	运行时间 (s)	能耗 (kwh)	节能率 (%)	算法计算时间 (s)
优化前	150	21.44	—	—
优化后	150	19.68	8.2	19.25

对于推荐速度曲线的多目标优化，如前文所述，将运行距离设置为 2265 米，即默认达到精准停车。应用人工蜂群算法对列车推荐速度曲线进行优化，设置初始参数，蜜蜂种群总数为 40，其中采蜜蜂数量为 20，观察蜂数量为 20，最大的迭代次数 *maxCycle* 设置为 100，最大开采限度 *Limit* 设置为 50，根据北京地铁亦庄线的线路数据、车辆参数及拟合计算公式，应用 MATLAB 进行仿真，得到的 Pareto 前端如图 5-5 所示，推荐速度曲线如图 5-6 所示。

图 5-5 是算法优化后外部档案中所有 Pareto 最优解形成的 Pareto 前端，对所有 Pareto 最优解进行分析，综合考虑能耗和时间误差两项指标，选出一个最优解，此解对应的能耗值为 19.55kwh，列车的站间运行时间为 149.89s，与计划运行时间之间的误差为 0.11s，符合列车运行时间的误差标准。

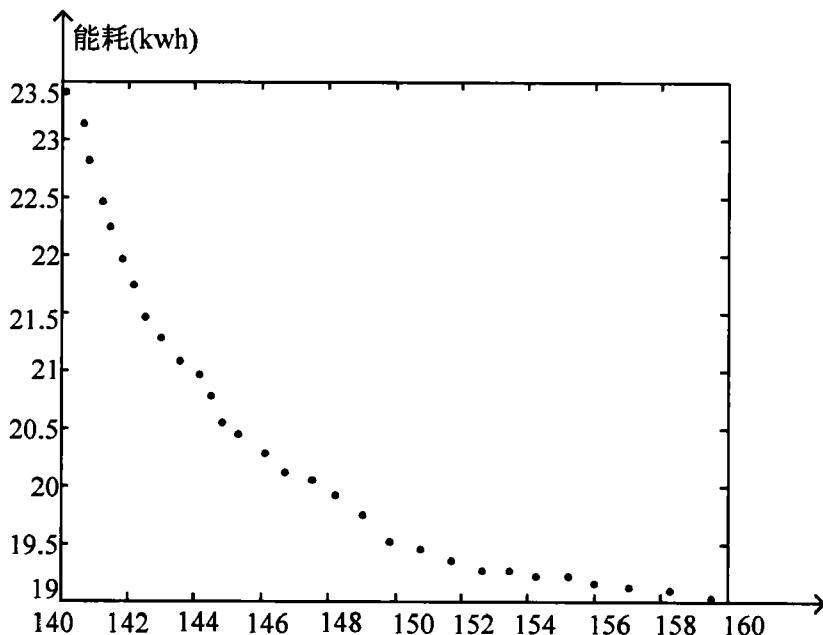


图 5-5 Pareto 前端

Figure 5-5 Pareto front

上文中选取的最优解的推荐速度曲线如图 5-6 所示，跟踪运行策略仍然将 A 设置为 2、B 设置为 3。程序中应用 tic 函数计时，得到算法计算时间是 20.52s，已知列车的站间停车时间为 30s，故将该方法应用到实际线路中具有可行性。

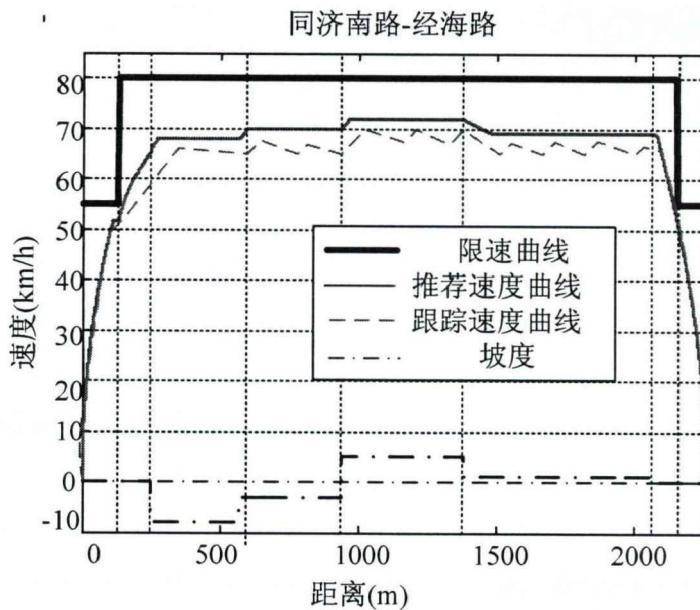


图 5-6 多目标优化仿真图

Figure 5-6 The multi-objective optimization simulation chart

表 5-4 为应用改进的人工蜂群算法对推荐速度曲线优化前后数据结果的对比，由表中数据可知，优化后的能耗与优化前相比，减少了 1.89kwh，节能率达到 8.81%，节能效果明显。

表 5-4 多目标优化前后数据结果对比

Table 5-4 Comparison of data results before and after multi-objective optimization

优化前后	运行时间 (s)	能耗 (kwh)	节能率 (%)	算法计算时间 (s)
优化前	150	21.44	—	—
优化后	149.89	19.55	8.81	21.67

将两种方法优化后的数据进行对比，如下表 5-5 所示，应用多目标优化方法得到的推荐速度曲线的节能率优于单目标优化方法，但由于多目标人工蜂群算法在优化时需要对外部档案进行维护，计算外部档案中各解之间的拥挤距离，剔除多余的解，因此多目标优化方法比单目标优化方法的计算时间要大。

表 5-5 单目标与多目标优化对比结果

Table 5-5 Comparison of single-objective optimization and multi-objective optimization

方法	运行时间 (s)	能耗 (kwh)	节能率 (%)	算法计算时间 (s)
单目标优化	150	19.68	8.2	19.25
多目标优化	149.89	19.55	8.81	21.67

5.3 等分区间与非等分区间的仿真验证

离散组合优化问题中应用频率最高、最简单的方法为等分区间法，而本文中对推荐速度曲线的优化，其计算与线路中的限速、坡度有关，所以应用非等分区间的方法，为了验证非等分区间的效果，对等分区间与非等分区间的优化仿真结果进行对比。由于 5.2 节对单目标、多目标方法的对比结果显示多目标优化方法更优，因此，选用多目标节能方法对离散组合进行验证。其中，两种方法之间仅有区间划分不同，其余参数设置均相同，以保证验证结果的差异由离散组合的不同而产生。算法中初始化参数的设置为：蜜蜂种群总数为 40，其中采蜜蜂数量为 20，观察蜂数量为 20，最大的迭代次数 *maxCycle* 设置为 100，最大开采限度 *Limit* 设置为 50。图 5-7 为等分区间得到的优化仿真图，图 5-6 为非等分区间得到的优化仿真图。

如图 5-7 所示，等分区间方法得到的推荐速度码较多，即运行工况的转换点较多，与图 5-6 的非分区方法相比，牵引距离增大，造成能耗较大，但也由于牵引次数的增多，减小了列车的站间运行时间。

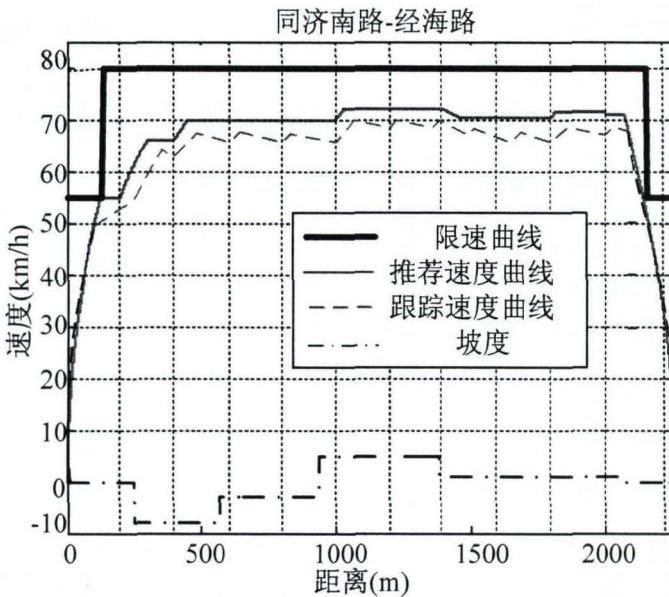


图 5-7 等分区间仿真图

Figure 5-7 The figure of equal partition optimization simulation

等分区间与非等分区间的对比结果如表 5-6 所示，与非等分区间相比，无论是从时间误差还是能耗上，等分区间都不占优势，并且等分区间的算法计算时间为 35.64s，大于列车在站间的停车时间，故等分区间不仅节能效果相对较差，更没有投入实际应用的可行性。

表 5-6 等分区间与非等分区间的对比结果

Table 5-6 The comparison between equal partitions and non-equal partitions

方法	运行时间 (s)	能耗 (kwh)	节能率 (%)	算法计算时间 (s)
等分区间	149.6	20.43	6.73	35.64
非等分区间	149.89	19.55	8.81	21.67

5.4 不同控制策略下的仿真验证

实际列车运行中，难以做到对推荐速度曲线的精确跟踪，往往以一定的控制策略控制列车的运行，本文应用 MATLAB 对不同控制策略的跟踪曲线进行仿真，参照亦庄线的控制参数，应用 simulink 模拟列车自动运行系统的跟踪控制，产生相应驱动信号，对跟踪控制策略中的参数进行设置，使系统根据控制策略输出相应的牵引或制动命令，对列车速度进行控制，完成跟踪运行。

本节以多目标优化得到的推荐速度曲线为基础，对控制策略中的参数进行设

置，比较不同参数的设置对节能效果的影响，图 5-8 为对 A、B 赋不同值时，列车跟踪曲线的优化结果。

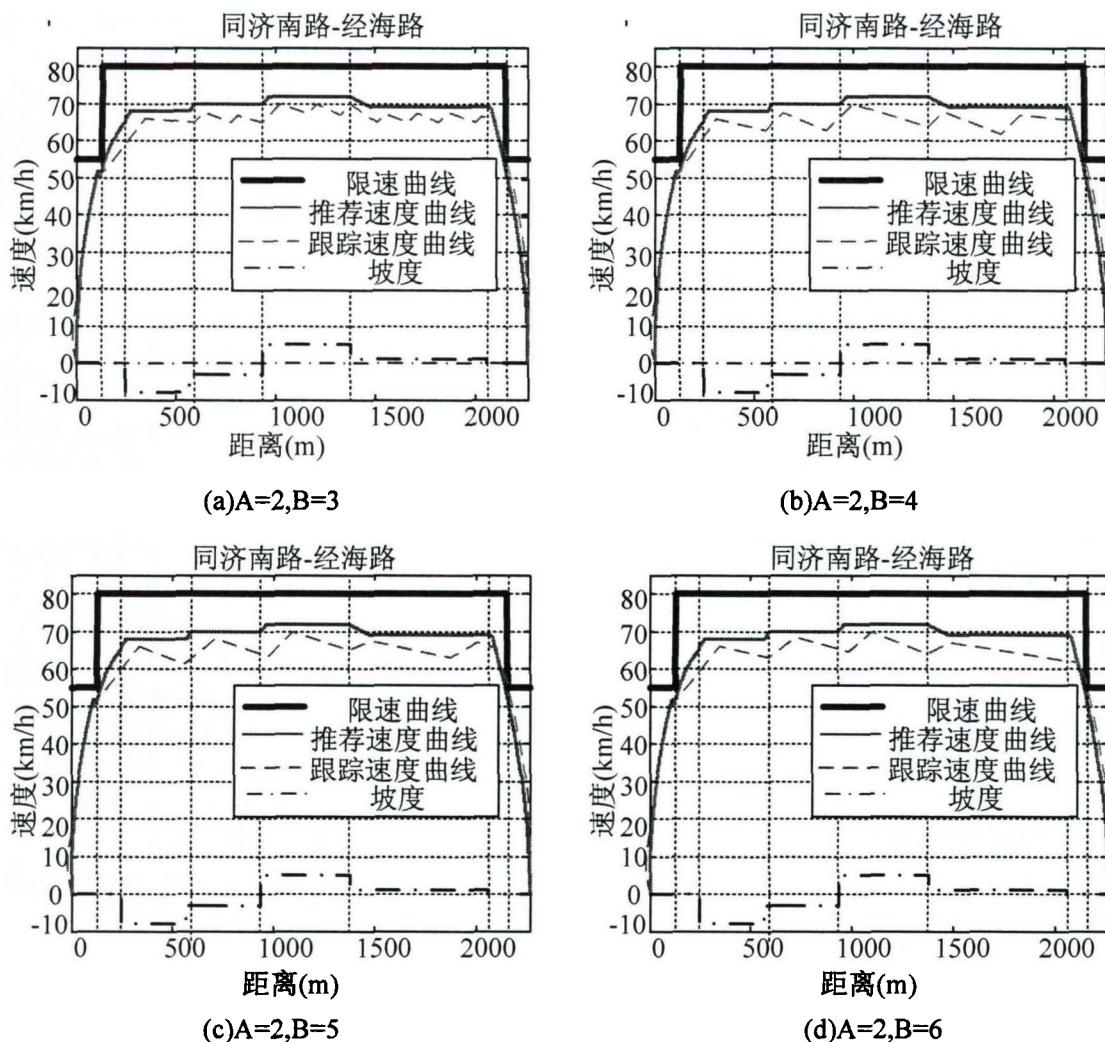


图 5-8 不同控制策略下的优化结果

Figure 5-8 The optimization results under different control strategies

根据图 5-8 中不同控制策略的仿真图对比，发现在 A 的值不变的情况下，B 的值越大，列车在中间运行时的牵引工况越少、惰行工况越多，能大大减小列车运行能耗，但由于惰行时间较长，相应的站间运行时间也增多，因此控制策略中的参数设置并不是 B 的数值越大越好。

对控制策略设置不同的参数进行仿真，结果如表 5-7 所示，由表可知不同运行参数的设置对列车跟踪运行的能耗和运行时间都有影响，如果仅考虑节能因素、在 A 不变的情况下，不合理的设置 B 的大小来增加惰行时间，有可能造成列车严重的延误，相反，合理的设置参数能够在推荐速度曲线优化的基础上，减小能耗，达到更优的节能效果。

表 5-7 不同控制策略下的优化对比结果

Table 5-7 The optimal contrast results under different control strategies

参数设置	能耗 (kwh)	运行时间 (s)
A=2, B=3	20.53	150.21
A=2, B=4	19.94	150.62
A=2, B=5	19.28	151.07
A=2, B=6	19.97	151.29

5.5 本章小结

本章将应用 MATLAB 仿真平台得到的仿真图与仿真数据进行对比分析。第一节对仿真过程中的参数进行了介绍，仿真线路为亦庄线上行中的同济南路到经海路运行区间，根据列车的牵引制动特性曲线拟合出了列车的最大牵引力和最大制动力的计算公式，并对列车根据控制策略的跟踪运行方式进行了介绍；第二节对第四章中提出的应用人工蜂群算法进行单目标优化以及多目标优化方法进行了仿真，并对仿真结果进行对比分析，得出采用多目标人工蜂群算法对推荐速度曲线进行多目标优化具有更高的节能率，节能率达到 8.81%。第三节对比对线路进行离散化时等分区间和非等分区间的优化结果，得出非等分区间在节能、运行误差、算法计算时间三个方面均具呈现出较好的效果，且等分区间增大了计算的复杂度，使算法计算时间大大增加，大于列车的站间停车时间，不具有可行性；第四节分析了不同列车控制策略下跟踪曲线的优化效果，验证了控制参数 A、B 的设置能影响列车跟踪运行时的牵引及惰行里程，进而影响能耗及运行时间误差，因此，设定合理的控制参数能在推荐速度曲线优化的基础上找到更优的推荐速度曲线。

6 总结与展望

6.1 总结

对于单列车的节能运行问题，本文基于列车自动运行系统ATO的双层控制结构，考虑列车跟踪运行的控制策略，提出了使用收敛速度快且不易陷入局部收敛的人工蜂群算法进行列车运行推荐速度曲线的节能优化，并利用MATLAB进行仿真验证。

本文的主要工作及研究结论如下：

(1) 首先通过数据分析了城市轨道交通运营规模大、耗电量高的研究背景，对耗电量的占比进行分析，通过牵引耗能半数以上的结论得出优化列车推荐速度曲线的研究意义，对国内外的研究现状进行概括分析，发现现有智能算法的弊端，提出应用人工蜂群算法进行优化。

(2) 将列车作为单质点，对其运行过程进行受力分析，建立动力学模型，分析列车在四种工况下的受力及能耗，并在动力学模型的基础上，应用最大值原理建立汉密尔顿函数，得出最优操纵策略应包括最大牵引、巡航、惰行、最大制动四种工况的结论，后对ATO的其他性能指标进行分析。

(3) 将人工蜂群算法与已应用在列车节能优化问题中的智能算法进行比较，通过对三个基准函数的仿真结果分析人工蜂群算法的寻优性能，验证应用人工蜂群算法进行推荐速度曲线节能优化的可行性：

- 1) 对单峰单极值函数Sphere Model的仿真，ABC算法的最佳寻优精度在 10^{-17} 数量级，而PSO算法和DE算法的最佳寻优精度分别在 10^{-11} 和 10^{-10} 的数量级，证明人工蜂群算法具有良好的寻优精度。通过对三种算法适应度进化曲线的对比，证明人工蜂群算法具有较快的收敛速度。
- 2) 对多峰多极值函数Griewank的仿真，ABC算法的最佳寻优精度高出PSO算法和DE算法14个数量级，但ABC算法的稳定性有所降低，30次仿真结果中的最大值与最小值之间相差6-7个数量级，而DE算法和PSO算法的仿真结果较为稳定，陷入局部收敛。三种算法的适应度进化曲线仍显示ABC算法具有最快的收敛速度。
- 3) 对病态函数Generalized Rosenbrock的仿真，低维仿真时三种算法的寻优精度差距较小，高维时，ABC算法的寻优精度仍然保持较高，但DE算法和PSO算法的寻优精度较差，算法容易陷入局部收敛，通过适应度进化曲线

的对比发现，ABC 算法和 PSO 算法有较快的收敛速度，证明 ABC 算法和 PSO 算法都具有较强的搜索能力。

(4) 将列车的推荐速度曲线节能优化问题转化成在速度-距离二维空间内进行能耗最小、运行时间误差最小的路径规划问题。提出两种解决方法，其一是将运行时间误差转化成为约束条件从而将多目标优化转化成单目标优化，其二是对人工蜂群算法进行改进直接进行多目标优化，并对两种方法分别进行建模优化。

- 1) 线路离散化：根据线路的坡度信息以及限速信息，将线路划分为多个不等分的区间。
- 2) 考虑列车长度，计算列车在线路中运行时的等效坡度，以减少误差。
- 3) 多目标优化中对人工蜂群算法的改进主要在适应度值的计算方面，根据 Pareto 支配关系，定义新的适应度值，以淘汰支配解。其次是将寻找到的 Pareto 最优解存储到外部档案中，对外部档案的规模设定固定值，并通过计算拥挤距离维护外部档案。最后定义了新的邻域搜索公式，使得外部档案中的解对邻域搜索起到指引作用。

(5) 应用 MATLAB 进行仿真，以北京地铁亦庄线的实际数据为基础，对本文中提出的方法进行验证。

- 1) 分别对上文中提到的单目标优化方法和多目标优化方法进行验证，得出多目标优化的节能率更高、运行时间误差更小的结论，但多目标优化方法由于需要计算 Pareto 支配关系并对外部档案进行维护，故算法的计算时间相对较长。
- 2) 分别对等分区间和非等分区间的方法进行验证，结果表明等分区间不仅节能效果相对较差、运行时间误差较大，而且算法的计算时间明显增大，验证了非等分区间的正确性。
- 3) 考虑列车的控制策略，对控制策略设置不同的参数，进行仿真结果比较，证明合理的控制策略能在推荐速度曲线优化的基础上得出较好的跟踪速度曲线，达到更优的节能效果。

6.2 展望

本文对列车推荐速度曲线的优化进行了研究，但是由于问题较为复杂，需要考虑的因素过多，研究中仍存在不足，日后需继续改进，概括如下：

(1) 本文对列车进行受力分析时，应用的单质点模型，虽然计算简便，但由于列车长度较长，单质点模型忽略了车厢与车厢之间的相互作用力，产生误差，且未考虑有乘客时列车质量的变化对受力产生的影响。

(2) 本文对列车推荐速度曲线的优化为单列车节能优化，假设站间只有一列列车运行，不受其他列车影响，没有考虑列车的追踪运行。

(3) 本文对推荐速度曲线的优化仅考虑了节能和准时性两个目标，后续可以增加舒适性指标，以列车加速度的变化率作为第三个目标函数，进行优化。

(4) 本文仅验证了ATO控制策略中参数变化对能耗、运行时间误差均能产生影响，并未考虑对控制策略的优化，后续可以通过优化列车的控制策略，提高跟踪精度，以达到更好的节能效果。

参考文献

- [1] 唐涛,黄良骥.列车自动驾驶系统控制算法综述[J].铁道学报,2003(02):98-102.
- [2] 任兴明,王晶晶.国产化城市轨道交通ATO系统设计[J].电子机械工程,2011,27(05):53-56.
- [3] Thales Rail Signaling Solutions Inc. Shanghai Line 11 CBTC System design[Z]. Canada, Thales Rail Signaling Solutions Inc, 2009: 141-143.
- [4] Milroy IP. Aspects of aitomatic train contiol[D]. © Ian Peter Milroy,1980.
- [5] Lee D H, Milroy I P, Tyler K. Application of Pontryagin's maximum principle to the semi-automatic control of rail vehicles[C].Institution of Engineers,Australia,1982.
- [6] Howlett P. Existence of an Optimal Strategy for the Control of a Train[D]. University of South Australia, 1988.
- [7] Howlett P. Optimal strategies for the control of a train[J]. Automatica, 1996, 32(4):519-532.
- [8] Howlett P, Cheng J. Optimal driving strategies for a train on a track with continuously varying gradient[J].The Journal of the Australian Mathematical Society.Series B. Applied Mathematics, 1997, 38(03): 388-410.
- [9] Howlett P. The optimal control of a train [J].Annals of Operations Research, 2000, 98(1-4): 65-87.
- [10] 王自力.列车节能运行优化操纵的研究[J].西南交通大学学报,1994(03):275-280.
- [11] 金炜东,靳蕃,李崇维,胡飞,苟先太.列车优化操纵速度模式曲线生成的智能计算研究[J].铁道学报,1998(05):48-53.
- [12] 李玉生,侯忠生.基于遗传算法的列车节能控制研究[J].系统仿真学报,2007(02):384-387.
- [13] 丁勇,刘海东,柏赟,周方明.地铁列车节能运行的两阶段优化模型算法研究[J].交通运输系统工程与信息,2011,11(01):96-101.
- [14] 耿超. 高速列车节能优化操纵方法的研究[D].西南交通大学,2016.
- [15] 王成莉. 基于遗传算法的高速列车节能运行控制研究[D].北京交通大学,2016.
- [16] Khmelnitsky,Eugene.On an optimal control problem of train operation[J]. IEEE Transactions on Automatic Control,2000
- [17] Khmelnitsky, Eugene. A Combinatorial, Graph-Based Solution Method for a Class of Continuous-Time Optimal Control Problems[J]. Mathematics of Operations Research, 2002, 27(2):312-325.
- [18] Rongfang (Rachel) Liu,Iakov M. Golovitcher. Energy-efficient operation of rail vehicles[J]. Transportation Research Part A,2003,37(10).
- [19] Baranov L , Meleshin I , L. Chin'. Optimal control of a subway train with regard to the criteria of minimum energy consumption[J]. Russian Electrical Engineering, 2011, 82(8):405-410.
- [20] 梁志成,王青元,何坤,冯晓云.基于极大值原理的电动车组节能操纵 [J].铁道学报,2015,37(10):16-25.
- [21] XU Yanping,ZHAO Xia,WANG Lin, et al.Optimal Control of Automatic Train Operation Based on Multi-scale Dynamic Programming[C].//The 33th Chinese Control Conference,2014:3429-3433.
- [22] Jianwei Qu, Xiaoyun Feng , Qingyuan Wang. Real-time trajectory planning for rail transit train

- considering regenerative energy[J]. 17th International IEEE Conference on Intelligent Transportation Systems (ITSC), 2014, pp. 2738-2742.
- [23] Gu Q, Tang T, et al. Energy-Efficient Train Operation in Urban Rail Transit Using Real-Time Traffic Information[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(3): 1216-123.
- [24] 唐海川. 城市轨道交通多列车运行节能优化控制[D].西南交通大学,2015.
- [25] 蔡虎. 城轨列车速度曲线影响因素分析及其节能优化[D].北京交通大学,2016.
- [26] Wong * K K , Ho T K . Dynamic coast control of train movement with genetic algorithm[J]. International Journal of Systems Science, 2004, 35(13-14):835-846.
- [27] Sentinella M R . Comparison and integrated use of differential evolution and genetic algorithms for space trajectory optimisation[C]// IEEE Congress on Evolutionary Computation. IEEE, 2007.
- [28] Bocharnikov Y V , Tobias A M , Roberts C . Reduction of train and net energy consumption using genetic algorithms for Trajectory Optimisation[C]// Railway Traction Systems. IET, 2010.
- [29] Bocharnikov Y V, Tobias A M, Roberts C, et al. Optimal driving strategy for traction energy saving on DC suburban railways[J]. Iet Electric Power Applications, 2007, 1(5):675-682.
- [30] 王鹏玲,林轩,李跃宗,冯晓云.自适应遗传算法在列车节能优化中的应用[J].计算机仿真,2012,29(11):350-354.
- [31] 卢启衡,冯晓云,王青元.基于遗传算法的追踪列车节能优化[J].西南交通大学学报,2012,47(02):265-270.
- [32] 龙凤维. 基于遗传算法的列车最佳惰行点优化研究[D].北京交通大学,2014.
- [33] 王成莉. 基于遗传算法的高速列车节能运行控制研究[D].北京交通大学,2016.
- [34] 桂行东. 基于 Pareto 多目标遗传算法的列车节能运行方法研究[D].南京理工大学,2017.
- [35] 纪云霞,孙鹏飞,毛畅海,王青元.基于改进遗传算法的列车运行曲线优化[J].计算机与现代化,2018(08):1-7.
- [36] Tong He, Rui-Qi Xiong. Research on Multi-Objective Real-Time Optimization of Automatic Train Operation in Urban Rail Transit[J].Journal of Shanghai Jiaotong University,2018,23(02):327-335.
- [37] 杨彦强,刘海东,麻存瑞,徐靓.列车节能运行目标速度控制优化研究[J].交通运输系统工程与信息,2019,19(01):138-144.
- [38] Hui Hu, Yin-ping Fu, Chao Hu. PSO-based optimal operation strategy of energy saving control for train[P]. Industrial Engineering and Engineering Management (IE&EM), 2010 IEEE 17Th International Conference on,2010.
- [39] Hu H . Parallel PSO-Based Optimal Strategy Study of Energy Efficient Operation Control for Train[J]. Advanced Materials Research, 2012, 605-607:5.
- [40] Hu H . PSO-Based Optimal Strategy Study of Train's Energy Efficient Operation under Disturbed Condition[J]. Advanced Materials Research, 2012.
- [41] Gago, María Domínguez, FernándezCardador, Antonio, García, Asunción Paloma Cucala, et al. Multi objective particle swarm optimization algorithm for the design of efficient ATO speed profiles in metro lines.[J]. Engineering Applications of Artificial Intelligence, 2014, 29(3):43-53.
- [42] Fernandez-Rodriguez A , Fernandez-Cardador A , Cucala A P , et al. Design of Robust and

- Energy-Efficient ATO Speed Profiles of Metropolitan Lines Considering Train Load Variations and Delays[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(4):2061-2071.
- [43] Adrián Fernández-Rodríguez, Antonio Fernández-Cardador, Asunción P. Cucala. Energy efficiency in high speed railway traffic operation: a real-time ecodriving algorithm[C]// IEEE International Conference on Environment & Electrical Engineering. IEEE, 2015.
- [44] 任啸宇. 基于优化粒子群算法的列车节能策略研究[D].北京交通大学,2015.
- [45] 叶庆仕,张虹,赵蓉蓉.基于粒子群算法的面向节能的单/多列车优化决策问题[J].数学的实践与认识,2016,46(15):34-44.
- [46] 李玲玉. 基于粒子群算法的城市轨道交通列车节能优化研究[D].北京交通大学,2016.
- [47] 谭文举,贺德强,王合良.基于免疫粒子群算法的地铁列车节能优化研究[J].机车电传动,2017(02):93-95+105.
- [48] 高坚. 高速列车追踪运行节能优化与控制[D].北京交通大学,2018.
- [49] 李烨,郭子立,郭奕杉.基于 PSO 的轨道交通列车节能控制优化研究 [J]. 控制工程,2018,25(10):1911-1915.
- [50] Bwo-Ren Ke , Meng-Chieh Chen , Chun-Liang Lin. Block-Layout Design Using MAX-MIN Ant System for Saving Energy on Mass Rapid Transit Systems[J]. Intelligent Transportation Systems, IEEE Transactions on, 2009, Vol.1 (2), pp.226- 235IEEE
- [51] Lu S , Hillmansen S , Ho T K , et al. Single-Train Trajectory Optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(2):743-750.
- [52] Zhao N , Roberts C , Hillmansen S , et al. An integrated metro operation optimization to minimize energy consumption[J]. Transportation Research Part C: Emerging Technologies, 2017, 75:168-182.
- [53] 范礼乾. 基于蚁群算法的列车推荐速度曲线优化[D].北京交通大学,2016.
- [54] 张志明. 列车开行模式对车辆能耗影响的研究[D].上海工程技术大学,2016.
- [55] 李卓玥. 群智能算法在列车运行速度曲线节能优化中的研究[D].北京交通大学,2016.
- [56] 张靖林. 多机牵引重载列车分布式协同控制[D].北京交通大学,2017.
- [57] Hoang H , Polis M , Haurie A . Reducing energy consumption through trajectory optimization for a metro network[J]. Automatic Control IEEE Transactions on, 1975, 20(5):590-595.
- [58] C.S. Chang, D.Y. Xu, H.B. Quek. Pareto-optimal set based multiobjective tuning of fuzzy automatic train operation for mass transit system[J]. IEE Proceedings - Electric Power Applications, 1999, Vol.146(5).
- [59] Chang C S , Kwan C M . Evaluation of Evolutionary Algorithms for Multi-objective Train Schedule Optimization[M]// AI 2004: Advances in Artificial Intelligence. Springer Berlin Heidelberg, 2004.
- [60] 杨文. 基于无模型自适应控制的列车节能优化运行方法研究[D].北京交通大学,2013.
- [61] S. Liu, F. Cao, J. Xun , Y. Wang. Energy-Efficient Operation of Single Train Based on the Control Strategy of ATO[J], 2015 IEEE 18th International Conference on Intelligent Transportation Systems, Las Palmas, 2015, pp. 2580-2586.
- [62] Psychas I D , Marinaki M , Marinakis Y , et al. Non-dominated sorting differential evolution algorithm for the minimization of route based fuel consumption multiobjective vehicle routing problems[J]. Energy Systems, 2017, 8(4):785-814.

- [63] 陶细华. 基于 GA-SPSO 算法的列车速度曲线优化算法研究[D]. 山东科技大学, 2017.
- [64] 汪仁智, 李德伟, 席裕庚. 采用预测控制的地铁节能优化控制算法 [J]. 控制理论与应用, 2017, 34(09): 1129-1135.
- [65] Li G, Niu P, Xiao X, et al. Development and investigation of efficient artificial bee colony algorithm for numerical function optimization[M]// The cell cycle in development and differentiation;. 2012.
- [66] Karaboga D, Gorkemli B, Ozturk C, et al. A comprehensive survey: artificial bee colony (ABC) algorithm and applications[J]. Artificial Intelligence Review, 2014, 42(1): 21-57.
- [67] Aslan S, Badem H, Karaboga D. Improved quick artificial bee colony (iqABC) algorithm for global optimization[J]. 2019(4).
- [68] 孔翔宇. 几类优化问题的人工蜂群算法[D]. 西安电子科技大学, 2016.
- [69] 何尧, 刘建华, 杨荣华. 人工蜂群算法研究综述[J]. 计算机应用研究, 2018, 35(05): 1281-1286.
- [70] Bing Xue, Emrah Hancer, Mengjie Zhang, et al. Pareto front feature selection based on artificial bee colony optimization[J]. Information Sciences: An International Journal, 2018, 422: 462-479.
- [71] 何宣虎. 基于人工蜂群算法的最优潮流相关技术研究[D]. 北京交通大学, 2016.

图索引

图 1-1 城轨能耗分布图	2
图 2-1 ATC 系统的工作原理	9
图 2-2 ATO 系统的分层控制结构	10
图 2-3 ATO 控制原理示意图	11
图 2-4 列车牵引力示意图	12
图 2-5 列车牵引特性曲线示意图	12
图 2-6 列车制动力示意图	13
图 2-7 坡道附加阻力示意图	15
图 2-8 列车运行受力分析	16
图 2-9 列车运行工况示意图	22
图 3-1 蜜蜂采蜜行为示意图	26
图 3-2 三种蜜蜂之间的转换关系图	26
图 3-3 人工蜂群算法流程图	30
图 3-4 Sphere Model 函数图形	32
图 3-5 Sphere Model 的适应度进化曲线	34
图 3-6 Griewank 函数图形	35
图 3-7 Griewank 的适应度进化曲线	36
图 3-8 Generalized Rosenbrock 函数图形	37
图 3-9 Generalized Rosenbrock 的适应度进化曲线	39
图 3-10 ABC 算法优化的适应度进化曲线	40
图 3-11 PSO 算法优化的适应度进化曲线	40
图 3-12 DE 算法优化的适应度进化曲线	41
图 4-1 列车推荐速度曲线优化示意图	44
图 4-2 Pareto 前端示意图	46
图 4-3 线路等分分区示意图	49
图 4-4 线路非等分分区示意图	49
图 4-5 不同速度码之间的连接策略	50
图 4-6 单目标优化流程图	53
图 4-7 多目标优化流程图	57
图 5-1 AW0 下的列车牵引制动特性曲线	60
图 5-2 跟踪策略示意图	61
图 5-3 最优能耗进化曲线	62
图 5-4 单目标优化仿真图	63
图 5-5 Pareto 前端	64
图 5-6 多目标优化仿真图	64
图 5-7 等分区间仿真图	66
图 5-8 不同控制策略下的优化结果	67

表索引

表 2-1 列车最优操纵工况	21
表 2-2 列车运行工况转换原则表	21
表 2-3 乘客舒适度评价表	24
表 3-1 蜜蜂采蜜行为与优化问题的对应关系表.....	27
表 3-2 Sphere Model 仿真数据.....	33
表 3-3 Griewank 仿真数据.....	36
表 3-4 Generalized Rosenbrock 仿真数据	38
表 3-5 不同迭代次数下 Sphere Model 的仿真数据	41
表 5-1 同济南路-经海路线路数据	59
表 5-2 同济南路-经海路车辆参数表	60
表 5-3 单目标优化前后数据结果对比.....	63
表 5-4 多目标优化前后数据结果对比.....	65
表 5-5 单目标与多目标优化对比结果.....	65
表 5-6 等分区间与非等分区间的对比结果.....	66
表 5-7 不同控制策略下的优化对比结果.....	68

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

刘海娜，女，1995年8月出生，山东潍坊人，硕士研究生，主要研究方向为列车运行节能优化控制。

2013年9月-2017年6月山东理工大学电气学院自动化专业本科生，并于2017年6月获得工学学士学位。

2017年9月-2019年6月北京交通大学电子信息工程学院控制工程专业研究生。

二、实习经历

2018年3月-2018年8月 交控科技股份有限公司研发部白盒测试组 实习生

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：刘海娜 签字日期：2019年6月15日

学位论文数据集

表 1.1: 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
城市轨道交通; 推荐速度曲线; 人工蜂群算法; 多目标节能优化; ATO 控制策略	公开			
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
北京交通大学	10004	工学	硕士	
论文题名*	并列题名			论文语种*
基于人工蜂群算法的推荐速度曲 线节能优化				中文
作者姓名*	刘海娜		学号*	17125108
培养单位名称*	培养单位代码*	培养单位地址	邮编	
北京交通大学	10004	北京市海淀区西直 门外上园村 3 号	100044	
工程领域*	研究方向*	学制*	学位授予年*	
控制工程	城市轨道交通节 能优化	2	2019	
论文提交日期*	2019.6.1			
导师姓名*	王俊峰		职称*	教授
评阅人	答辩委员会主席*		答辩委员会成员	
	步兵		徐田华 蒋海林 牛儒 陆德彪	
电子版论文提交格式 文本() 图像() 视频() 音频() 多媒体() 其他() 推荐格式: application/msword; application/pdf				
电子版论文出版(发布)者	电子版论文出版(发布)地			权限声明
论文总页数*	101			
共 33 项, 其中带*为必填数据, 为 21 项。				